

Récapitulatif — lois de calibration des PI

DeepEdgeBenchmark vs DEITA (LocalProjectTimeSeries1) — 2 août 2026

Les deux projets sont partis du même constat — les intervalles de prédiction gaussiens natifs sous-couvrent massivement (MACE 8 à 28 points côté DeepEdgeBenchmark ; couvertures live de 5 à 83 % pour un nominal de 95 % côté DEITA) — mais ont pris deux routes opposées. DeepEdgeBenchmark corrige la loi : il choisit une distribution mieux adaptée par modèle et recalibre sa variance par lissage EWMA causal. DEITA ignore la loi : il conserve la prévision ponctuelle et reconstruit l'intervalle à partir des quantiles empiriques des résidus observés (calibration conforme, distribution-free). Les deux convergent sur la diffusion (quantiles du nuage d'échantillons, aucune hypothèse paramétrique) et sur les exigences transverses : causalité stricte (as-of), réversibilité et traçabilité de la correction.

1. DeepEdgeBenchmark — lois paramétriques par modèle (adopté en prod)

Campagne σ dynamique des 30-31 juillet 2026 : 5 modèles daily (+ variantes hebdo), 3 fenêtres de validation, 5 actifs. Les options « swap de loi post-hoc » (Student-t, GED sur résidus), CQR conforme et MDN ont été testées puis écartées — voir §3.

Modèle	Loi des PI	Correction de variance	Effet (MACE)
ARIMA-GARCH	Skew-t natif (innovations GARCH), quantiles asymétriques → log-normale asymétrique en prix	Aucune EWMA — le σ GARCH est déjà dynamique (refit à chaque run)	2,5-4,0 ; seule option robuste sur les 3 fenêtres
SARIMA	Normale (Kalman)	$\times \sqrt{\text{EWMA}(z^2)}$ causale, $\lambda = 0,94$ (D+1), $\lambda = 0,94^{1/7}$ (D+7) — multiplicative, dynamique Kalman préservée	9,9 → 4,0
Prophet	Log-espace → lognormale en prix	$\times$ EWMA, $\lambda = 0,94$ partout (exception documentée au garde-fou D+7)	28 → 5-7 sur SPY/BTC/ETH ; ZN/TLT à confirmer (le log seul dégrade)
LSTM	Normale	σ EWMA sur résidus observés, $\lambda = 0,94$ (D+1), $\lambda = 0,94^{1/7}$ (D+7)	10-16 → 3-6
Naive	Normale (marche aléatoire)	σ EWMA des variations observées ; $\sqrt{h}$ pour D+7	10-16 → 3-6 (plage commune avec LSTM ; l'EWMA bat le CQR hors fenêtre 1)
TSDiff-D / TSDiff-W	Empirique : quantiles du nuage d'échantillons de diffusion — aucune loi imposée	Aucune (hors périmètre calibration)	—
Variantes hebdo (SARIMA-W, Prophet-W, LSTM-W)	Mêmes lois que le daily	EWMA $\lambda = 0,94$ par origine hebdo	Backfill OOS uniquement (seul TSDiff-W est live en hebdo)

Reporting : le CRPS est passé « distribution-aware » (two-piece, lognormale, Student-t) — plus de symétrie gaussienne forcée dans les métriques. Toutes les corrections EWMA sont causales (seules les prédictions résolues alimentent l'état), réversibles (--calibrate-sigma off) et tracées ligne à ligne dans tracking.db (sigma_scale_applied).

2. DEITA — calibration distribution-free / conforme

Système de production à 3 sleeves (9 modèles IA, CTA, pool de diffusion). Le tier daily live avait des couvertures réelles de 5 % (GRU) à 83 % (ARIMA) pour un nominal de 95 % : les largeurs natives des PI ont été jugées sans signal et remplacées, plutôt que corrigées.

Périmètre	Méthode / loi	Détail
Sleeve 1 — live daily (9 modèles)	Split-conformal glissant, symétrique, distribution-free	$\hat{q}$ = quantile fini-échantillon (rang $[(n+1) \cdot 0,95]$) des $ \text{résidus} $ live, fenêtre $N = 60$; intervalle = $\text{pred} \pm \hat{q}$; chaîne de repli (actif, modèle) → pool normalisé par prix → PI brut flaggé ; as-of strict (aucun look-ahead) ; validation walk-forward exigée (couverture cible [88 %, 98 %]) avant activation
Sleeve 1 — benchmark (XGBoost, RF, PatchTST, NBEATS)	Grille prédictive conforme (99 quantiles)	pred + quantiles empiriques des résidus signés (fenêtre glissante, monotone) → axe CRPS/NLL sans ré-entraînement
Sleeve 1 — benchmark (LSTM, GRU)	Nuage MC-Dropout (empirique)	Distribution d'échantillons (n_{test} , N_{MC}) → CRPS/NLL ; ARIMA/Prophet restent ponctuels (axes intervalle seulement)
Gate de calibration	Couverture conditionnelle (Christoffersen) en axe HARD	$p < 0,01$ fail / $p < 0,05$ warn ; couverture marginale rétrogradée en guard ($ \text{cov} - 0,95 > 0,08$) ; Winkler (interval score) + axes skill CRPS/Winkler SOFT vs baseline random-walk (plancher $-0,05$)
Sleeve 3 — diffusion (TSDiff, TimeGrad, Mamba-S6)	Empirique (nuage) + correction de dispersion	Aujourd'hui : shrink scalaire post-hoc α ($x \leftarrow \mu + \alpha \cdot (x - \mu)$) ; en cours de remplacement par la variance apprise (Improved DDPM, perte hybride VLB) et le prior data-dependent $N(0, \Sigma)$ (PriorGrad), Σ pilotée par la vol réalisée / le régime
Régime (Option B)	Conforme par régime	Offsets conformes / scaling d'intervalle par régime HMM (calm / trending / stress) ; Christoffersen stratifié par régime — corrige « trop large en calme, trop étroit en turbulent »

Effet observé : le gate discrimine réellement — XGBoost/BTC-USD bloqué ($\text{cond_cov_p} = 0,0001$, clustering de volatilité) malgré 97 % de couverture marginale ; SPY passe ($p = 0,72$) ; GC=F en warning. Parité Sleeve 1 livrée de bout en bout (migrations 027/028, runs #2321 → #2350, tests 56/56).

3. Comparaison directe

Axe	DeepEdgeBenchmark	DEITA
Philosophie	Paramétrique : choisir la bonne loi, corriger σ par EWMA causale	Distribution-free : quantiles empiriques des résidus (conforme)
Loi centrale	Skew-t (GARCH), normale $\times$ EWMA, lognormale (log-espace)	Aucune loi imposée ; gaussien natif conservé mais largeur remplacée
Conformal / CQR	Testé (CQR gagnant apparent en fenêtre 1 : SARIMA 8,1 $\rightarrow$ 4,4) puis écarté : s'effondre hors fenêtre (11,5 en W2)	Adopté en live : split-conformal sur fenêtre glissante N = 60 de résidus récents — la fenêtre courte suit le régime
Queues épaisses / asymétrie	Portées par la loi (skew-t, lognormale, CRPS two-piece)	Portées par les résidus empiriques et le nuage de diffusion ; v2 : quantiles asymétriques (ACI) prévus
Diffusion	TSDiff : quantiles du nuage, hors périmètre calibration	Même principe, mais calibration active : shrink $\alpha \rightarrow$ variance apprise + PriorGrad
Contrôle qualité	MACE strict (moyenne par actif), 3 fenêtres de validation, pinball/CRPS	Gate multi-axes : Christoffersen HARD, guard ± 8 pp, Winkler, CRPS skill, leaderboard
Écartés	Swap Student-t/GED post-hoc (non robuste), CQR, MDN (pire, +23 % coût), σ rolling 20 j, GARCH sur résidus ($<$ EWMA), rescale $\times 1,08$	Couverture marginale comme axe unique (rétrogradée) ; <code>_sharp_alpha</code> en voie de retrait ; ACI/poids décroissants reportés en v2

4. Lecture croisée — pourquoi deux verdicts opposés sur le conforme ?

Le CQR écarté par DeepEdgeBenchmark était calibré une fois sur une fenêtre fixe (40 % de la période de test) puis appliqué tel quel : il mémorise le niveau de volatilité de sa fenêtre et casse quand le régime change. Le split-conformal adopté par DEITA est recalculé à chaque prédiction sur les 60 derniers résidus live : c'est une correction adaptative, fonctionnellement plus proche de l'EWMA de DeepEdgeBenchmark ($\lambda = 0,94 \approx$ mémoire effective de ~ 33 jours) que du CQR statique rejeté. Les deux projets ont donc convergé vers la même idée — recalibrer en continu sur l'erreur récente — l'un via un multiplicateur de σ paramétrique, l'autre via un quantile empirique. Restent deux vraies divergences : la forme (skew-t/lognormale explicites vs intervalles symétriques v1 côté DEITA) et le conditionnement (DEITA stratifié par régime HMM ; DeepEdgeBenchmark s'appuie sur la réactivité de l'EWMA).

5. Sources

- DeepEdgeBenchmark : 20260801_Recap_modeles_lois_calibration.pdf ; comparaison_options_calibration_tous_modeles.pdf (29-30/07, MACE strict) ; HANDOFF_sigma_calibration_suivi.md ; BRIEF_branchement_prod_calibration_sigma.md ; NOTE_reponse_prophet_zn_tlt.md
- DEITA : CALIBRATION_OVERVIEW.md (30/06) ; BRIEF_conformal_pi_calibration.md (07/07) ; BRIEF_sleeve1_calibration_parity.md ; BRIEF_regime_adaptive_calibration.md (02/07) ; BRIEF_diffusion_learned_variance_and_prior.md