

Comparaison des options de calibration des PI — tous modèles

DeepEdgeBenchmark — option 1 (loi alternative) étendue aux 5 modèles, options 2 (CQR) et 3 (MDN) testées en comparaison

Résultats au 29 juillet 2026 — corrigé le 30 juillet 2026

Correction du 30 juillet 2026 : les chiffres ci-dessous utilisent désormais `mace_strict` (erreur de calibration moyennée par actif, puis mise en valeur absolue) plutôt que `mace_loose` (valeur absolue de la moyenne inter-actifs). La version loose laissait des écarts de signe opposé s'annuler entre actifs (BTC sur-couvre, SPY sous-couvre → « calibré » en moyenne sans qu'aucun des deux actifs le soit) — repéré par une vérification indépendante (voir `HANDOFF_sigma_calibration_suivi.md`). Les chiffres sont moins spectaculaires qu'hier mais honnêtes ; deux verdicts s'en trouvent inversés (LSTM, ARIMA-GARCH — voir §3).

1 Méthode

Chaque modèle est réévalué via son propre backtest walk-forward existant, non modifié. La fenêtre de test (2020–2024, 15 % en test) est séparée chronologiquement en une fenêtre de calibration (40 %, jamais notée) et une fenêtre d'évaluation (60 %, seule fenêtre servant au calcul des KPIs). **Erreur de calibration** (MACE stricte) = moyenne, sur les 5 actifs, des écarts absolus entre couverture mesurée et cible aux niveaux 50/80/95 % — 0 = parfaitement calibré, sans possibilité de compensation entre actifs.

2 Verdict par modèle

Modèle	Erreur avant	Meilleure option	Erreur après	Δ	Surcoût	Verdict
SARIMA	8,07	CQR	4,43	-45%	+0.001s / 70s	Vaut le coût — CQR nettement devant
Prophet	28,08	CQR	20,67	-26%	+0.000s / 164s	Aucune option testée ne suffit
LSTM	10,96	CQR	8,43	-23%	+0.000s / 31s	Aide un peu, ne règle pas le vrai problème
Naive	9,26	CQR	3,76	-59%	+0.000s / 0s	Vaut le coût — CQR nettement devant
ARIMA-GARCH	4,49	GED natif (refit)	2,51	-44%	+2.6s / 3s	Le refit natif l'emporte pour de bon

Erreur de calibration en points de pourcentage (MACE stricte, 0 = parfait). Surcoût : coût de l'option / coût du backtest de base du modèle (mêmes unités, secondes). Détail complet (4 à 6 options par modèle, largeur, pinball, CRPS) dans `experiments/dist_options_summary.json`.

3 Ce qu'il faut retenir

- **CQR est l'option qui aide le plus souvent** — SARIMA (8,07→4,43), Naive (9,26→3,76), Prophet, et même LSTM (10,96→8,43) — les quatre modèles dont le σ ne varie pas dans le temps par construction. -23 à -59 % d'erreur de calibration pour un surcoût de calcul négligeable.
- **Le swap de loi seul (Student-t/GED) est plus fragile qu'il n'y paraissait sous l'ancienne agrégation.** Net pour SARIMA, mais pour Naive GED fait à peine mieux que ne rien faire (7,81 contre 9,26 sans rien faire, contre 3,76 pour CQR) ; pour LSTM il *dégrade* franchement la calibration (jusqu'à 12,53 contre 10,96 sans rien faire) — le σ de LSTM est une seule valeur figée sur les résidus d'entraînement, pas un chemin qui varie dans le temps ; lui changer la forme de queue ne corrige pas un problème de niveau.

- **Ça ne corrige rien quand le problème est ailleurs.** Prophet sous-couvre massivement à *tous* les niveaux (erreur 28,08 points) — changer la forme de la queue autour d'un σ déjà trop petit ne le rend pas plus grand ; même CQR (20,67) ne suffit pas à le rendre correctement calibré.
- **Pour ARIMA-GARCH, c'est l'inverse : le refit natif l'emporte pour de bon** sur le swap manuel gratuit (2,51 contre 3,27 points) — et CQR, ici seulement, fait moins bien (4,27) que les corrections de forme. Logique : c'est le seul modèle dont le σ est déjà dynamique par construction (GARCH), donc le vrai problème restant est la forme de la queue, pas son niveau — l'inverse du diagnostic pour les 4 autres modèles.
- **Le MDN (option 3) n'est pas rentable en l'état.** Erreur moyenne 13,74 contre 10,96 pour le LSTM de production (pire, +25 %), pour +23 % de temps d'entraînement, et une instabilité réelle d'un entraînement à l'autre à seed égal (couverture à 50 % sur SPY : 66 % puis 14 % entre deux runs identiques avant stabilisation).
- **Tout ce qui précède reste sur une seule fenêtre (2020–2024).** Un travail de suivi (HANDOFF_sigma_calibration_suivi.md) a testé les mêmes options sur 3 fenêtres temporelles et montré que les gagnants statiques ci-dessus (CQR pour SARIMA/Naive) ne généralisent pas d'une fenêtre à l'autre — seul ARIMA-GARCH natif reste robuste. La correction qui tient sur les 3 fenêtres pour les 4 autres modèles est un σ dynamique par EWMA causale, pas un choix de loi statique — à lire avant d'adopter quoi que ce soit en dur sur la base de ce document seul.

Code: experiments/dist_options_common.py, all_models_dist_options.py, lstm_mdn_prototype.py, summarize_dist_options.py · données: experiments/dist_options_summary.json · suivi robustesse/EWMA: HANDOFF_sigma_calibration_suivi.md.