

# Comparaison des options de calibration des PI — tous modèles

DeepEdgeBenchmark — option 1 (loi alternative) étendue aux 5 modèles, options 2 (CQR) et 3 (MDN) testées en comparaison

Résultats au 29 juillet 2026 — corrigé le 30 juillet 2026

**Correction du 30 juillet 2026** : les chiffres ci-dessous utilisent désormais `mace_strict` (erreur de calibration moyennée par actif, puis mise en valeur absolue) plutôt que `mace_loose` (valeur absolue de la moyenne inter-actifs). La version loose laissait des écarts de signe opposé s'annuler entre actifs (BTC sur-couvre, SPY sous-couvre → « calibré » en moyenne sans qu'aucun des deux actifs le soit) — repéré par une vérification indépendante (voir `HANDOFF_sigma_calibration_suivi.md`). Les chiffres sont moins spectaculaires qu'hier mais honnêtes ; deux verdicts s'en trouvent inversés (LSTM, ARIMA-GARCH — voir §3).

## 1 Méthode

Chaque modèle est réévalué via son propre backtest walk-forward existant, non modifié. La fenêtre de test (2020–2024, 15 % en test) est séparée chronologiquement en une fenêtre de calibration (40 %, jamais notée) et une fenêtre d'évaluation (60 %, seule fenêtre servant au calcul des KPIs).

**Qu'est-ce que « l'erreur » du tableau et des graphiques ?** Chaque prévision vient avec un intervalle de confiance à 3 niveaux (50 %, 80 %, 95 %) — censé contenir le vrai prix 50/80/95 % du temps. On mesure combien de fois, en pratique, le vrai prix est tombé dans cet intervalle (la couverture), et on compare à la cible. « **Erreur de calibration** » = l'écart moyen, en points de pourcentage, entre couverture mesurée et couverture visée, aux 3 niveaux et sur les 5 actifs — 0 = l'intervalle tient exactement sa promesse. Exemple : une erreur de 8 points veut dire qu'en moyenne l'intervalle censé être juste 1 fois sur 2 (50 %) l'est en réalité 58 % ou 42 % du temps — trop large ou trop étroit, dans un sens ou dans l'autre. Ce n'est pas une erreur de prédiction de prix (RMSE) — un modèle peut prédire le prix tout aussi bien avant et après correction, seule la fiabilité de son intervalle change (cf. « Pinball rel. » dans les tableaux §3, qui lui reflète la qualité de l'intervalle dans son ensemble, largeur et position).

## 2 Verdict par modèle


| Modèle      | Erreur calib. avant | Meilleure option  | Erreur calib. après | $\Delta$ | Surcoût        | Verdict                                    |
|-------------|---------------------|-------------------|---------------------|----------|----------------|--------------------------------------------|
| SARIMA      | 8,07                | CQR               | 4,43                | -45%     | +0,001s / 70s  | Vaut le coût — CQR nettement devant        |
| Prophet     | 28,08               | CQR               | 20,67               | -26%     | +0,000s / 164s | Aucune option testée ne suffit             |
| LSTM        | 10,96               | CQR               | 8,43                | -23%     | +0,000s / 31s  | Aide un peu, ne règle pas le vrai problème |
| Naive       | 9,26                | CQR               | 3,76                | -59%     | +0,000s / 0s   | Vaut le coût — CQR nettement devant        |
| ARIMA-GARCH | 4,49                | GED natif (refit) | 2,51                | -44%     | +2,6s / 3s     | Le refit natif l'emporte pour de bon       |

Erreur de calibration en points de pourcentage (MACE stricte, 0 = parfait). Surcoût : coût de l'option / coût du backtest de base du modèle (mêmes unités, secondes). Détail complet (4 à 6 options par modèle, largeur, pinball, CRPS) dans `experiments/dist_options_summary.json`.

## 3 Détail par modèle

Barres : erreur de calibration stricte par option (plus court = mieux calibré). Tableau : couverture aux 3 niveaux, largeur relative au cas gaussien, perte pinball relative, et surcoût de calcul par rapport au backtest de base.

SARIMA — *Vaut le coût* — CQR nettement devant



Erreur de calibration — points de % d'écart à la couverture visée (0 = parfait, plus court = mieux)

| Option                 | Cov 50% | Cov 80% | Cov 95% | Larg. rel. | Pinball rel. | Surcoût |
|------------------------|---------|---------|---------|------------|--------------|---------|
| Gaussienne (actuel)    | 57,5%   | 83,4%   | 92,3%   | 1,00×      | 1,000×       | +0,001s |
| Student-t (fit manuel) | 49,2%   | 77,7%   | 92,4%   | 0,80×      | 0,977×       | +0,006s |
| GED (fit manuel)       | 51,3%   | 81,7%   | 93,2%   | 0,84×      | 0,988×       | +0,020s |
| CQR                    | 52,1%   | 80,9%   | 94,8%   | 0,86×      | 0,963×       | +0,001s |

Backtest de base : 70,2s par actif, avant tout surcoût d'option.

Prophet — *Aucune option testée ne suffit*



Erreur de calibration — points de % d'écart à la couverture visée (0 = parfait, plus court = mieux)

| Option                 | Cov 50% | Cov 80% | Cov 95% | Larg. rel. | Pinball rel. | Surcoût |
|------------------------|---------|---------|---------|------------|--------------|---------|
| Gaussienne (actuel)    | 24,3%   | 46,1%   | 70,4%   | 1,00×      | 1,000×       | +0,001s |
| Student-t (fit manuel) | 24,1%   | 46,0%   | 70,4%   | 1,00×      | 1,000×       | +0,008s |
| GED (fit manuel)       | 25,4%   | 46,9%   | 67,8%   | 1,07×      | 0,999×       | +0,017s |
| CQR                    | 31,3%   | 54,2%   | 77,7%   | 1,32×      | 0,923×       | +0,000s |

Backtest de base : 164,1s par actif, avant tout surcoût d'option.

**LSTM — Aide un peu, ne règle pas le vrai problème**




Erreur de calibration — points de % d'écart à la couverture visée (0 = parfait, plus court = mieux)

| Option                 | Cov 50% | Cov 80% | Cov 95% | Larg. rel. | Pinball rel. | Surcoût |
|------------------------|---------|---------|---------|------------|--------------|---------|
| Gaussienne (actuel)    | 44,9%   | 73,0%   | 86,9%   | 1,00×      | 1,000×       | +0,000s |
| Student-t (fit manuel) | 36,4%   | 67,7%   | 87,2%   | 0,85×      | 1,004×       | +0,003s |
| GED (fit manuel)       | 37,5%   | 70,5%   | 88,3%   | 0,87×      | 1,003×       | +0,013s |
| CQR                    | 43,1%   | 67,8%   | 93,4%   | 1,00×      | 0,976×       | +0,000s |

Backtest de base : 30,6s par actif, avant tout surcoût d'option.

**Naive — Vaut le coût — CQR nettement devant**




Erreur de calibration — points de % d'écart à la couverture visée (0 = parfait, plus court = mieux)

| Option                 | Cov 50% | Cov 80% | Cov 95% | Larg. rel. | Pinball rel. | Surcoût |
|------------------------|---------|---------|---------|------------|--------------|---------|
| Gaussienne (actuel)    | 60,8%   | 82,4%   | 92,3%   | 1,00×      | 1,000×       | +0,000s |
| Student-t (fit manuel) | 48,6%   | 78,1%   | 92,1%   | 0,78×      | 0,970×       | +0,003s |
| GED (fit manuel)       | 50,4%   | 81,1%   | 93,2%   | 0,81×      | 0,984×       | +0,015s |
| CQR                    | 53,1%   | 80,9%   | 94,8%   | 0,88×      | 0,952×       | +0,000s |

Backtest de base : 0,0s par actif, avant tout surcoût d'option.

## ARIMA-GARCH — *Le refit natif l'emporte pour de bon*



Erreur de calibration — points de % d'écart à la couverture visée (0 = parfait, plus court = mieux)

| Option                     | Cov 50% | Cov 80% | Cov 95% | Larg. rel. | Pinball rel. | Surcoût |
|----------------------------|---------|---------|---------|------------|--------------|---------|
| Gaussienne (actuel)        | 58,3%   | 84,1%   | 94,4%   | 1,00×      | 1,000×       | +0,000s |
| Student-t (fit manuel)     | 52,3%   | 80,8%   | 94,2%   | 0,87×      | 0,992×       | +0,004s |
| GED (fit manuel)           | 53,5%   | 83,3%   | 95,2%   | 0,91×      | 0,994×       | +0,053s |
| CQR                        | 54,8%   | 82,5%   | 96,1%   | 0,93×      | 0,999×       | +0,000s |
| GED natif (refit GARCH)    | 52,4%   | 81,9%   | 94,7%   | 0,87×      | 1,000×       | +2,6s   |
| Skew-t natif (refit GARCH) | 52,7%   | 80,2%   | 94,0%   | 0,88×      | 0,999×       | +2,4s   |

Backtest de base : 3,2s par actif, avant tout surcoût d'option.

## 4 Option 3 — gros plan MDN

### Option 3 — gros plan MDN (LSTM)

Seul modèle testé qui demande un vrai réentraînement (pas un post-traitement) — architecture identique au LSTM de production, seule la tête de sortie change (Dense(1) → mélange de 3 gaussiennes, perte MSE → log-vraisemblance).



Erreur de calibration — points de % d'écart à la couverture visée (0 = parfait, plus court = mieux)

| Actif | Cov 50% (moy. ± écart-type) | Cov 95% (moy.) | CRPS (moy.) | Temps d'entraînement |
|-------|-----------------------------|----------------|-------------|----------------------|
| SPY   | 27,1% ±4,2                  | 95,6%          | 8,20        | 34,6s                |
| BTC   | 68,7% ±7,0                  | 98,4%          | 1859,20     | 48,6s                |
| ETH   | 72,8% ±2,8                  | 97,2%          | 88,67       | 43,0s                |
| ZN    | 80,5% ±1,9                  | 99,7%          | 0,48        | 27,6s                |
| TLT   | 76,1% ±0,7                  | 99,1%          | 0,72        | 34,1s                |

Couverture à 50/95% et CRPS moyennés sur 3 seeds par actif — l'écart-type sur la couverture à 50% est l'instabilité d'un entraînement à l'autre, code et données identiques (seeds [42, 43, 44]). Coût moyen 37,6s contre 30,6s pour le LSTM de production.

## 5 Ce qu'il faut retenir

- **CQR est l'option qui aide le plus souvent** — SARIMA (8,07→4,43), Naive (9,26→3,76), Prophet, et même LSTM (10,96→8,43) — les quatre modèles dont le  $\sigma$  ne varie pas dans le temps par construction. -23 à -59 % d'erreur de calibration pour un surcoût de calcul négligeable.
- **Le swap de loi seul (Student-t/GED) est plus fragile qu'il n'y paraissait sous l'ancienne agrégation.** Net pour SARIMA, mais pour Naive GED fait à peine mieux que ne rien faire (7,81 contre 9,26 sans rien faire, contre 3,76 pour CQR) ; pour LSTM il *dégrade* franchement la calibration (jusqu'à 12,53 contre 10,96 sans rien faire) — le  $\sigma$  de LSTM est une seule valeur figée sur les résidus d'entraînement, pas un chemin qui varie dans le temps ; lui changer la forme de queue ne corrige pas un problème de niveau.
- **Ça ne corrige rien quand le problème est ailleurs.** Prophet sous-couvre massivement à *tous* les niveaux (erreur 28,08 points) — changer la forme de la queue autour d'un  $\sigma$  déjà trop petit ne le rend pas plus grand ; même CQR (20,67) ne suffit pas à le rendre correctement calibré.
- **Pour ARIMA-GARCH, c'est l'inverse : le refit natif l'emporte pour de bon** sur le swap manuel gratuit (2,51 contre 3,27 points) — et CQR, ici seulement, fait moins bien (4,27) que les corrections de forme. Logique : c'est le seul modèle dont le  $\sigma$  est déjà dynamique par construction (GARCH), donc le vrai problème restant est la forme de la queue, pas son niveau — l'inverse du diagnostic pour les 4 autres modèles.
- **Le MDN (option 3) n'est pas rentable en l'état.** Erreur moyenne 13,74 contre 10,96 pour le LSTM de production (pire, +25 %), pour +23 % de temps d'entraînement, et une instabilité réelle d'un entraînement à l'autre à seed égal (couverture à 50 % sur SPY : 66 % puis 14 % entre deux runs identiques avant stabilisation).
- **Tout ce qui précède reste sur une seule fenêtre (2020–2024).** Un travail de suivi (HANDOFF\_sigma\_calibration\_suivi.md) a testé les mêmes options sur 3 fenêtres temporelles et montré que les gagnants statiques ci-dessus (CQR pour SARIMA/Naive) ne généralisent pas d'une fenêtre à l'autre — seul ARIMA-GARCH natif reste robuste. La correction qui tient sur les 3 fenêtres pour les 4 autres modèles est un  $\sigma$  dynamique par EWMA causale, pas un choix de loi statique — à lire avant d'adopter quoi que ce soit en dur sur la base de ce document seul.

---

Code: experiments/dist\_options\_common.py, all\_models\_dist\_options.py, lstm\_mdn\_prototype.py, summarize\_dist\_options.py · données: experiments/dist\_options\_summary.json · suivi robustesse/EWMA: HANDOFF\_sigma\_calibration\_suivi.md.