

CRPS gaussien vs CRPS empirique

DeepEdgeBenchmark — lecture des KPIs probabilistes

Etat au 24 juillet 2026

Mini synthèse

Le tableau de bord `distributions_dashboard.html` ($n=113$ à 178 selon l'actif, horizon $D+1$) confirme un classement stable : **Naive**, **ARIMA-GARCH** et **SARIMA** forment un trio de tête quasiment indiscernable de la persistance pure, **TSDiff** se positionne juste derrière (proche du trio sur BTC/ETH, plus en retrait sur SPY/ZN=F/TLT), **LSTM** est systématiquement 5e et **Prophet** systématiquement dernier, sur les 5 actifs sans exception. Ce constat ne change pas selon qu'on lise le CRPS gaussien (forme fermée, dans le dashboard) ou le CRPS empirique (calculé ici à partir des vrais nuages d'échantillons, `experiments/kpi_probabilistes.json`) — les deux racontent la même histoire au niveau global.

Ce qui change en revanche : (1) l'ordre fin à *l'intérieur* du trio de tête (Naive vs ARIMA-GARCH) bouge selon le CRPS choisi, cf. §3 ; (2) l'écart entre les deux mesures est bien plus grand pour Prophet (jusqu'à $+162\%$) et TSDiff (jusqu'à $\pm 28\%$) que pour ARIMA-GARCH/SARIMA/Naive (souvent $<10\%$) — signe que le CRPS empirique est la mesure qui reflète le mieux les modèles dont la vraie distribution s'écarte de l'hypothèse gaussienne implicite, cf. §4.

1 Rappel : deux façons de calculer le même CRPS

- **CRPS gaussien** (dans `distributions_dashboard.html`) : forme fermée (`honest_eval.metrics.crps_gaussian`) à partir de μ (le point prédit) et σ recouvré depuis la largeur de l'IC95 % stocké ($\sigma = (y_{upper} - y_{lower}) / (2 \times 1.96)$). Aucun tirage, exact sous l'hypothèse gaussienne.
- **CRPS empirique** (dans `experiments/kpi_probabilistes.json`, via `crps_metrics.crps_empirical`) : calculé sur un vrai nuage de $N = 500$ tirages par prévision. Pour ARIMA-GARCH/SARIMA/Prophet/LSTM/Naive ces 500 tirages sont eux-mêmes générés en *échantillonnant la loi gaussienne (ou log-normale pour ARIMA-GARCH) implicite du modèle*, à partir du même $(y_{pred}, y_{lower}, y_{upper})$ — donc en théorie la même distribution que le CRPS gaussien, juste estimée par Monte Carlo plutôt que par la formule fermée (`experiments/generate_samples_parametric.py`, `prob_kpi_common.sample_parametric`, vérifié directement dans le code). Pour TSDiff seul, les 500 tirages sont natifs : un vrai ré-échantillonnage du modèle de diffusion (`generate_samples_tsdiff.py`), pas une approximation gaussienne.

Limite méthodologique à garder en tête : les deux sources ne couvrent pas exactement la même fenêtre de backtest. Le dashboard utilise $n=165$ (BTC/ETH) ou $113-114$ (SPY/ZN=F/TLT), démarrant le 08/02/2026 ; `kpi_probabilistes.json` utilise $n=177-178$ ou $117-119$, démarrant le 24/01/2026 — soit ~ 12 à 14 origines de plus. Une partie de l'écart chiffré en §3 vient donc aussi de la fenêtre, pas seulement du choix de métrique. C'est précisément pour cette raison que ce document interprète les écarts en tendance et en ordre de grandeur, pas au chiffre près.

2 Comparaison D+1, tous modèles, tous actifs

Code couleur sur l'écart relatif $(\text{empirique} - \text{gaussien})/\text{gaussien}$: vert $< 10\%$ en valeur absolue (les deux mesures racontent la même chose), orange $10\text{--}40\%$, rouge $> 40\%$ (les deux mesures divergent nettement).

Actif	Modèle	CRPS gaussien	CRPS empirique	Écart
BTC-USD	ARIMA-GARCH	844,58	955,97	+13,2 %
BTC-USD	SARIMA	818,89	968,46	+18,3 %
BTC-USD	Prophet	3404,51	6333,07	+86,0 %
BTC-USD	LSTM	1429,86	2391,82	+67,3 %
BTC-USD	Naive	816,95	977,02	+19,6 %
BTC-USD	TSDiff	854,32	1056,02	+23,6 %
ETH-USD	ARIMA-GARCH	32,74	38,90	+18,8 %
ETH-USD	SARIMA	35,52	41,59	+17,1 %
ETH-USD	Prophet	194,38	349,75	+79,9 %
ETH-USD	LSTM	57,05	56,36	−1,2 %
ETH-USD	Naive	35,71	42,08	+17,8 %
ETH-USD	TSDiff	33,70	43,27	+28,4 %
SPY	ARIMA-GARCH	3,55	3,58	+1,0 %
SPY	SARIMA	3,47	3,50	+0,8 %
SPY	Prophet	11,21	16,18	+44,3 %
SPY	LSTM	10,68	7,82	−26,8 %
SPY	Naive	3,46	3,75	+8,2 %
SPY	TSDiff	4,98	4,06	−18,4 %
ZN=F	ARIMA-GARCH	0,191	0,177	−7,3 %
ZN=F	SARIMA	0,185	0,180	−2,5 %
ZN=F	Prophet	0,432	0,995	+130,5 %
ZN=F	LSTM	0,337	0,323	−4,2 %
ZN=F	Naive	0,184	0,227	+23,7 %
ZN=F	TSDiff	0,260	0,216	−17,0 %
TLT	ARIMA-GARCH	0,291	0,288	−0,9 %
TLT	SARIMA	0,303	0,302	−0,4 %
TLT	Prophet	0,633	1,658	+161,9 %
TLT	LSTM	0,572	0,600	+4,8 %
TLT	Naive	0,303	0,341	+12,7 %
TLT	TSDiff	0,439	0,362	−17,4 %

Lecture : pour ARIMA-GARCH et SARIMA, les deux mesures sont quasiment collées sur les actifs calmes (SPY/ZN=F/TLT, écart $< 8\%$) et s'écartent un peu plus sur BTC/ETH (13 à 19 %) — cohérent avec la fenêtre légèrement différente évoquée en §2, plutôt qu'avec un vrai désaccord de métrique, puisque leur “empirique” est un tirage Monte Carlo de la même distribution que le gaussien. **Prophet diverge fortement partout** (+44 à +162 %) : l'empirique révèle un modèle encore pire que ce que suggère déjà le gaussien catastrophique. **TSDiff est le seul modèle à changer de signe selon l'actif** (+24/+28 % sur BTC/ETH, mais −17 à −18 % sur SPY/ZN=F/TLT) : c'est la signature attendue d'une vraie distribution non gaussienne (asymétrique/à queues différentes selon le régime de l'actif), puisque son empirique n'est pas une simple ré-estimation Monte Carlo du même gaussien —

contrairement aux 4 autres modèles paramétriques.

3 Est-ce que le classement change ?

Rang moyen sur les 5 actifs (1 = meilleur CRPS), D+1 :

Modèle	Rang moyen (gaussien)	Rang moyen (empirique)
ARIMA-GARCH	2,2	1,2
SARIMA	2,4	1,8
Naive	1,8	3,2
TSDiff	3,6	3,8
LSTM	5,0	5,0
Prophet	6,0	6,0

Le gros du classement est robuste au choix de métrique : Prophet dernier et LSTM avant-dernier sur les 5 actifs, dans les deux cas ; TSDiff stable en milieu de tableau (3,6 vs 3,8). Ce qui bouge : à l'intérieur du trio de tête, le CRPS gaussien place Naive en tête (1,8) devant ARIMA-GARCH (2,2), alors que l'empirique inverse ce podium (ARIMA-GARCH 1,2, Naive recule à 3,2). Concrètement : **ne pas conclure “Naive bat ARIMA-GARCH” ou l'inverse à partir d'une seule des deux mesures** — l'écart entre les deux est plus petit que le bruit induit par le choix de métrique/fenêtre.

4 Et à W+1 ?

Le CRPS gaussien du dashboard n'existe qu'à D+1 pour les 5 modèles classiques (aucune section hebdomadaire les concernant) — la comparaison gaussien/empirique n'est donc possible qu'à D+1. À W+1 (TSDiff resté sur son entraînement quotidien, poussé à l'horizon semaine, cf. `experiments/kpi_probabilistes.json`) seul le CRPS empirique est disponible pour les 6 modèles :

Actif	ARIMA-G.	SARIMA	Naive	TSDiff	Prophet / LSTM
BTC-USD	2577,8	2337,8	2346,8	2765,2	31548 / 6513
ETH-USD	102,5	106,7	103,1	121,8	627 / 188
SPY	6,95	7,31	7,21	7,74	14,2 / 17,5
ZN=F	0,371	0,378	0,372	0,414	0,90 / 0,59
TLT	0,606	0,677	0,685	0,654	1,29 / 1,10

Rang moyen W+1 (empirique, 5 actifs) : ARIMA-GARCH 1,4 — Naive 2,4 — SARIMA 2,6 — TSDiff 3,6 — LSTM 5,2 — Prophet 5,8. Même ossature qu'à D+1 : TSDiff toujours 4e sur 6, ni pire ni meilleur relativement aux autres qu'au jour le jour — rien n'indique qu'il serait “mieux à W+1”, il se contente de rester dans la même position relative pendant que tout le monde se dégrade en valeur absolue avec l'horizon.

5 Lequel des deux est le plus parlant pour comparer les modèles ?

Pour les 5 modèles classiques entre eux : peu importe — gaussien et empirique mesurent, par construction, la même distribution (le second est un tirage Monte Carlo du premier). Le gaussien est même préférable ici : exact, sans bruit d'échantillonnage, moins cher à calculer.

Dès que TSDiff entre dans la comparaison : le CRPS empirique est la seule mesure qui a du sens. Le gaussien collapse le nuage réel de TSDiff en une gaussienne symétrique — une perte

d’information que les 5 autres modèles n’ont pas, puisque l’hypothèse gaussienne est déjà tout ce qu’ils sont. Comparer “CRPS gaussien de ARIMA-GARCH” à “CRPS gaussien de TSDiff” revient à comparer TSDiff à sa propre version appauvrie, pas à sa vraie prévision. Les écarts de signe observés en §3 (TSDiff au-dessus du gaussien sur BTC/ETH, en-dessous sur SPY/ZN=F/TLT) le confirment : sa vraie distribution n’est symétrique nulle part de façon stable.

Recommandation : utiliser le CRPS empirique comme métrique de référence pour toute comparaison incluant TSDiff (c’est déjà l’approche de `experiments/kpi_probabilistes.json`) — il ne change presque rien aux conclusions pour les 5 modèles classiques (cf. §3–4, robustes), mais c’est la seule version qui traite TSDiff sans le désavantager par construction. Garder le CRPS gaussien en complément uniquement pour sa lecture rapide/exacte des 5 modèles paramétriques entre eux, jamais pour statuer sur TSDiff seul ou face aux autres.

6 Pourquoi TSDiff est-il globalement pire qu’ARIMA/SARIMA, et surtout que Naive ?

Les colonnes `y_pred/last_close/y_true` de `experiments/kpi_probabilistes.json` (D+1, tous modèles) permettent de mesurer le mécanisme directement plutôt que de le supposer.

Actif	mvt réel moy.	pari Naive	pari ARIMA-G.	pari SARIMA	pari TSDiff	dir.acc TSDiff
BTC-USD	1,84 %	0,035 %	0,155 %	0,104 %	0,535 %	54,8 %
ETH-USD	2,45 %	0,042 %	0,073 %	0,092 %	0,765 %	53,7 %
SPY	0,69 %	0,069 %	0,115 %	0,082 %	0,558 %	52,1 %
ZN=F	0,22 %	0,066 %	0,015 %	0,016 %	0,145 %	49,2 %
TLT	0,46 %	0,084 %	0,022 %	0,042 %	0,351 %	50,4 %

Table 2: “pari” = mouvement moyen absolu prédit par rapport au dernier prix connu, en %. “dir.acc” = part des jours où le signe du mouvement prédit par TSDiff correspond au signe du mouvement réel.

Le mécanisme. Naive, ARIMA-GARCH et SARIMA parient quasiment 0 % de mouvement à chaque origine — ils prédisent essentiellement “demain = aujourd’hui”. Sur un rendement journalier d’actif financier, c’est un pari redoutablement dur à battre : à cet horizon, le rendement conditionnel attendu est très proche de zéro (marché quasi-efficent, comportement proche d’une marche aléatoire), donc “ne rien parier” est déjà proche de l’optimal pour le point prédit. Leur seul vrai travail consiste à bien calibrer la largeur de l’intervalle (le GARCH pour ARIMA-GARCH) — pas à deviner la direction.

TSDiff, lui, parie un vrai mouvement (3 à 15 fois plus gros que Naive selon l’actif). Pour que ce pari paie sur le CRPS, il faudrait une compétence directionnelle nette. Or son taux de bonne direction tourne à 49–55 % — à peine au-dessus du pile-ou-face, sur un échantillon de ~120–180 origines : quasi certainement non significatif statistiquement. Concrètement, environ une fois sur deux, TSDiff décale sa distribution dans le mauvais sens, sans que l’autre moitié des cas compense suffisamment — alors que Naive/ARIMA-GARCH, en restant centrés sur zéro, ne subissent jamais ce risque directionnel.

Pourquoi ça dépend de l’actif. Sur BTC/ETH, le vrai mouvement quotidien est énorme (1,8–2,5 %) — assez grand pour qu’un pari modeste de TSDiff (0,54–0,77 %) ait une vraie chance de tomber juste, ce qui explique qu’il colle voire dépasse ARIMA-GARCH sur ETH (§3). Sur SPY/ZN=F/TLT, le vrai mouvement quotidien est minuscule (0,22–0,69 %) — dans ce régime, tout pari non nul coûte plus qu’il ne rapporte, ce qui explique que TSDiff y décroche le plus nettement de Naive/ARIMA-GARCH/SARIMA.

Sur la couverture. Restreint au D+1 pur, la couverture à 95 % de TSDiff mesurée ici est quasi totale (99–100 %), ce qui suggère plutôt un intervalle trop large aux extrêmes sur cet échantillon précis — à l’inverse de la sous-couverture à 95 % observée dans l’analyse poolée plus large discutée précédem-

ment ($\sim 81\%$ observé). Les deux mesures ne portent pas exactement sur les mêmes fenêtres ni les mêmes regroupements de conditions (horizons/régimes) — point non réconcilié ici, à creuser plutôt qu’à trancher.

Facteur annexe. TSDiff n’a pas de checkpoint sauvegardé et est ré-entraîné à chaque run (contrairement à ARIMA/SARIMA, qui se refittent de façon déterministe et bon marché) — cela ajoute du bruit d’un run à l’autre, qui peut expliquer une partie de la variance observée, mais n’est pas le moteur principal du phénomène.

En résumé : ce n’est pas un problème de “diffusion moins bonne qu’ARIMA”. Battre la persistance à $D+1$ demande un edge directionnel réel, et TSDiff n’en a pas encore démontré un suffisamment net sur cet échantillon — ses paris sont réels mais pas (encore) rentables à cet horizon, sur ces actifs.

Limites

- Fenêtres de backtest légèrement différentes entre le dashboard ($D+1$, $n=113-165$) et `kpi_probabilistes.json` ($D+1$, $n=117-178$) — les écarts du §3 mêlent effet de métrique et effet de fenêtre, non séparés ici.
- Pour les 5 modèles classiques, le CRPS empirique n’est pas un test indépendant de l’hypothèse gaussienne : il en est un tirage Monte Carlo, donc il ne peut pas *invalidier* cette hypothèse, seulement l’estimer avec du bruit d’échantillonnage en plus. Une vraie validation de la forme gaussienne demanderait de comparer aux résidus réels (approche déjà abordée dans `optimisation_modeles_ia.pdf`, §4).
- $N=500$ tirages par origine : suffisant pour un CRPS stable à quelques % près, mais pas pour les quantiles extrêmes (au-delà de 99%).
- Le taux de bonne direction de TSDiff (49–55 %) n’a pas été testé statistiquement ici (pas de test formel vs 50 %, type IC de Wilson) — à faire avant de conclure définitivement à une absence d’edge (cf. `honest_eval.directional_accuracy`).