

DEITA — Glossaire du Benchmark

Terminologie unifiée : signal, metriques, modeles, methodologie

Document de reference interne — Juin 2026

Ce glossaire definit de facon univoque les termes utilises dans le benchmark DEITA. Chaque entree donne la definition formelle, puis une note de contextualisation specifique a DEITA. Les termes sont regroupees par domaine, non alphabetiquement, pour faciliter la comprehension des enchainements logiques.

Contents

1	Signal et donnees	3
1.1	Signal	3
1.2	Log-return	3
1.3	Stationnarisation	3
1.4	Normalisation (mise a l'echelle)	3
1.5	RevIN (Reversible Instance Normalization)	3
1.6	Distribution shift	4
1.7	Data leakage	4
2	Metriques d'evaluation	4
2.1	Reference absolue	4
2.2	Reference relative (MASE)	4
2.3	RMSSE	5
2.4	Skill Score	5
2.5	Coverage PI	5
2.6	Winkler (Interval Score)	5
2.7	WIS (Weighted Interval Score)	6
2.8	CRPS (Continuous Ranked Probability Score)	6
3	Modele naif et references	7
3.1	Modele naif (option A — derive bornee)	7
3.2	Modele naif (option B — random walk)	8
3.3	Plausibilite	8
4	Methodologie du benchmark	8
4.1	Walk-forward (expanding window)	8
4.2	Test de Diebold-Mariano (DM)	8
4.3	MCS (Model Confidence Set)	8
4.4	Agregation des PI (intervalles de prediction)	9
4.5	EnCQR (Ensemble Conformalized Quantile Regression)	9
5	Architecture DEITA	9
5.1	Regime de marche	9
5.2	Profilier	9
5.3	Superviseur	10
5.4	Evaluateur	10
5.5	Famille d'actif	10
5.6	Horizon de prediction	10

Signal

Variable que le modele tente de predire ou d'expliquer. Ce n'est pas necessairement la serie brute : c'est le resultat d'un choix de representation (prix, return, log-return, volatilité...) qui determine les proprietes statistiques exploitees par les modeles.

Note DEITA : DEITA travaille principalement sur les **log-returns** $r_t = \ln(P_t/P_{t-1})$ car ils sont approximativement stationnaires, additifs dans le temps, et independants de l'echelle absolue des prix. Sur certains horizons S, la **volatilite realisee** peut etre utilisee comme signal secondaire pour le Profiler.

Log-return

Transformation logarithmique du ratio de prix consecutifs :

$$r_t = \ln(P_t / P_{t-1})$$

Proprietes principales : approximativement stationnaire, additif sur plusieurs periodes ($r_{t,t+k} = \sum_{i=1}^k r_{t+i-1}$), et invariant par changement d'echelle de prix.

Note DEITA : Sur crypto, les log-returns restent leptokurtiques (kurtosis 3–5) malgre la transformation. Sur matieres premieres (kurtosis 25–32), les queues epaisses subsistent. La normalisation Z-score ou RevIN doit etre appliquee *apres* le log-return, pas a la place.

Stationnarisation

Transformation visant a rendre les proprietes statistiques d'une serie (moyenne, variance, autocorrelation) constantes dans le temps. Teste par ADF, KPSS et Phillips-Perron. Objectif distinct de la normalisation (mise a l'echelle).

Note DEITA : ARIMA et SARIMA supposent la stationnarisation. Le passage en log-return est la principale stationnarisation dans DEITA. Si ADF rejette encore la stationnarite apres log-return (rare), une difference supplementaire est appliquee avant d'entrer dans le modele.

Normalisation (mise a l'echelle)

Transformation des donnees pour homogeneiser les magnitudes des features, independamment de la stationnarisation. Deux methodes principales :

- **Z-score** : $z_t = (x_t - \mu_{\text{train}}) / \sigma_{\text{train}}$ — centre et reduit
- **Min-Max** : $z_t = (x_t - x_{\min}) / (x_{\max} - x_{\min})$ — borne dans $[0, 1]$

Regle absolue : $\mu, \sigma, x_{\min}, x_{\max}$ sont calcules *uniquement sur le train*. Les appliquer au test serait une fuite de donnees (data leakage).

Note DEITA : En walk-forward, chaque pas de prediction recalcule ses propres parametres de normalisation sur sa propre fenetre de train. Le Z-score est prefere sur crypto (pas de borne naturelle, queues epaisses). Min-Max est deconseille sur crypto : tres sensible aux outliers de prix.

RevIN (Reversible Instance Normalization)

Methode de normalisation adaptative proposee par Kim et al. (ICLR 2022). Normalise

chaque *instance* (fenetre de contexte individuelle) par sa propre moyenne et variance :

$$\tilde{x}_t = \frac{x_t - \mu_{\text{instance}}}{\sigma_{\text{instance}}}$$

puis **denormalise la sortie du modele** avant de calculer la perte. Avantage : absorbe le *distribution shift* sans hypothese de stationnarite globale.

Note DEITA : RevIN est particulierement utile pour PatchTST, NBEATS et les modeles Diffusion, qui voient des fenetres de contexte individuelles plutot que des statistiques globales. Elle est implementee comme couche d'entree/sortie, pas comme un pre-traitement externe — les parametres de normalisation sont internes a l'instance.

Distribution shift

Changement des proprietes statistiques (moyenne, variance, distribution) entre la periode d'entrainement et la periode d'inference. Probleme central en finance : les regimes de marche changent, rendant les statistiques apprises partiellement caduques.

Note DEITA : Le Profiler (TimesNet) dans DEITA detecte les changements de regime (Bull/Bear/lateral) pour signaler au Superviseur qu'un distribution shift est en cours. RevIN limite l'impact du shift sur les modeles DL ; EnCQR recalibre les intervalles de prediction en consequence.

Data leakage

Situation ou des informations du jeu de test (ou de la periode future) contaminent l'entrainement ou la normalisation, produisant des performances artificiellement optimistes qui ne se generalisent pas en production.

Note DEITA : Dans DEITA, les risques principaux sont : (1) normaliser sur l'ensemble train+test au lieu du train seul ; (2) entrainer un meta-modele (Superviseur) sur des predictions generees avec fuite temporelle ; (3) utiliser le regime futur comme feature. Le walk-forward expanding window est la principale protection contre le leakage data.

Metriques d'evaluation

Reference absolue

Metrique calculee sans normalisation par un baseline. Exemples : RMSE, MAE, largeur brute des PI. Utilisable pour comparer des modeles *sur le meme actif et le meme horizon*, mais incomparable entre actifs d'echelles differentes.

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2}$$

Note DEITA : Dans DEITA, les references absolues servent a diagnostiquer un modele sur un actif donne (ex. Prophet RMSE 42\$ sur BTC/USD) mais ne sont jamais utilisees pour classer les modeles inter-actifs.

Reference relative (MASE)

Mean Absolute Scaled Error (Hyndman & Koehler, 2006) : erreur absolue du modele

normalisee par l'erreur absolue du modele naif :

$$\text{MASE} = \frac{\text{MAE}_{\text{modele}}}{\text{MAE}_{\text{naif}}}$$

Interpretation : $\text{MASE} < 1$ signifie que le modele bat le naif. Metrique sans dimension, comparable entre actifs d'echelles differentes.

Note DEITA : MASE est la metrique principale de comparaison inter-actifs et inter-horizons dans DEITA. Elle permet de dire qu'un $\text{MASE} = 0.82$ sur BTC et sur un ETF signifient exactement la meme chose : 18% de gain sur le naif.

RMSSE

Root Mean Squared Scaled Error : analogue quadratique du MASE.

$$\text{RMSSE} = \frac{\text{RMSE}_{\text{modele}}}{\text{RMSE}_{\text{naif}}}$$

Penalise davantage les grandes erreurs que le MASE. Utilise comme metrique secondaire lorsque les erreurs extremes sont importantes (crypto en bear market).

Note DEITA : Dans le benchmark DEITA, le classement principal utilise MASE ; RMSSE sert de critere de tie-breaking et de signal d'alerte (modele avec MASE acceptable mais $\text{RMSSE} > 2$ = erreurs rares mais tres grandes).

Skill Score

Gain relatif sur le naif, exprime en pourcentage :

$$\text{Skill} = \left(1 - \frac{\text{RMSE}_{\text{modele}}}{\text{RMSE}_{\text{naif}}}\right) \times 100\%$$

$\text{Skill} > 0$ signifie que le modele ameliore le naif. $\text{Skill} < 0$ signifie qu'il est moins bon. Equivalent signe du RMSSE.

Note DEITA : Utile pour les rapports DEITA car intuitif : « Modele X apporte +15% sur le naif sur horizon J, famille Crypto ».

Coverage PI

Proportion des valeurs reelles dans l'intervalle de prediction $[L_t, U_t]$:

$$\text{Coverage} = \frac{1}{T} \sum_{t=1}^T \mathbf{1}[L_t \leq y_t \leq U_t]$$

Cible theorique : $1 - \alpha$ (typiquement 95%). Un Coverage trop bas ($< 80\%$) indique des intervalles trop etroits (sous-estimation de l'incertitude). Un Coverage trop haut ($> 99\%$) indique des intervalles trop larges (inutiles).

Note DEITA : Dans Benchmark 1.6, le Coverage de Prophet sur crypto est de 3.9% (cible 95%) : les intervalles gaussiens ne capturent pas les queues epaisses. EnCQR au Niveau 3 recalibre pour atteindre la cible.

Winkler (Interval Score)

Score de Winkler (Winkler, 1972), formalise comme regle de score strictement propre par

Gneiting & Raftery (2007, eq. 43). Pour un intervalle de prediction $[L_t, U_t]$ au niveau $1 - \alpha$:

$$\text{Winkler}_\alpha = (U_t - L_t) + \frac{2}{\alpha}(L_t - y_t)\mathbf{1}[y_t < L_t] + \frac{2}{\alpha}(y_t - U_t)\mathbf{1}[y_t > U_t]$$

Un intervalle qui contient la vraie valeur est score par sa seule largeur (recompense la precision/etroitesse) ; un intervalle qui la rate est penalise proportionnellement a la distance de sortie, et inversement a α — une sortie de l'IC95% coute $40\times$ la distance de depassement, contre $4\times$ a l'IC50%. Plus bas = meilleur.

Note DEITA : Cette formule est identique, terme a terme, a celle du WIS defini juste apres — le WIS de DEITA, calcule a un seul α , **est** un score de Winkler, pas une coincidence de notation. Dans le code (`honest_eval/metrics.py::winkler_score`, `winkler`, utilise par `experiments/dashboard_d7_w1.html`), « Winkler » designe cette version a un seul niveau (calculee separement a 50/80/95%, puis moyennee par cellule) — par opposition a un WIS multi-niveaux pondere (facon COVID Forecast Hub) que DEITA n'implemente pas.

Utilise dans `dashboard_d7_w1.html` precisement quand la base ne stocke que $(\hat{y}_t, L_t, U_t, y_t)$ — pas de nuage d'echantillons pour un vrai CRPS ; citation du footer du dashboard : « le Winkler est la metrique probabiliste honnete ici, pas un CRPS maquille ». Exemple reel (ARIMA-GARCH, BTC-USD, horizon D+7) : RMSE = 4419,63 \$, Winkler = 30001,45, Cov95 = 88,9%, largeur PI = 15239,43 \$ — la couverture est legerement sous la cible, donc une partie du score vient des penalites de depassement, pas seulement de la largeur. Sur une origine bien couverte (SPY, ARIMA-GARCH, D+1, $y_t=685,59$ \$ dans $[674, 25 ; 700, 18]$), Winkler95 se reduit a la largeur seule $\approx 25,71$ \$. Piegé : comme le RMSE, le Winkler n'est pas sans dimension — jamais compare en absolu entre actifs ; DEITA ne poole que des skills ($1 - \text{score_modele} / \text{score_naif}$).

WIS (Weighted Interval Score)

Score de Gneiting & Raftery (2007) combinant Coverage et largeur de PI en un seul scalaire proprement scorant :

$$\text{WIS}_\alpha = (U_t - L_t) + \frac{2}{\alpha}(L_t - y_t)\mathbf{1}[y_t < L_t] + \frac{2}{\alpha}(y_t - U_t)\mathbf{1}[y_t > U_t]$$

Un PI large mais bien calibre penalise moins qu'un PI etroit mal calibre.

Note DEITA : Le **WIS relatif** (WIS modele / WIS naif) est la metrique de comparaison probabiliste principale dans DEITA, au meme titre que MASE pour la prediction ponctuelle.

CRPS (Continuous Ranked Probability Score)

Regle de scoring strictement propre pour les distributions predictives completes (Gneiting & Raftery 2007). Generalise le MAE au cas probabiliste :

$$\text{CRPS}(F, y) = \int_{-\infty}^{+\infty} (F(z) - \mathbf{1}[z \geq y])^2 dz$$

ou F est la CDF predictive. Forme empirique effectivement executee par le pipeline DEITA (`experiments/crps_metrics.py::crps_empirical`, kernel/energy score) sur un nuage de N echantillons $\{x_1, \dots, x_N\}$:

$$\text{CRPS}_{\text{emp}} = \frac{1}{N} \sum_i |x_i - y| - \frac{1}{2N^2} \sum_i \sum_j |x_i - x_j|$$

Terme 1 : distance moyenne des echantillons a la realisation (precision). Terme 2 : dispersion

moyenne des échantillons entre eux (penalise un nuage inutilement large). Se réduit au MAE si tous les x_i sont égaux (modèle déterministe). Plus bas = meilleur.

Note DEITA : Deux façons de produire le nuage de $N=500$ échantillons dans DEITA (`experiments/prob_kpi_common.py`), toutes deux sans fuite temporelle :

(1) Paramétrique (ARIMA-GARCH, SARIMA, Prophet, Naive, LSTM) : `tracking.db` ne stocke que $(\hat{y}_t, L_t, U_t)$, jamais le nuage brut, et aucun de ces modèles n'a de checkpoint rejouable à chaque origine historique. Le σ implicite est retrouvé depuis le PI95% stocké ($z = 1,959963985$, valeur exacte, pas 1,96 arrondi), puis 500 tirages sont générés depuis la loi reconstruite : lognormale en espace log-return pour ARIMA-GARCH, gaussienne en espace prix pour les 4 autres. Ce CRPS teste surtout si la loi *assumée* est correcte, pas la vraie forme apprise par le modèle.

(2) Native (TSDiff — modèle Diffusion) : pas de checkpoint persistant non plus, mais au lieu de reconstruire une loi paramétrique, le pipeline rejoue le walk-forward (`seed=42`, mêmes données, même époque déjà sélectionnée par actif) et conserve le nuage brut des 500 échantillons que le modèle génère nativement, sans le réduire à une moyenne/quantiles. Ce CRPS porte sur la vraie forme apprise (potentiellement multimodale, queues asymétriques), pas une approximation.

Les deux utilisent la même formule finale et sont donc comparables en valeur, pas en interprétation. Exemple réel (BTC-USD, D+1, 177 origines) : ARIMA-GARCH CRPS moyen = 955,97 \$ (Cov95=93,8%, Winkler95=10779,11, MASE=0,993) contre TSDiff CRPS moyen = 1056,02 \$ (Cov95=99,4%, Winkler95=13597,64, MASE=1,051) — ARIMA-GARCH bat légèrement TSDiff en CRPS malgré une loi assumée simple, tandis que TSDiff sur-couvre nettement : ses intervalles trop larges gonflent son Winkler sans améliorer son CRPS. Un CRPS proche entre deux modèles n'implique donc pas la même qualité de calibration — toujours le lire avec Coverage/Winkler en regard.

Piège : `Run/distributions_dashboard.html` recalcule, à but illustratif, un CRPS gaussien vs Student-t(ν réglable) en forme fermée (pas de nuage d'échantillons), reconstruit directement en espace prix pour tous les modèles y compris ARIMA-GARCH (dont la vraie loi est lognormale en rendement) — simplification volontaire, assumée par la page elle-même (« approximation assumée »). Ce n'est pas la source de vérité du CRPS : c'est `prob_kpi_common.py` → `kpi_probabilistes.json` (traitement ci-dessus) qui fait foi. Les deux portent le même nom « CRPS » mais ne mesurent pas la même chose : loi assumée à IC95% fixe, vs nuage réel ou rejoue.

Modèle naïf et références

Modèle naïf (option A — dérive bornée)

Prediction déterministe avec dérive bornée :

$$\hat{y}_{t+1} = y_t + \text{clip}(\delta, -5\% \cdot y_t, +5\% \cdot y_t)$$

ou δ est la dérive moyenne empirique sur le train. Modèle de base pour le calcul des métriques relatives (MASE, RMSSE, Skill Score).

Note DEITA : C'est le naïf principal de DEITA : simple, déterministe, sans paramètre appris. Il sert de dénominateur à toutes les métriques relatives. Un modèle qui ne bat pas ce naïf est exclu de l'agréation (condition du Superviseur : $\text{RMSE} > 1.5 \times \text{RMSE naïf}$).

Modele naif (option B — random walk)

Prediction stochastique : $\hat{y}_{t+1} = y_t \times (1 + \varepsilon)$, $\varepsilon \sim \mathcal{U}[-5\%, +5\%]$. Test de la question : « les modeles font-ils mieux qu'une perturbation purement aleatoire ? »

Note DEITA : L'option B est le **test du singe** : si un modele complexe ne bat pas systematiquement un random walk dans $[-5\%, +5\%]$, son apport informationnel est nul. Utilise en complement de l'option A pour valider que la surperformance n'est pas due au hasard.

Plausibilite

Verification de coherence qu'un modele produit des predictions et des intervalles physiquement et statistiquement sensees, *avant* de l'inclure dans l'agregation. Trois niveaux :

- **Physique** : $\hat{y}_t < 0$ pour un prix — disqualifiant
- **Statistique** : $L_t > U_t$ (PI inverse), $L_t = U_t$ (PI degenerate), $U_t - L_t > 10\bar{P}$ (PI absurde)
- **Comparative** : $\text{RMSE} > 2 \times \text{RMSE naif}$ sur 20 derniers pas — audit requis avant agregation

Note DEITA : La plausibilite est un pre-filtre au niveau du benchmark (avant l'agregation) et un critere d'exclusion dynamique au Niveau 2 (Superviseur). Elle est distincte de la performance : un modele peut avoir un bon MASE moyen mais echouer occasionnellement au test de plausibilite lors de chocs de marche.

Methodologie du benchmark

Walk-forward (expanding window)

Protocole d'evaluation sequentiel : la fenetre d'entrainement s'elargit d'un pas a chaque iteration, et le test est toujours le pas suivant. Aucune donnee future n'est utilisee pour l'entrainement.

$$\text{Iteration } k : \quad \text{Train} = [1, k], \quad \text{Test} = k + 1$$

Note DEITA : Protocole obligatoire dans DEITA. L'alternative (train/test fixe) introduit du leakage temporel et produit des metriques irrealistes en production. Les parametres de normalisation sont recalculés a chaque iteration k .

Test de Diebold-Mariano (DM)

Test statistique de comparaison de deux series d'erreurs de prevision (Diebold & Mariano, 1995). Teste H_0 : les deux modeles ont la meme esperance d'erreur. La statistique utilise une variance HAC (Newey-West, truncation $\lfloor T^{1/3} \rfloor$) pour tenir compte de l'autocorrelation des erreurs.

Note DEITA : Utilise dans DEITA pour comparer exactement 2 modeles. Pour $N > 2$ modeles, le DM pairwise genere $N(N-1)/2 = 78$ tests pour 13 modeles, d'ou inflation du risque α — utiliser le MCS a la place.

MCS (Model Confidence Set)

Procedure de Hansen, Lunde & Nason (2011) pour selectionner l'ensemble de modeles statistiquement indistinguables du meilleur, a un niveau de confiance $1 - \alpha$. Controle le risque de faux positifs pour $N > 2$ modeles simultanes.

Note DEITA : Methode recommandee pour la comparaison finale des 13 modeles DEITA. Le MCS retourne un sous-ensemble de modeles (souvent 3–5) qui ne sont pas significativement differents du champion. Ces modeles constituent la coalition a agreguer au Niveau 1.

Agregation des PI (intervalles de prediction)

Combinaison des intervalles $[L_t^{(i)}, U_t^{(i)}]$ produits par N modeles en un unique PI final. Trois strategies :

- **Union :** $[\min_i L_t^{(i)}, \max_i U_t^{(i)}]$ — conservateur, couverture $\geq 1 - \alpha$
- **Intersection :** $[\max_i L_t^{(i)}, \min_i U_t^{(i)}]$ — agressif, peut etre vide
- **Ponderee :** moyenne ponderee des bornes — recommandee, mais n’assure que $1 - 2\alpha$ dans le pire cas

Dans tous les cas, une **recalibration conforme** (EnCQR) est necessaire apres l’agregation pour garantir le niveau de couverture cible.

Note DEITA : Dans DEITA, l’agregation des PI est toujours suivie du Niveau 3 (EnCQR). Ne jamais servir un PI agrege sans recalibration : meme l’union ne garantit pas $1 - \alpha$ sur des series heterogenes.

EnCQR (Ensemble Conformalized Quantile Regression)

Methode de calibration conforme (IEEE 2022) qui garantit le Coverage a $1 - \alpha$ sans hypothese distributionnelle :

$$q_{1-\alpha} = \text{Quantile}_{1-\alpha}(\{|y_i - \hat{y}_i| : i \in \mathcal{D}_{\text{cal}}\}), \quad [L_t, U_t] = [\hat{y}_t - q, \hat{y}_t + q]$$

Propriete PAC (*probably approximately correct*) : la couverture est garantie en expectation sur les donnees de calibration.

Note DEITA : Niveau 3 de l’architecture DEITA. Toujours actif, quel que soit le regime. Il corrige les PI des modeles statistiques (qui supposent la gaussianite) et des modeles DL (qui peuvent etre mal calibres sur des horizons longs).

Architecture DEITA

Regime de marche

Phase caracterisee par des proprietes statistiques coherentes sur une fenetre temporelle. Les trois regimes principaux :

- **Bull :** tendance haussiere, faible volatilite relative, AC1 positif
- **Bear :** tendance baissiere, forte volatilite, queues epaisses accentuees
- **Lateral :** mean-reversion, volatilite moderee, AC1 negatif ou nul

Note DEITA : Le Profiler (TimesNet) detecte le regime a chaque inference et le transmet au Superviseur comme feature. Le regime est la principale information contextuelle qui permet au Superviseur d’adapter ses poids dynamiquement sans reentrainement.

Profiler

Agent base sur TimesNet (TCN — Temporal Convolutional Network) dont le role est exclusivement le **profilage** : caracteriser l'actif et le regime de marche courant. Il ne produit pas de prediction de prix. Outputs : regime (Bull/Bear/lateral), volatilit e realisee, AC1, kurtosis roulant, famille d'actif detectee.

Note DEITA : Le Profiler est unique dans l'architecture (1 instance pour tous les actifs). Il tourne a chaque inference et ses outputs sont les features d'entree du Superviseur. C'est le seul agent qui ne produit pas de $\hat{y}$.

Superviseur

Agent XGBoost de meta-apprentissage dont le role est le **gating** inter-famille : attribuer des poids w_{fam} aux predictions des Experts selon le regime et la performance recente. Re-entraine hebdomadairement. Peut exclure une famille (poids = 0) si $\text{RMSE} > 1.5 \times \text{RMSE naif ET Coverage} < 60\%$ sur les 20 derniers pas.

Note DEITA : Coalition minimale : 3 familles actives. L'exclusion est temporaire (reintegration apres 5 pas si les metriques s'ameliorent). Le Superviseur est le seul agent avec un entraînement periodique (hebdomadaire).

Evaluateur

Agent EnCQR dont le role est la **calibration conforme** de l'intervalle de prediction final. Tourne en temps reel, sans reentrainement. Il prend la prediction centrale $\hat{y}_{\text{final}}$ du Superviseur et produit $[L_t, U_t]$ garanti a $1 - \alpha$.

Note DEITA : L'Evaluateur est le dernier element de la chaine. Il est orthogonal a l'agregation (il calibre l'incertitude, pas la prediction centrale) et fonctionne independamment du regime ou de la famille d'actif.

Famille d'actif

Groupe d'actifs partageant des proprietes statistiques similaires. Les 3 familles DEITA :

- **Crypto** : AC1 ≈ 0 , kurtosis 3–5, vol. 47–87%
- **ETFs** : AC1 $-0.03/-0.06$, kurtosis 10–18, vol. 12–22%
- **Matieres premieres** : AC1 $-0.05/-0.08$, kurtosis 25–32, vol. 18–35%

Chaque famille a ses propres experts (Niveau 1) et son propre comportement de regime.

Note DEITA : La famille est une feature du Superviseur. Elle conditionne les poids de gating par default avant que le RMSE roulant ne les ajuste dynamiquement. Un meme modele (ex. Prophet) peut  tre performant sur une famille (MP/horizon S) et disqualifie sur une autre (Crypto/horizon H).

Horizon de prediction

Fenetre temporelle cible pour la prediction. DEITA utilise 3 horizons :

- **H (intraday)** : prevision infra-journaliere (ex. +1h, +4h)
- **J (daily)** : prevision J+1 et J+2
- **S (weekly)** : prevision S+1 et S+2

L'horizon conditionne le choix du modele et la strategie d'agregation.

Note DEITA : Les modeles statistiques (ARIMA, SARIMA) sont plus competitifs sur J/S. Les modeles Diffusion apportent plus sur H (queues epaisses intraday). Le Superviseur recoit l'horizon comme feature categorielle fixe.

Tableau de correspondance rapide

Terme	Role dans le benchmark	Piege courant
Log-return	Signal principal (stationnarisation)	Confondre avec la normalisation (scaling)
Z-score / RevIN	Mise a l'echelle des features	Calculer μ, σ sur train+test
MASE / RMSSE	Metriques relatives (inter-actifs)	Utiliser RMSE absolu pour comparer BTC vs ETF
Coverage PI	Calibration de l'incertitude	Viser 100% (PI infiniment large) plutot que 95%
Winkler	Score d'intervalle single-level (sans nuage)	Comparer un Winkler brut entre actifs d'echelles differentes
WIS	Score probabiliste combine	Ignorer la largeur du PI (optimiser Coverage seul)
CRPS	Score distributional, parametrique ou natif selon le modele	Confondre le CRPS illustratif (loi fermee) avec le CRPS empirique de reference
Walk-forward	Protocole sans leakage	Re-utiliser les parametres de normalisation du premier pas
DM test	Comparaison de 2 modeles	L'appliquer a $N > 2$ modeles (inflation de α)
MCS	Comparaison de $N > 2$ modeles	Interpreter le MCS comme un classement ordonne
Plausibilite	Pre-filtre avant agregation	Skipper ce filtre sur les benchmarks rapides
EnCQR	Calibration conforme finale	Utiliser EnCQR seul sans prediction centrale

Ordre logique a respecter dans le benchmark :

Signal → Stationnarisation → Normalisation (scaling) → Modeles
→ Plausibilite → Agregation PI → EnCQR → Metriques relatives

Toute inversion de cet ordre introduit soit du leakage, soit une comparaison non equitable entre modeles heterogenes.