

KPIs alternatifs pour TSDiff

Daily vs Weekly, D+1 vs W+1 — synthèse DeepEdgeBenchmark

Etat au 21 juillet 2026 — source : `experiments/pooled_analysis.json`,
`matrice_paired_tests.json`

Synthèse de la journée — points clés par modèle

Résumé de l'ensemble des échanges du jour (taux d'utilisation, fiabilité des « vraies » prédictions, CRPS, daily vs weekly), pas seulement du contenu de ce document.

- **ARIMA-GARCH** — Le seul des 6 modèles qui passe le test de calibration (couverture $\approx 93,5\%$, écart à 95 % non significatif). Son taux d'utilisation « vrai » initial (58,8 %) était artificiellement bas à cause d'un trou de collecte (signal enregistré sur seulement 2 des 9 jours réels, contre 6/9 pour SARIMA) — une fois les données complétées sur les 5 actifs, il devient **rigoureusement identique** à SARIMA cellule par cellule. Aucun écart significatif daily/hebdo ni D+7/W+1.
- **SARIMA** — Quasi-jumeau d'ARIMA-GARCH sur le taux d'utilisation (identique sur les 5 actifs) : à D+1, les deux modèles sont des suiveurs de quasi-persistance (mouvement prédit ≈ 0), et le test business est trop grossier pour voir l'effet réel mais faible de la saisonnalité à 5 jours. Contrairement à ARIMA-GARCH, SARIMA **sous-couvre significativement** sa bande à 95 % ($-3,7$ pt) — sa largeur de PI, sans mécanisme de volatilité conditionnelle (pas de GARCH), ne s'adapte pas aux conditions de marché. Signal fragile (discordant) sur l'apport de l'entraînement natif hebdo.
- **Prophet** — Le cas le plus problématique. Son OOS quotidien reflète encore un bug connu (prévision batch au lieu de walk-forward, $+11,8\%/+21,8\%$ de biais) corrigé dans le code le 15/07 mais **jamais régénéré dans les données** (biais encore de $+10,4\%/+17\%$ mesuré aujourd'hui). Il affichait pourtant le meilleur taux d'utilisation « vrai » au tout début de la discussion (41,2 %) — un artefact de très petit échantillon, pas un signe de qualité. **Sévèrement mal calibré** (couverture 75,9 %, $-20,3$ pt, le pire avec TSDiff). Significativement meilleur en D+7 quotidien qu'en W+1 natif.
- **LSTM** — Résultats très variables par actif (71,4 % sur BTC/ETH, seulement 40 % sur SPY/TLT), expliqués mécaniquement : son intervalle ($\text{pred} \pm 1,96 \times \text{écart-type fixe}$ des résidus d'entraînement, jamais réactif comme un GARCH) est démesurément large sur BTC/ETH (24 à 33 %, presque tout y « rentre » automatiquement) et plus resserré sur SPY/TLT, où ses paris directionnels échouent souvent. C'est le **seul modèle avec un écart net et significatif** daily vs hebdo (daily $\rightarrow$ hebdo nettement meilleur) et en D+7 vs W+1 (D+7 nettement meilleur) — probablement parce que sa fenêtre fixe de 30 pas capture un historique très différent selon qu'il représente 30 jours ou 30 semaines. Légèrement mais significativement mal calibré ($-2,6$ pt).
- **TSDiff** — Sa moins bonne performance ne vient pas d'une bande systématiquement plus large ou plus étroite (elle est en fait *plus étroite* que ARIMA/SARIMA sur crypto, *plus large* sur

actions/obligations). La vraie cause : c’est le seul modèle qui fait un vrai pari directionnel (mouvement prédit 0,3 à 0,85 %) plutôt que de recopier le dernier prix, ce qui le prive du gain « gratuit » du signal Sideways que les autres empochent presque automatiquement. Sous-couverture **sévère et significative** (80,9 %, -14,6 pt) — cohérent avec le fait qu’un modèle de diffusion mal calibré sera justement pénalisé par un CRPS, ce que le RMSE seul ne révèle jamais. Tendance non confirmée ($p \approx 0,055$) à mieux se calibrer en entraînement natif hebdo — non testable directement à D+1/W+1 avec le KPI business actuel (restreint à D+1). Profil « tout ou rien » : leader 5 fois sur 15 en hebdo natif, mais significativement battu 4 fois.

- **Naive** — Sert de référence. Strictement indifférent entre daily et hebdo (différentiel exactement nul par construction) et entre D+7/W+1. Légèrement mais significativement mal calibré lui aussi (-2,9 pt) — même une bande gaussienne simple $\sigma\sqrt{h}$ ne couvre pas exactement 95 % sur cet échantillon.
- **Point transversal** — le CRPS (empirique pour TSDiff, gaussien normalisé pour comparer les 6) est une extension pertinente et déjà largement implémentée dans le repo ; et toute lecture du taux d’utilisation « vraies prédictions » doit garder en tête la taille d’échantillon très réduite (souvent une dizaine de jours par couple modèle-actif) et les trous de collecte historiques, qui pèsent plus lourd que de vraies différences de modèle sur plusieurs des écarts observés aujourd’hui.

Légende du code couleur

 Validé — pas de différence/miscalibration exploitable statistiquement.  À confirmer — signal fragile, discordant entre tests, ou proche du seuil.  Invalidé — différence ou défaut de calibration statistiquement significatif.

1 Le RMSE peut-il être remplacé par le CRPS pour TSDiff ? Mon avis

Oui, et c’est en grande partie déjà implémenté dans le repo. Le RMSE compare un point unique à une valeur réalisée : il ignore totalement l’incertitude, alors que TSDiff ne produit pas un point mais un nuage d’échantillons (`sample_paths`). Le comparer aux autres modèles sur RMSE seul revient à ne juger qu’une moyenne de son nuage, en jetant l’information distributionnelle qui fait tout l’intérêt d’un modèle de diffusion. Le CRPS est une règle de score propre (*proper scoring rule*) qui capture à la fois la précision ponctuelle et la qualité de l’incertitude : c’est la bonne direction.

Deux implémentations coexistent déjà dans ton repo, et c’est important de ne pas les confondre :

- **CRPS empirique** (`experiments/crps_metrics.py`, estimateur de Gneiting & Raftery 2007) — calculé directement sur le nuage d’échantillons brut de TSDiff, sans hypothèse de distribution. C’est la version *exacte*, mais elle suppose de disposer du nuage complet — aujourd’hui seulement TSDiff en produit un (utilisé pour comparer TSDiff-W à TSDiff-D entre eux).
- **CRPS gaussien** (`honest_eval.metrics.crps_gaussian`) — forme fermée qui suppose une loi $\mathcal{N}(\mu, \sigma)$, avec σ déduit de la bande PI 95 % ($\sigma = (y_{upper} - y_{lower}) / (2 \times 1,96)$). C’est ce qui est utilisé dans `experiments/pooled_analysis.py` pour comparer les 6 modèles entre eux, car ARIMA/SARIMA/Prophet/LSTM/Naive ne renvoient qu’un point + IC95, jamais un nuage.

Deux réserves à garder en tête si tu généralises ce remplacement :

1. **Remplacer RMSE par CRPS ne résout pas, à lui seul, la comparabilité inter-actifs.** Un CRPS en unités de prix brutes n'est pas plus comparable entre BTC ($\sim 60\,000\ \$$) et ZN=F ($\sim 110\ \$$) qu'un RMSE brut. Le repo le fait déjà correctement : il normalise *à la fois* l'erreur ponctuelle (MASE, division par l'échelle propre à chaque actif, convention Hyndman & Koehler) *et* le CRPS (division par la même échelle) — les deux métriques ci-dessous sont donc les versions normalisées, pas les versions brutes.
2. **Le CRPS gaussien appliqué à TSDiff écrase sa vraie distribution (potentiellement asymétrique) en une gaussienne symétrique.** C'est un compromis d'ingénierie raisonnable — le seul qui permette de comparer les 6 modèles sur un pied d'égalité aujourd'hui — mais ce n'est pas le CRPS empirique complet. Pour un face-à-face TSDiff-W vs TSDiff-D (même modèle, deux variantes), je recommande de garder le CRPS empirique (le vrai), qui existe déjà pour ce cas précis.

Recommandation concrète : adopter le même duo de métriques que `pooled_analysis.py` plutôt que remplacer purement RMSE par CRPS : l'erreur ponctuelle normalisée (MASE-style) comme axe principal, le CRPS normalisé comme axe complémentaire de calibration/distribution. C'est exactement ce que les tableaux ci-dessous exploitent.

2 Méthodologie — daily vs weekly, D+1 vs W+1

Trois scripts, dans `experiments/`, prolongent le protocole *train-once / walk-forward* déjà utilisé pour TSDiff (`weekly_headtohead.py`, `weekly_headtohead_v2.py`) aux 5 autres modèles : `weekly_multimodel.py` définit le **régime B** (modèle entraîné en quotidien, poussé en multi-pas jusqu'à l'horizon hebdo — ex. TSDiff-D) et le **régime C** (modèle ré-entraîné nativement sur des données ré-échantillonnées en hebdo — ex. TSDiff-W), sur 5 actifs (SPY, BTC-USD, ETH-USD, ZN=F, TLT) et 30 origines walk-forward. `pooled_analysis.py` regroupe ensuite l'évidence *par modèle* (au lieu de l'éparpiller sur 15+ cellules actif×horizon séparées), avec double test (Diebold-Mariano Newey-West *et* bootstrap par blocs, qui doivent concorder) et correction de Holm sur les 6 modèles.

3 Tableau 1 — Entraînement daily (régime B) vs weekly-natif (régime C)

Modèle	MASE (p bootstrap)	CRPS norm. (p bootstrap)	Verdict
ARIMA-GARCH	0,554 (ns)	0,507 (ns)	Indifférent — équivalent B/C
SARIMA	0,080 (ns)	0,043 (sig.)	Signal fragile — DM et bootstrap discordants sur C
Prophet	0,383 (ns)	0,000 (sig.)	Significatif sur CRPS seul — C (natif) mieux calibré
LSTM	0,001 (sig.)	0,001 (sig.)	Significatif — B (daily→hebdo) nettement meilleur
Naïve	1,000 (ns)	0,102 (ns)	Indifférent (trivial par construction)
TSDiff	0,402 (ns)	0,055 (ns)	Tendance CRPS non confirmée ($p \approx 0,055$)

Table 1: Différentiel pooled (B – C), 270 points par modèle (3 classes d'actifs indice/obligataire/crypto × 3 horizons W+1–W+3, block bootstrap $L=3$).

Seul LSTM montre un écart net et concordant : son architecture à fenêtre fixe (30 pas) n'a pas besoin d'être modifiée pour tourner en hebdo, mais 30 jours et 30 semaines d'historique n'ont pas le même pouvoir prédictif — le régime B (entraîné en daily, poussé en multi-pas) reste nettement préférable pour ce modèle. Prophet montre l'inverse sur le seul axe CRPS (mieux calibré en natif hebdo), à

interpréter avec prudence compte tenu des problèmes de walk-forward déjà documentés pour Prophet ailleurs dans le repo (`BRIEF_correction_prophet.md`) — je n’ai pas ré-audité cette implémentation hebdo spécifique pour la même régression.

4 Tableau 2 — D+7 (daily) vs W+1 (weekly-natif), aligné vendredi

Modèle	MASE (p bootstrap)	CRPS norm. (p bootstrap)	Verdict
ARIMA-GARCH	0,030 (sig.)	0,198 (ns)	Significatif sur l’erreur ponctuelle seulement
SARIMA	0,089 (ns)	0,192 (ns)	Indifférent (puissance faible, $n=35$)
Prophet	0,000 (sig.)	0,000 (sig.)	Significatif — D+7 nettement meilleur que W+1
LSTM	0,000 (sig.)	0,000 (sig.)	Significatif — D+7 nettement meilleur que W+1
Naive	0,148 (ns)	0,197 (ns)	Indifférent (puissance faible)
TSDiff	0,531 (ns)	0,438 (ns)	Indifférent ($n=31$, puissance très limitée)

Table 2: Différentiel pooled (D+7 – W+1), $n=31-40$ selon modèle. **Réserve de puissance explicite (déjà documentée dans le repo)** : D+7 n’a que ~ 10 origines glissantes éparses par (modèle, actif), et l’alignement vendredi n’en retient qu’une fraction — tout verdict ici doit être lu avec prudence, y compris les cases vertes.

5 Tableau 3 — Calibration (couverture PI 95 %), pooled par modèle

Modèle	Couverture observée	Écart à 95 %	Verdict (bootstrap, Holm)
ARIMA-GARCH	93,5 %	–1,3 pt	Pas de miscalibration exploitable
SARIMA	92,9 %	–3,7 pt	Sous-couverture significative
Prophet	75,9 %	–20,3 pt	Sous-couverture sévère
LSTM	93,6 %	–2,6 pt	Sous-couverture significative (faible mais réelle)
Naive	93,3 %	–2,9 pt	Sous-couverture significative
TSDiff	80,9 %	–14,6 pt	Sous-couverture sévère

Table 3: Couverture pooled tous horizons/régimes confondus (bootstrap par blocs, cluster-aware, correction de Holm sur 6 modèles). Le test naïf de Kupiec, moins fiable ici (suppose des essais i.i.d.), est écarté au profit du bootstrap.

Constat le plus net de ce document : **5 des 6 modèles sous-couvrent significativement leur propre bande à 95 %** — seul ARIMA-GARCH passe le test robuste. Prophet et TSDiff décrochent sévèrement (–20 et –15 points), ce qui, pour TSDiff, rejoint directement la question du CRPS : un modèle de diffusion mal calibré verra son CRPS empirique pénalisé pour la bonne raison (intervalles trop étroits par rapport au réel), ce que le RMSE seul ne peut jamais révéler.

6 Tableau 4 (exploratoire) — classement brut par cellule actif×horizon

Tableau complet : les 6 modèles apparaissent chacun dans les 3 catégories (D+1/D+7 quotidien natif, daily→hebdo régime B, natif hebdo régime C) — 18 lignes en tout, sur les 25 cellules actif×horizon de la matrice.

Modèle	Fois leader (RMSE brut) / 25	Fois sig. pire que le leader	Fois indiscernable
<i>D+1 / D+7 (quotidien natif)</i>			
ARIMA-GARCH	5	2	3
SARIMA	3	2	5
Naive	2	2	6
Prophet	0	10	0
LSTM	0	8	2
TSDiff	0	5	5
<i>Daily→hebdo (régime B — entraîné quotidien, poussé multi-pas)</i>			
ARIMA-GARCH	4	0	11
SARIMA	2	0	13
Naive	0	0	15
Prophet	1	9	5
LSTM	0	7	8
TSDiff	2	0	13
<i>Natif hebdo (régime C — ré-entraîné sur données ré-échantillonnées)</i>			
ARIMA-GARCH	0	1	14
SARIMA	1	0	14
Naive	0	0	15
Prophet	0	12	3
LSTM	0	11	4
TSDiff	5	4	6

Table 4: Comptage brut (RMSE non normalisé par actif, 25 cellules actif×horizon, 18 lignes = 6 modèles × 3 catégories). **Non poolé, pas de code couleur ici** — réserve explicite du repo : TSDiff est figé à T0 (train-once-forward) alors que les 5 autres sont ré-entraînés à chaque origine, asymétrie de protocole qu’aucun test statistique ne corrige. À lire comme indicatif, pas comme un classement définitif.

7 Conclusions

- **CRPS** : oui, remplace utilement le RMSE pour juger TSDiff équitablement — déjà implémenté (empirique pour TSDiff seul, gaussien normalisé pour la comparaison à 6 modèles). Le garder en *complément* d’une erreur ponctuelle normalisée (MASE), pas en remplacement isolé.
- **Daily vs weekly** : seul LSTM a un écart net et fiable (régime daily→hebdo préférable). Les autres modèles sont soit indifférents, soit sur un signal trop fragile pour trancher (SARIMA, Prophet sur CRPS, TSDiff en tendance).
- **D+7 vs W+1** : Prophet et LSTM nettement meilleurs en D+7 quotidien qu’en W+1 natif — mais puissance statistique faible partout sur ce test, à confirmer avec plus d’origines avant d’en tirer une politique définitive.
- **Calibration** : le vrai signal d’alerte du document — 5 modèles sur 6 sous-couvrent significativement, TSDiff et Prophet sévèrement. À traiter avant toute bascule de pipeline daily/weekly.