

NOTE — NsDiff vs TSDiff à budget d'échantillonnage égal, régimes weekly ET daily

2026-08-06. Complète NOTE_nsdiff_consolidation_daily_vs_weekly.md (chantier intra-NsDiff) et NOTE_compare_weekly_tsdiff_nsdiff.md (TSDiff-W vs NsDiff-W à $m=500$, 30 origines, régime weekly seulement).
Artefacts : experiments/diffusion_multiseed_v2.py → diffusion_multiseed_v2/, experiments/tsdiff_daily_epoch_sweep.py → tsdiff_daily_epochs.json, experiments/nsdiff_vs_tsdiff_v2.py → nsdiff_vs_tsdiff_v2.json, machinerie de test partagée dans experiments/diffusion_headtohead.py.

0. Ce que cette note ajoute

NOTE_compare_weekly_tsdiff_nsdiff.md comparait déjà les deux diffusions, à budget d'échantillonnage égal ($m=500$ des deux côtés) et sur 5 graines — ce n'était donc pas un match biaisé. Mais elle est limitée au **régime weekly-natif** et aux **30 origines du duel**. Deux manques :

1. le **régime daily (B)** n'avait jamais été comparé entre les deux diffusions — c'est précisément l'axe du chantier de consolidation ; 2. la **grille des 90 origines** oos, sur laquelle tout le reste de la consolidation est mesuré, n'était pas couverte.

Cette note comble les deux. Les lignes oos de TSDiff en base n'étaient pas réutilisables : elles sont à $n_samples=50$, où un intervalle étiqueté 95 % n'en couvre réellement que $\sim 91,3$ % (biais du quantile empirique, cf. NOTE_nsdiff_consolidation_daily_vs_weekly.md §1) — soit $\sim 2,8$ points offerts à NsDiff. Les deux bras ont donc été régénérés à 200 tirages, **dans le même run, sur une seule série de prix gelée, par la même boucle de génération** (generate_nsdiff_asset avec son kwarg engine).

0.1 Ce que p désigne ici

Toutes les p -values de ce chantier viennent du **bootstrap par blocs par percentile** (paired_test.paired_block_bootstrap_test), jamais d'un test paramétrique. Concrètement : on rééchantillonne 10 000 fois la série chronologique des différences par origine, en blocs de 3 origines consécutives (pour respecter le chevauchement des cibles $W+2/W+3$), et

$p = 2 \times$ (fraction des 10 000 moyennes rééchantillonnées tombant du côté de zéro OPPOSÉ à la moyenne observée), plafonnée à 1.

C'est donc une p -value **bilatérale**, qui répond à « si le vrai écart moyen était nul, quelle fraction des rééchantillonnages produirait un écart au moins aussi extrême que celui observé ? ». Elle ne suppose ni normalité, ni indépendance des origines.

Résolution : avec 10 000 réplicats, le plus petit p non nul vaut $2/10\,000 = 2 \times 10^{-4}$. Un $p = 0$ affiché signifie donc **zéro réplicat sur 10 000 du mauvais côté** — soit $p < 2 \times 10^{-4}$, et rien de plus fin ne peut être affirmé sans augmenter n_boot .

Seuil de décision. La convention du repo est $\alpha = 0,05$ (significant_at_05), mais elle ne suffit pas ici pour deux raisons :

- **tests multiples** — 30 cellules et 12 tests poolés sans correction. À 5 %, on attend $\sim 1,5$ faux positif par famille de 30. Une correction de Holm sur les 12 tests poolés donnerait un seuil effectif de $0,05/12 \approx 0,004$;
- **puissance faible** — effective_ $n = 30$. Un p juste au-dessus de 0,05 ne démontre rien du tout.

D'où la lecture pratique appliquée dans cette note : un p de l'ordre de 2×10^{-4} survit à n'importe quelle correction raisonnable et se lit comme un résultat ; un p entre 0,01 et 0,05 (ex. crypto/Winkler à $W+3$ dans la note de consolidation, $p = 0,0378$) ne survit pas à Holm et se lit comme un signal à confirmer ; un p au-dessus de 0,05 ne se lit **pas** comme une absence d'effet — c'est ce que le TOST, lui, permet d'affirmer.

1. Verdict

1.1 Régime weekly-natif — NsDiff domine sur les deux axes

Horizon	Actif	RMSE NsDiff / TSDiff	verdict RMSE	graines sig.	Cov95 NsDiff / TSDiff	verdict Winkler
W+1	BTC-USD	5255 / 5789	NsDiff	4/5	0.967 / 0.911	indistinguable
W+1	ETH-USD	274.0 / 349.4	NsDiff	4/5	0.947 / 0.927	NsDiff
W+1	SPY	12.95 / 13.19	indistinguable	0/5	0.944 / 0.802	NsDiff
W+1	TLT	1.402 / 1.790	NsDiff	5/5	0.964 / 0.956	NsDiff
W+1	ZN=F	0.7725 / 0.7712	indistinguable	0/5	0.933 / 0.827	NsDiff
W+2	BTC-USD	8118 / 9567	NsDiff	4/5	0.949 / 0.898	NsDiff
W+2	ETH-USD	413.6 / 632.8	NsDiff	4/5	0.962 / 0.884	NsDiff
W+2	SPY	17.07 / 17.61	indistinguable	0/5	0.951 / 0.811	NsDiff
W+2	TLT	1.832 / 2.820	NsDiff	4/5	0.976 / 0.924	NsDiff
W+2	ZN=F	0.9722 / 1.017	indistinguable	1/5	0.962 / 0.793	NsDiff
W+3	BTC-USD	10 610 / 12 760	NsDiff	4/5	0.942 / 0.891	NsDiff
W+3	ETH-USD	525.8 / 849.4	NsDiff	4/5	0.936 / 0.880	NsDiff
W+3	SPY	20.82 / 21.76	indistinguable	1/5	0.920 / 0.818	NsDiff
W+3	TLT	2.073 / 3.538	NsDiff	5/5	0.987 / 0.947	NsDiff
W+3	ZN=F	1.143 / 1.237	NsDiff	0/5	0.964 / 0.838	NsDiff

Poolé tous actifs : NsDiff significativement meilleur sur les 6 tests (3 horizons × RMSE/Winkler), **p = 0 partout** (0 réplicat bootstrap sur 10 000 du mauvais côté). TSDiff ne gagne aucune cellule sur aucun axe.

1.2 Régime daily — égalité sur le point, écart massif sur l'incertitude

Horizon	Poolé RMSE	Poolé Winkler	Cov95 NsDiff	Cov95 TSDiff
W+1	indistinguable (p=0.152)	NsDiff (p = 0)	0.882 – 0.933	0.598 – 0.738
W+2	indistinguable (p=0.813)	NsDiff (p = 0)	0.889 – 0.951	0.611 – 0.747
W+3	indistinguable (p=0.280)	NsDiff (p = 0)	0.816 – 0.976	0.567 – 0.724

Sur le **point**, les deux diffusions sont **interchangeables en daily** : aucun test poolé ne les sépare, et les verdicts par cellule sont majoritairement indistinguables (TSDiff prend BTC-USD à W+1/W+2 sur 1 graine sur 5 ; NsDiff prend SPY/TLT/ZN=F à W+3). Sur l'**incertitude**, l'écart est sans exception : **20 à 30 points de couverture** d'avance pour NsDiff, et le Winkler en sa faveur sur les **15 cellules sur 15**.

1.3 Synthèse sur les 30 cellules (2 régimes × 3 horizons × 5 actifs)

Axe	NsDiff gagne	TSDiff gagne	indistinguable
Winkler	29	0	1
RMSE	12	2	16

Le motif est net et il recoupe le finding de fond du programme : **le gain de NsDiff se loge dans la fiabilité de l'incertitude, pas dans le point**. En weekly il gagne les deux ; en daily, seulement la calibration.

2. Deux erreurs de protocole rencontrées en route

2.1 Le premier bras daily était invalide (corrigé)

La première génération réutilisait, côté daily, le budget d'époques hebdomadaire de chaque modèle — convention héritée de `oos_nsdiff_daily_weekly.py`. Elle est sûre pour NsDiff (40 plat) et **fausse pour TSDiff**. La série quotidienne compte ~2465 observations contre ~511 en hebdomadaire : à époques égales, ~5× plus de pas de gradient. Mesuré sur SPY, largeur médiane du PI 95 % en % du prix :

epochs	10	20	40	80
largeur PI	12.39 %	3.41 %	0.46 %	0.12 %

À 80 époques (ce qu'utilisait le premier run pour 4 actifs sur 5), la couverture observée tombait à **1–6 %** : plus un modèle sous-calibré, un modèle effondré, contre lequel toute victoire au Winkler est mécanique. Le repo connaissait la fragilité à demi-mot — `weekly_headtohead_v2.run_pair_v2` désactive TSDiff-D par défaut en le qualifiant de *structurally under-calibrated*, et `weekly_headtohead_results.json` (300 époques) enregistre `coverage_95: 0.0`.

Correction : `generate_nsdiff_asset` accepte désormais un `epochs_daily` distinct (opt-in, défaut = `epochs`, comportement inchangé), et `tsdiff_daily_epoch_sweep.py` sélectionne le budget de TSDiff-D par validation — argmin CRPS, critère maison réutilisé tel quel (`epoch_sweep.select_epochs`), candidats 10/20/40, entraînement incrémental (`epoch_sweep.fit_checkpoints`). Retenu : **20 époques dans 19 cellules sur 25** (40 dans 5, 10 dans 1), ce qui reproduit l'ordre de grandeur des lignes oos en base (3.41 % contre 3.65 %).

Vérification du correctif : sur `seed42|SPY`, le bras weekly se reproduit **bit-à-bit** (largeur 5.930 % → 5.930 %, échantillons identiques) tandis que le bras daily passe de 0.177 % à 4.573 %. Les tirages hebdomadaires précèdent le fit daily dans la boucle et n'en dépendent pas — vérifié, pas supposé. Les chiffres weekly du §1.1 sont donc les mêmes avant et après correction.

2.2 Une fuite dans la sélection d'époques hebdomadaire de TSDiff (déclarée, non corrigée)

Les époques hebdomadaires de TSDiff (40/60/80) sont relues verbatim de `compare_weekly_diffusion.json`, où elles avaient été sélectionnées sur validation **dans le protocole du duel**. Or ce découpage place la validation (SPY : 2025-09-19 → 2025-12-05, 12 origines) **à l'intérieur** de la grille de test oos (2024-10-18 → 2026-07-02). ~13 % des origines évaluées ont donc servi à choisir l'hyperparamètre de TSDiff.

Non corrigé (il faudrait re-sweeper le bras hebdomadaire), mais **la fuite joue en faveur de TSDiff** — qui perd quand même les 6 tests poolés weekly. Le verdict du §1.1 en est d'autant plus conservateur. Le sweep daily du §2.1, lui, est ancré **strictement avant** la première origine de test : aucune des 90 origines n'entre dans la sélection.

3. Non-négociables — statut

- **Budget d'échantillonnage strictement égal** : 200 tirages des deux côtés, lus par la même formule (quantiles empiriques 2.5/97.5) dans la même boucle.
- **Prix identiques** : téléchargés une fois, gelés dans `diffusion_multiseed_v2/prices/*.parquet`, partagés par les deux bras. Nécessaire : yfinance reset les mêmes cotes avec ~2e-7 de bruit relatif d'un appel à l'autre, qu'un fit de 40-80 époques amplifie à ~6e-6 sur les échantillons.
- **Même code de génération** : `generate_nsdiff_asset` paramétré par un `DiffusionEngine`. Le chemin par défaut (NsDiff) a été vérifié **bit-à-bit** équivalent à l'appel d'origine sur les trois points touchés (fit, standardisation, forecast).
- **Même code de test** : `diffusion_headtohead.py`, partagé avec le match vs ARIMA-GARCH. Le refactor qui l'a extrait a été vérifié à **0 écart numérique** sur ce match.
- **Multi-graines** : 42-46, chaque test rejoué par graine et sur les graines poolées (métrique moyennée par origine, l'unité d'inférence reste l'origine — `n=90`, `effective_n=30`).
- `tracking.db` **jamais écrit** : artefact isolé. La piste `oos/dashboard` reste `single-seed 42` et `n_samples=50`.
- **pytest : 365 passed, 1 skipped** (+14 tests neufs sur les conventions de signe du duel — la couverture se maximise quand tout le reste se minimise, c'est là qu'un head-to-head s'inverse en silence).

4. Limites déclarées

- **Budgets d'époques non égalisés, et c'est volontaire** : TSDiff a 40/60/80 par (actif, graine) côté weekly, sélectionnés sur validation ; NsDiff a 40 plat. Les égaliser reviendrait à jeter la sélection de TSDiff. L'asymétrie va dans le sens de TSDiff (§2.2).
- **TSDiff-D reste fragile** : sa calibration varie d'un facteur 100 entre 10 et 80 époques. Le budget retenu est l'argmin CRPS, **pas** un optimum de calibration — même à son meilleur CRPS, il plafonne à 0.60–0.76 de couverture en validation. La supériorité de calibration de NsDiff en daily se lit donc face à un adversaire structurellement mal calibré, pas face à son meilleur réglage possible en couverture.
- **Puissance** : `effective_n=30`. Aucun « indistinguishable » de cette note n'est une absence d'effet démontrée — et aucun TOST n'a été fait ici (contrairement au chantier intra-NsDiff), donc l'« interchangeabilité » du point en daily (§1.2) est une non-réfutation, pas une équivalence établie.
- **Tests multiples non corrigés** sur les 30 cellules.
- **Protocole d'entraînement** : *train-once-forward* pour les deux bras, donc symétrique ici — contrairement au match vs ARIMA-GARCH.