

NOTE — NsDiff daily vs weekly : consolidation du verdict (tâches 1 à 7)

2026-08-05. Réponse au brief « NsDiff : consolider le verdict daily vs weekly ». **Supersède les conclusions de** NOTE_compare_daily_vs_weekly_nsdiff.md §4.2/§6bis/§7 (qui restent valables comme description de l'artefact $n_samples=50$, mais dont le verdict « signal réel de calibration en faveur du weekly » ne survit pas tel quel — voir §1 et §3). Ne remplace pas NOTE_compare_weekly_tsdiff_nsdiff.md (TSDiff vs NsDiff, question distincte).

Artefacts produits (tous isolés, tracking.db jamais écrit — la piste oos/dashboard reste single-seed 42, comparable aux 6 autres modèles) :

Fichier	Contenu
experiments/nsdiff_multiseed_v2.py + nsdiff_multiseed_v2/	tâche 4 : régénération 5 graines $\times$ 5 actifs $\times$ 3 horizons $\times$ 2 régimes à $n_samples=200$, nuages complets conservés (13 500 lignes $\times$ 200 tirages, 8 min)
experiments/calibration_tests.py (+ test_calibration_tests.py)	briques neuves : Kupiec, Christoffersen, TOST, test d'écart de couverture par blocs — 19 tests unitaires
experiments/nsdiff_consolidation_tests.py $\rightarrow$.json	tâches 1, 2, 3
experiments/nsdiff_conformal_daily.py $\rightarrow$.json	tâche 5
experiments/nsdiff_seed_ensemble.py $\rightarrow$.json	tâche 6
experiments/nsdiff_vs_garch_w23.py $\rightarrow$.json	tâche 7
experiments/nsdiff_v2_data.py	chargement/mise en forme partagés, aucune statistique

Suite : NOTE_duel_nsdiff_vs_tsdiff_budget_egal.md étend le match inter-modèles à TSDiff, aux deux régimes et à budget d'échantillonnage égal (200 tirages des deux côtés, prix gelés partagés). Les deux notes partagent la machinerie de test (experiments/diffusion_headtohead.py).

Convention de lecture, demandée par le brief et appliquée partout :

- **descriptif** = un chiffre, jamais testé ;
- **significatif à graine fixe** = test sur une seule graine (ce que faisait le dashboard oos) ;
- **significatif poolé multi-graines** = métrique moyennée sur les 5 graines origine par origine, puis testée. L'unité d'inférence reste **l'origine** ($n=90$, effective_ $n=30$ inchangés) : moyenner sur les graines réduit le bruit Monte-Carlo, ça ne crée pas de points de donnée. Ce qui est testé ainsi est la performance **attendue d'un run à graine tirée au hasard** — pas celle d'un ensemble des 5 graines, qui est la tâche 6.

0. Le résultat principal, d'emblée

Le « signal réel de calibration en faveur du weekly » de la synthèse précédente était, pour l'essentiel, un artefact de $n_samples=50$ — et il se scinde en deux fois testé proprement :

- **la couverture** : le weekly est bel et bien mieux calibré, le daily sous-couvre, et ça **résiste** au passage à 200 tirages, au pooling multi-graines et à deux familles de tests indépendantes $\rightarrow$ **établi** ;
- **le Winkler** (score composite largeur + pénalité) : l'avantage weekly **disparaît**. Il valait $p=0.0100$ en global et $p=0.0154$ en crypto à la graine 42 avec 50 tirages ; à 200 tirages, **la même graine 42** donne $p=0.0500$ et $p=0.0510$, et le poolé 5 graines donne **$p=0.3180$** (global, $W+1$). $\rightarrow$ **non établi**.

Autrement dit : le weekly **couvre mieux, mais il paie cette couverture en largeur**, et une fois les bandes du daily correctement estimées, le score composite ne départage plus les deux régimes. C'est plus modeste que « weekly mieux calibré », et c'est ce que les données supportent.

Sur la **précision**, le brief demandait de conclure *positivement* : c'est fait. Le TOST établit l'**équivalence à ± 5 %** sur 4 actifs / 5 à W+1 et à W+2 — ce n'est plus « indistinguishable », c'est « interchangeable », avec une marge déclarée a priori.

1. Tâche 4 (faite en premier, comme conseillé) — 50 → 200 tirages

experiments/nsdiff_multiseed_v2.py. Aucun réentraînement : mêmes fits, mêmes graines (42-46), mêmes origines (lues verbatim), mêmes budgets (epochs=40, seq_len=30, k_denoise=20) ; seul le **forecast** est refait avec 200 tirages au lieu de 50. 8 minutes pour 5 graines × 5 actifs × 3 horizons × 2 régimes. Les nuages complets sont conservés sur disque, ce qui rend les tâches 5 et 6 possibles sans refit.

Pourquoi c'était le bon ordre. À 50 tirages, le quantile empirique à 97,5 % est la ~49^{ème} statistique d'ordre sur 50 : il est **biaisé vers l'intérieur**, donc les bandes sont trop étroites, donc il y a trop de violations, donc le Winkler est pénalisé. L'effet est mesurable, et il n'a **pas frappé les deux régimes également** :

Couverture 95 %, **graine 42 seule**, W+1 (colonne gauche : artefact n_samples=50 de la note précédente §2 ; colonne droite : artefact v2) :

Actif	daily 50 → 200	weekly 50 → 200
BTC-USD	0.900 → 0.922	0.967 → 0.967
ETH-USD	0.867 → 0.911	0.933 → 0.944
SPY	0.822 → 0.867	0.922 → 0.944
ZN=F	0.856 → 0.911	0.878 → 0.956
TLT	0.889 → 0.933	0.956 → 0.967

Le daily gagne **+4,2 points** de couverture en moyenne (médiane +4,4), le weekly **+2,4** (médiane +1,1 — sa moyenne est tirée vers le haut par le seul ZN=F, +7,8). Hypothèse (cohérente, **non testée formellement** — elle demanderait un plan d'expérience sur n_samples que ce brief ne demande pas) : le nuage du régime daily est propagé sur ~5 pas quotidiens contre 1 pas hebdomadaire, donc plus dispersé et à queues plus lourdes, et le biais du quantile empirique à 50 tirages y coûte davantage. **Ce qui est certain, c'est la conséquence** : une partie du déficit de couverture attribué au « régime daily » était en fait un déficit d'échantillonnage.

Conséquence directe sur la note précédente : sa §4.2 (« le Winkler descend côté weekly ... malgré une PI plus large ») décrivait un artefact autant qu'un effet de régime. Sur les moyennes 5 graines à 200 tirages, le Winkler est **plus bas côté daily sur 2 actifs / 5** à W+1 (TLT 7.80 vs 8.02 ; ZN=F 4.15 vs 4.32) et quasi ex æquo sur BTC-USD (30 540 vs 30 430, 0,4 % d'écart) — à 50 tirages, le daily ne gagnait que sur ZN=F et l'écart BTC était de 8 %.

2. Tâche 2 — W+2 et W+3 passés en multi-graines

Tout ce qui suit (§3, §4) est calculé aux **trois** horizons, 5 graines, 90 origines/actif, effective_n=30. Les W+2/W+3 ne sont plus un « bonus qualitatif single-seed » (note précédente §5) : même protocole complet que W+1. C'est utile, parce que **c'est là que le motif est le plus net** — la sous-couverture du daily se creuse avec l'horizon :

Actif	Cov95 daily W+1 → W+2 → W+3	Cov95 weekly W+1 → W+2 → W+3
BTC-USD	0.933 → 0.911 → 0.884	0.967 → 0.949 → 0.942
ETH-USD	0.898 → 0.889 → 0.816	0.947 → 0.962 → 0.936
SPY	0.880 → 0.927 → 0.938	0.944 → 0.951 → 0.920
TLT	0.933 → 0.951 → 0.976	0.964 → 0.976 → 0.987
ZN=F	0.922 → 0.942 → 0.976	0.933 → 0.962 → 0.964

(graines moyennées.) La crypto se dégrade franchement côté daily ; les taux partent au contraire en **sur**-couverture aux horizons longs, des deux côtés.

3. Tâche 1 — le signal calibration, testé formellement

3.1 Skill Winkler poolé (le test que la note précédente déclarait hors budget)

dashboard_d7_w1.build_pooled_series / run_pooled_test réutilisés tels quels (dédoublonnage ZN=F+TLT en une contribution « taux » inclus), rejoués **par graine** puis **sur les 5 graines poolées**.

Horizon	Groupe	graines significatives (weekly)	p poolé 5 graines	verdict poolé
W+1	global	0/5	0.3180	indistinguable
W+1	crypto	0/5	0.2946	indistinguable
W+1	actions	0/5	0.4344	indistinguable
W+1	obligations	0/5	0.5968	indistinguable
W+2	global	0/5	0.8082	indistinguable
W+2	crypto	1/5	0.1138	indistinguable
W+2	actions	0/5	0.2980	indistinguable
W+2	obligations	0/5	0.9538	indistinguable
W+3	global	0/5	0.4314	indistinguable
W+3	crypto	2/5	0.0378	weekly significativement meilleur
W+3	actions	0/5	0.2204	indistinguable
W+3	obligations	0/5	0.3268	indistinguable

Une seule case survit : **crypto à W+3** ($p=0.0378$, 2 graines sur 5 — 42 : $p=0.0124$ et 44 : $p=0.0422$, 46 à 0.0524 juste au-dessus du seuil). C'est un signal, pas un verdict : **une case sur les douze** (4 groupes $\times$ 3 horizons) à $p<0.05$, sans correction pour tests multiples, portée par 2 graines sur 5.

Le résultat de la note précédente ne se reproduit donc pas : à la graine 42, W+1, global, on passe de $p=0.0100$ (50 tirages) à **$p=0.0500$** (200 tirages) — pile au seuil, du mauvais côté. Le skill Winkler du weekly n'était pas robuste au budget d'échantillonnage.

3.2 Couverture — là, le signal tient

Deux familles de tests, volontairement redondantes.

(a) Test de référence — écart (indicateur – 0.95) bootstrappé **par blocs** (paired_test.paired_block_bootstrap_test, block_length=3), sans hypothèse d'indépendance des violations. Indicateur moyenné sur les 5 graines par origine.

(b) Complément de manuel — **Kupiec** (POF, couverture inconditionnelle) et **Christoffersen** (indépendance + conditionnelle), calculés **par graine**, χ^2 . Leurs p-values sont **optimistes** (elles supposent des violations i.i.d., or les cibles W+2/W+3 se chevauchent d'une origine à l'autre) ; LR_ind est en outre structurellement biaisé vers le rejet à W+2/W+3, ce chevauchement créant une dépendance **mécanique**. C'est déclaré dans le module et répété ici.

W+1, graines moyennées (p = test (a) ; Kupiec = nombre de graines rejetant à 5 %) :

Actif	daily : écart / p / Kupiec	weekly : écart / p / Kupiec	tête-à-tête (weekly – daily)
BTC-USD	–0.017 / 0.434 / 0/5	+0.017 / 0.333 / 0/5	weekly couvre plus ($p=0.009$)
ETH-USD	–0.052 / 0.024 / 2/5	–0.003 / 0.864 / 0/5	weekly couvre plus ($p<0.001$)
SPY	–0.070 / 0.009 / 4/5	–0.006 / 0.865 / 0/5	indistinguable ($p=0.052$)
TLT	–0.017 / 0.498 / 0/5	+0.014 / 0.448 / 0/5	weekly couvre plus ($p=0.006$)
ZN=F	–0.028 / 0.229 / 1/5	–0.017 / 0.468 / 0/5	indistinguable ($p=0.599$)

Aux trois horizons réunis : le **daily** est significativement mal couvert sur **4 cellules/15** (ETH W+1/W+2/W+3, SPY W+1), **toujours par sous-couverture** ; le **weekly** sur **1 cellule/15** (TLT W+3, et c'est une **sur**-couverture, +0.037). Kupiec par graine raconte la même chose en plus marqué (ETH daily : 2/5 puis 4/5 puis 5/5 graines rejettent quand l'horizon s'allonge ; weekly : 0/5 partout sauf TLT W+3). Le tête-à-tête apparié donne « weekly couvre significativement plus » sur **8 cellules/15**, et jamais l'inverse.

Verdict tâche 1 : le weekly est **mieux calibré en couverture** — établi, au sens poolé multi-graines, par deux tests indépendants, aux trois horizons. Il **n'est pas mieux calibré au sens du Winkler** — l'avantage composite était un artefact de $n_{\text{samples}}=50$. La différence entre les deux énoncés est la **largeur** : le weekly achète sa couverture en élargissant (PI plus large sur 15 cellules/15), ce que le Winkler facture.

4. Tâche 3 — TOST : « indistinguable » devient « équivalent »

Marge $\pm 5\%$ de **RMSE relatif**, fixée **a priori**, identique pour les 5 actifs et les 3 horizons. Justification déclarée : (i) c'est l'ordre de grandeur de la variabilité **inter-graines** déjà mesurée sur ce modèle (CV du RMSE 0,8 %–7,3 %) — une différence de régime plus petite que le bruit de graine n'est pas exploitable en production ; (ii) elle est plus stricte que les écarts observés sur les cellules déjà déclarées indistinguables ; (iii) aucune marge n'a été choisie après coup.

Actif	W+1 (ratio, p_TOST)	W+2	W+3
BTC-USD	1.016 — équivalent (0.012)	0.995 — équivalent (0.000)	0.947 — différence établie (daily meilleur)
ETH-USD	0.992 — équivalent (0.020)	0.972 — non conclusif (0.198)	0.955 — non conclusif (0.427)
SPY	1.024 — non conclusif (0.098)	1.015 — équivalent (0.047)	1.017 — non conclusif (0.074)
TLT	1.002 — équivalent (0.000)	1.006 — équivalent (0.000)	0.998 — équivalent (0.000)
ZN=F	1.009 — équivalent (0.003)	1.013 — équivalent (0.002)	1.002 — équivalent (0.000)

4 actifs/5 à W+1 et W+2 : l'interchangeabilité daily/weekly sur la précision est **positivement établie**, pas seulement non réfutée. Les cases « non conclusif » sont un vrai résultat : ni différence ni équivalence — à effective_n=30, il ne faut pas les lire comme « interchangeables ».

Une case va dans l'autre sens : **BTC-USD à W+3**, où le **daily** est significativement meilleur (ratio 0.947, soit $-5,3\%$ de RMSE) — l'exact opposé du « weekly meilleur sur BTC » de la version single-seed.

Réserve à déclarer : le TOST poolé conclut à l'équivalence là où le TOST graine-par-graine ne le fait que sur 0 à 4 graines selon la case. Ce n'est pas une contradiction — moyenner sur les graines supprime la variance Monte-Carlo, et c'est bien le **ratio de RMSE attendu** qu'on veut borner, pas celui d'un tirage particulier. Mais le résultat porte sur la performance attendue, pas sur la garantie d'un run individuel.

5. Tâche 5 — recalibration conformale du daily : corrigeable, mais pas comme ça

Brique existante (tsdiff_recalibrate.py) importée telle quelle : split conforme, score de non-conformité côté par côté, k par (actif, graine, horizon, régime), **jamais** de facteur global. Découpe 50/50 par cutoff_date unique, calibration strictement avant le test. effective_n ≈ 15 **sur le bloc de test** — deux fois moins puissant que le corps de l'étude ; tout « indistinguable » y est encore moins informatif.

W+1, bloc de test :

Actif	cov daily avant → après	largeur daily avant → après	k daily (médiane graines)
BTC-USD	0.911 → 0.920	19 860 → 21 110	1.043
ETH-USD	0.916 → 0.960	940 → 1 351	1.462
SPY	0.929 → 0.996	43.84 → 88.34	1.915
TLT	0.947 → 1.000	4.504 → 6.471	1.498
ZN=F	0.947 → 0.996	2.312 → 3.545	1.554

Réponse : oui, l'écart de couverture se comble — et il se comble beaucoup trop. Le conformal par split à $n_{\text{calib}}=45$ est franchement conservateur (le quantile fini-échantillon retenu est la ~44^{ème} statistique d'ordre sur 45, soit le 97,8^{ème} percentile des scores) : la couverture monte à 0,99–1,00 et la largeur de SPY **double**. Ce n'est plus une correction, c'est une sur-correction.

Le re-test demandé par le brief, sur le bloc de test, skill Winkler global :

Scénario	verdict	p
avant recalibration	indistinguable	0.719
A — daily recalibré seul (la question du brief)	weekly significativement meilleur	p = 0
B — daily et weekly recalibrés (contrôle d'équité)	indistinguable	0.114

Le scénario A est **trompeur si on le lit seul** : le weekly n'y gagne pas parce qu'il est meilleur, mais parce qu'on a infligé au daily une couche de sur-élargissement qu'on n'a pas infligée au weekly — et le Winkler facture la largeur. Le scénario B, symétrique, ramène à « indistinguable » ($p=0.114$, et même direction qu'avant recalibration). C'est pour ça qu'il a été ajouté.

Conclusion pratique : la sous-couverture du daily *est* corrigeable, mais le split conformal à ce volume de calibration n'est pas le bon outil — il coûte plus en largeur qu'il ne rapporte en couverture. La tâche 6 fait mieux, gratuitement.

6. Tâche 6 — ensemble multi-graines : le meilleur rapport qualité/prix du lot

Les 5 nuages de 200 tirages sont **concaténés** en un nuage de 1000 (mélange des 5 prédictives — élargit quand les graines sont en désaccord, ce qui est l'effet recherché ; moyenner les bornes l'aurait au contraire lissé). Point et bandes lus dessus avec **la même formule** que pour un run simple. Référence de comparaison : la performance **attendue d'un run à graine unique** (métrique moyennée sur les 5 graines, origine par origine) — pas la meilleure graine, pas la pire. **Coût : aucun refit.**

W+1 :

Actif	régime	RMSE 1 graine → ens.	Cov95 1 graine → ens.	Winkler 1 graine → ens.	test Winkler
BTC-USD	daily	5338 → 5150	0.933 → 0.956	30 540 → 28 750	indistinguable
BTC-USD	weekly	5255 → 5221	0.967 → 0.967	30 430 → 30 360	indistinguable
ETH-USD	daily	271.9 → 266.4	0.898 → 0.911	1557 → 1432	ensemble meilleur
ETH-USD	weekly	274.0 → 272.5	0.947 → 0.956	1366 → 1357	indistinguable
SPY	daily	13.26 → 13.03	0.880 → 0.900	81.18 → 73.73	ensemble meilleur
SPY	weekly	12.95 → 12.89	0.944 → 0.956	70.71 → 68.16	ensemble meilleur
TLT	daily	1.405 → 1.399	0.933 → 0.944	7.80 → 7.47	ensemble meilleur
TLT	weekly	1.402 → 1.395	0.964 → 0.967	8.02 → 8.04	indistinguable
ZN=F	daily	0.779 → 0.775	0.922 → 0.933	4.150 → 3.981	ensemble meilleur
ZN=F	weekly	0.773 → 0.769	0.933 → 0.933	4.323 → 4.210	ensemble meilleur

Sur les 3 horizons : le Winkler s'améliore significativement sur **7 cellules daily / 15** contre **2 cellules weekly / 15** — exactement ce que le brief anticipait (« en particulier sur le daily dont la dispersion est la plus forte »). La couverture monte des deux côtés, davantage côté daily. Le RMSE s'améliore partout, de façon modeste et non testée individuellement.

Et le verdict daily-vs-weekly rejoué sur l'ensemble : skill Winkler **indistinguable** aux trois horizons ($p=0.865 / 0.325 / 0.715$) ; skill RMSE indistinguable à W+1/W+2, et à **W+3 le daily devient significativement meilleur** ($p=0.0216$). L'ensemble mange une bonne part de ce qui restait de l'écart daily/weekly — et il ne coûte rien.

7. Tâche 7 — NsDiff contre le modèle volatilité (ARIMA-GARCH) à W+2/W+3

Appariement par (actif, horizon, target_date), à l'intérieur d'un même régime. **Asymétrie de protocole à citer avec tout chiffre de cette section** : ARIMA-GARCH est refit à **chaque** origine sur fenêtre glissante et est déterministe (pas de graine) ; NsDiff est *train-once-forward* et dépend d'une graine. L'écart mesuré mélange donc « modèle » et « protocole d'entraînement » — la réserve que porte déjà tout classement inter-modèles de ce repo.

Poolé tous actifs (skill vs marche aléatoire, dédoublement taux inclus) :

Horizon	Régime	Skill RMSE	Skill Winkler
W+1	weekly	GARCH meilleur (p=0.0298)	indistinguable (0.116)
W+1	daily	GARCH meilleur (p = 0, cf. §note sur p)	GARCH meilleur (p=0.0194)
W+2	weekly	indistinguable (0.0660)	indistinguable (0.365)
W+2	daily	GARCH meilleur (p=0.0080)	indistinguable (0.169)
W+3	weekly	GARCH meilleur (p=0.0300)	indistinguable (1.000)
W+3	daily	indistinguable (0.233)	GARCH meilleur (p=0.0484)

Par cellule à W+2/W+3 (20 cellules = 5 actifs × 2 horizons × 2 régimes) : **NsDiff ne gagne aucune cellule**, ni sur le RMSE ni sur le Winkler, dans aucun des deux régimes. GARCH en gagne **8 sur le RMSE** et **3 sur le Winkler** ; le reste est indistinguable. Côté couverture, GARCH est plus proche de la cible que NsDiff-daily sur presque toutes les cellules (ex. W+2 SPY : 0.989 vs 0.927 ; W+3 ETH : 0.933 vs 0.816).

Réponse à la question du programme : non, NsDiff ne referme pas l'écart vs le modèle volatilité à W+2/W+3. Il ne s'y effondre pas non plus (aucune cellule où GARCH gagne sur les deux axes à la fois hors ETH-daily W+3), mais il n'y a **aucun test poolé où NsDiff l'emporte**, à aucun horizon, dans aucun régime. C'est cohérent avec le duel CRPS (NOTE_due1_nsdiff.md : « ns 1/5 » contre ARIMA-GARCH aux trois horizons, rejet SPA vs GARCH(1,1) toujours à 0/75) — la conclusion la plus stable du programme reste inchangée.

8. Non-négociables — statut

- **Protocole multi-graines conservé** : toute conclusion de cette note repose sur les 5 graines (42-46), soit en poolé, soit en comptage graine-par-graine. Aucune conclusion n'est tirée d'une graine unique — et §1/§3.1 montrent une fois de plus qu'on aurait conclu à tort en le faisant.
- **Briques réutilisées, pas réimplémentées** : bootstrap par blocs (paired_test), Winkler + skill-score RW + pooling par classe (dashboard_d7_w1), test RMSE par cellule (matrice_paired_tests), recalibration conforme (tsdiff_recalibrate), fit/forecast NsDiff (oos_nsdiff_daily_weekly) — tous **importés et appelés**. Seuls Kupiec, Christoffersen et le TOST sont du code neuf (rien d'équivalent n'existait) : ils vivent dans calibration_tests.py et sont couverts par 19 tests unitaires (cas calculés à la main, entrées dégénérées, invariants).
- **Trois modifications de fichiers partagés, toutes additives et opt-in**, comportement par défaut strictement inchangé : generate_nsdiff_asset(..., collect_samples=False), build_enriched_pairs(..., horizon_unit="W+1"), paired_block_bootstrap_test(..., return_boot_means=False). Le dernier existe parce que le p_value bilatéral renvoyé est plafonné à 1.0 et ne peut donc pas être redivisé en p unilatérale fiable pour le TOST.
- tracking.db **jamais écrit** : lecture seule (origines + lignes ARIMA-GARCH). La piste oos/dashboard reste single-seed 42 et n_samples=50, comparable aux 6 autres modèles — **rien n'y a été touché**. Les chiffres de cette note ne sont donc **pas** ceux du dashboard, par construction (§1).
- **pytest vert** : python -m pytest experiments validation -q → **351 passed, 1 skipped**. Le skip est pré-existant et sans rapport (test_crps_metrics.py:61 – properscoring not installed). La note précédente rapportait 333 passed avant ce chantier ; +19 tests neufs ici.

- **Dépendance ajoutée** : openpyxl (absent du venv, requis par experiments/offline_prices.py pour la source de prix TLT). Il n'est pas dans requirements.txt — à ajouter, hors périmètre de ce brief.

9. Limites déclarées

- **Puissance** : effective_n=30 (90 origines, blocs de 3) pour §1-§4 et §7 ; ≈15 pour §5 (bloc de test seulement). Aucun « indistinguable » de cette note ne doit être lu comme une absence d'effet démontrée — sauf là où le TOST conclut explicitement à l'équivalence (§4), qui est précisément l'énoncé que le reste ne permet pas.
- **Tests multiples non corrigés** : les tableaux comptent beaucoup de cellules (5 actifs × 3 horizons × 2 régimes). Aucune correction de type Holm n'est appliquée — les cases isolées à p≈0.04 (crypto/Winkler à W+3, §3.1) doivent être lues comme telles.
- **Kupiec/Christoffersen** : p-values χ^2 optimistes (violations supposées i.i.d., cibles W+2/W+3 chevauchantes) ; LR_ind mécaniquement biaisé vers le rejet à ces horizons. Rapportés en complément, jamais comme verdict principal — le test de référence reste le bootstrap par blocs.
- **§7** : asymétrie de protocole (refit par origine vs train-once-forward), déclarée plus haut ; GARCH n'ayant pas de graine, la question posée est « un run NsDiff à graine tirée au hasard bat-il GARCH ? », pas « le meilleur NsDiff bat-il GARCH ? ».
- **§1, mécanisme** : l'explication du biais de quantile à 50 tirages est une hypothèse cohérente avec les chiffres, **non testée** (il faudrait balayer n_samples) ; l'effet, lui, est mesuré.
- **Non fait, volontairement** : aucun réentraînement, aucun rejeu du dashboard oos, aucune reprise des 6 autres modèles à 200 tirages (leur comparabilité mutuelle en dépend). Si le dashboard doit un jour refléter §1, c'est un chantier à part — il faudrait régénérer **tous** les modèles au même budget.