

Récapitulatif de session

DeepEdgeBenchmark — suivi de la calibration des PI, coordination avec le travail parallèle du collègue

31 juillet 2026

1 Ce qui a été fait aujourd'hui

Suite directe d'hier (comparaison des options 1/2/3 de calibration, *HANDOFF_dist_options_comparison.md*) et du travail parallèle du collègue, poussé pendant la nuit (adoption d'un σ dynamique EWMA en production pour les 5 modèles, *HANDOFF_sigma_calibration_suivi.md*). La session d'aujourd'hui a porté sur la vérification de ce travail, la correction d'un biais méthodologique trouvé dans mon propre script, et la reprise de deux fils laissés en suspens.

- **Vérifié et intégré le travail du collègue** — reclassement CRPS sous la meilleure option de calibration (aucun changement de rang), puis l'adoption complète du σ EWMA en production.
- **Corrigé un bug d'agrégation dans `summarize_dist_options.py`** — `mace_loose` laissait des écarts de signe opposé s'annuler entre actifs (repéré indépendamment par le collègue) ; ajout de `mace_strict`, la version honnête. Deux verdicts s'en trouvent inversés (LSTM, ARIMA-GARCH).
- **Régénéré et clarifié `comparaison_options_calibration_tous_modeles.pdf`** avec les chiffres corrigés, plus une explication en langage clair de ce que « erreur de calibration » représente (exemple concret à l'appui).
- **Laissé une question écrite pour le collègue sur `calibration/pi_recalibration.py`** — un script orphelin qui recoupe fortement l'adoption EWMA, statut à clarifier avant d'y toucher (*NOTE_question_pi_recalibration.md*, pas encore de réponse).
- **Repris et terminé le fix Prophet D+7/hebdomadaire** — le fit en log-prix était déjà commencé localement (non commité, pas de moi) ; ajout du paramètre `sigma_scale` (même mécanisme que `next_step_prophet` déjà en prod) et de tests dédiés — aucun n'existait avant pour ce module.
- **Étendu l'investigation Prophet du collègue aux 5 actifs** (SPY/BTC seulement avant) — résultats détaillés en §2, nuancent la conclusion « Prophet résolu » d'hier.

2 Résultats — extension de l'investigation Prophet aux 5 actifs

`experiments/prophet_sigma_investigation.py` (script du collègue) teste 6 configurations candidates pour corriger le sous-couvrement massif de Prophet, sur la fenêtre W1 (2020–2024). Jusqu'ici testé sur SPY/BTC seulement — étendu ici à ETH, ZN=F et TLT. Indicateur : erreur de calibration stricte (MACE), moyenne des écarts absolus à 50/80/95 % — 0 = parfait, mêmes conventions que le document de comparaison principal.

Configuration	SPY	BTC	ETH	ZN	TLT	Moyenne
base (référence)	12,8	29,3	34,4	40,5	27,2	28,8
cps_low	32,2	23,2	17,7	37,8	31,0	28,4
cps_high	26,3	27,6	27,8	34,3	31,9	29,6
no_seas	8,2	47,2	39,4	39,6	18,4	30,5

Configuration	SPY	BTC	ETH	ZN	TLT	Moyenne
flat	72,0	57,5	6,3	23,2	22,9	36,4
log (adopté en prod)	4,8	6,5	15,6	35,8	35,8	19,7

MACE stricte (points de %, 0 = parfait) par configuration et par actif, sur la fenêtre W1. Ligne en vert = meilleure moyenne sur les 5 actifs.

Le fix adopté (log-espace) reste le meilleur en moyenne (19,7 contre 28,8 pour la référence non corrigée) — mais il n'aide pas uniformément. Excellent sur SPY (12,8→4,8) et BTC (29,3→6,5), correct sur ETH (34,4→15,6), il ne bouge quasiment pas ZN (40,5→35,8) et fait *pire que ne rien faire* sur TLT (27,2→35,8). Le défaut de production (LOG_SPACE=True en dur pour tous les actifs, `models/prophet_model.py`) a été validé « sur 3 fenêtres × SPY/BTC » selon son propre commentaire — cette limite de périmètre était donc réelle, pas juste une formalité. Logique après coup : le log-prix corrige un problème d'extrapolation agressive du trend sur des séries en forte croissance non stationnaire — SPY/BTC/ETH sont exactement ce cas ; ZN et TLT (taux/obligataire) ont une dynamique de prix très différente, où cette correction n'a pas de raison de s'appliquer de la même façon.

Point important non tranché ici : ce balayage teste le log-espace *seul*, pas la combinaison complète adoptée en production (log + EWMA — la correction EWMA de la phase C de ce script n'est qu'un facteur d'échelle statique appliqué à la configuration *base* non corrigée, pas le mécanisme EWMA réellement adopté). Il est possible que la couche EWMA, dynamique, rattrape une partie du problème sur ZN/TLT là où le log seul ne suffit pas — mais ce test précis (log+EWMA sur les 5 actifs) n'a pas encore été fait.

3 Conclusions mises à jour

- **Le diagnostic général tient toujours** : le problème dominant est presque partout le *niveau* de σ qui doit suivre les régimes de volatilité, pas la forme de la loi — sauf pour ARIMA-GARCH, seul modèle dont le σ était déjà dynamique par construction.
- **« Prophet résolu » doit être nuancé.** Résolu pour les actifs à forte croissance non stationnaire (SPY, BTC, ETH) — pas démontré pour les actifs obligataires (ZN, TLT), où le fix adopté globalement peut activement dégrader la calibration. À vérifier avec log+EWMA combiné avant de considérer le sujet clos sur ces deux actifs — potentiellement besoin d'un traitement différent par classe d'actif plutôt qu'un défaut unique pour tout Prophet.
- **LSTM reste résolu par l'EWMA seule** (pas de réseau à mélange de gaussiennes nécessaire) — confirme que l'abandon du MDN (plus cher, moins bon, instable) était la bonne décision.
- **Calibration et classement global des modèles restent deux axes indépendants** — confirmé par le reclassement CRPS du collègue, aucun changement de rang malgré des gains de calibration nets.

4 Ce qui est exploitable maintenant

- `comparaison_options_calibration_tous_modeles.pdf` — chiffres corrects, à jour, partageable.
- Défauts de calibration EWMA/natifs adoptés en production pour le D+1 des 5 modèles (`models/*.py`).
- Hook `sigma_scale` disponible sur les chemins D+7 et hebdomadaire de Prophet — prêt à être alimenté, pas encore branché en live.
- Détail par actif de l'investigation Prophet (`experiments/prophet_sigma_investigation.json`) — base pour décider d'un traitement différencié ZN/TLT.

5 Reste ouvert

- Tester log+EWMA combiné sur les 5 actifs pour savoir si ZN/TLT sont réellement sauvés par la couche EWMA, ou s'il faut un traitement différent par classe d'actif (§2).
- Réponse du collègue sur `pi_recalibration.py` — toujours en attente.
- Intégration pipeline : alimenter `next_step_prophet(sigma_scale=...)` depuis `tracking.db` en production (HANDOFF_sigma_calibration_suivi.md §8.1).
- ARIMA-GARCH/SARIMA/Naive dans `benchmarks/multi_horizon.py` utilisent toujours un `Z_95` normal fixe pour le D+7 — non traité (hors périmètre de ce qui a été demandé aujourd'hui).

Fichiers touchés aujourd'hui : `summarize_dist_options.py`, `generate_dist_options_report.py`, `generate_dist_options_pdf.py`, `benchmarks/multi_horizon.py`, `experiments/weekly_multimodel.py`, `benchmarks/test_multi_horizon.py` (nouveau), `experiments/prophet_sigma_investigation.json`, `NOTE_question_pi_recalibration.md` (nouveau).