

Reclassement CRPS sous la meilleure option de calibration

Referme le point ouvert §6 de *Synthese_Calibration_Distributions_PI.pdf*

DeepEdgeBenchmark
30 juillet 2026

1 Question

Le document de synthèse précédent laissait un point ouvert : la calibration des intervalles s'améliore nettement pour 3 modèles sur 5 en changeant de loi (§5.1), mais le classement CRPS global n'avait jamais été recalculé avec cette meilleure option — seulement comparé à distribution inchangée. **Corriger la calibration change-t-il le classement des modèles ?**

2 Méthode

Pour chaque modèle, le facteur de correction CRPS réel (par actif) apporté par sa meilleure option de calibration a été extrait des données déjà produites (*all_models_dist_options_results.json*), puis appliqué aux CRPS empiriques déjà mesurés sur le benchmark live (*CRPS gaussien vs empirique*, 24 juillet 2026). Le rang par actif et le rang moyen sur les 5 actifs ont ensuite été recalculés.

Modèle	Meilleure option retenue	Effet sur le CRPS
ARIMA-GARCH	Student-t (manuel)	−0,2 à −1,8% selon l'actif
SARIMA	GED	−0,3 à −3,6% selon l'actif
Naive	GED	−0,3 à −5,1% selon l'actif
Prophet	Aucune (CQR aide la calibration mais n'a pas de CRPS défini)	Inchangé
LSTM	Aucune (le normal est déjà la meilleure option)	Inchangé
TSDiff	Hors périmètre de cette comparaison	Inchangé

Aucune correction n'a été appliquée à CQR (pas de CRPS défini pour cette option) ni au refit natif GARCH (jugé non rentable, cf. §5.1 du document précédent).

3 Résultat

Modèle	Rang moyen avant	Rang moyen après (meilleure option)
ARIMA-GARCH	1,20	1,20
SARIMA	1,80	1,80
Naive	3,20	3,20
TSDiff	3,80	3,80
LSTM	5,00	5,00
Prophet	6,00	6,00

Le classement ne bouge pas, sur aucun des 5 actifs, dans aucun sens. Corriger la calibration de SARIMA, Naive et ARIMA-GARCH ne change ni leur position relative entre eux, ni face à TSDiff, LSTM ou Prophet.

4 Pourquoi

Les corrections de CRPS apportées par la meilleure loi sont faibles (0,2 à 5% selon l'actif et le modèle), alors que les écarts *entre* modèles sont massifs : Prophet est 5 à 100× pire que le trio de tête selon l'actif, LSTM 2 à 3× pire. Une correction de quelques pourcents ne peut pas combler un tel écart. Cela confirme ce qui avait déjà été établi : calibration et classement CRPS global sont deux axes indépendants — l'un mesure si l'intervalle promis est honnête, l'autre si le pari (point + distribution) est globalement bon. Corriger le premier n'a pas à déplacer le second, et c'est exactement ce qui est observé ici.

5 Réserve méthodologique

Cette vérification applique un facteur de correction calculé sur la fenêtre de backtest historique (2020–2024) à des CRPS mesurés sur la fenêtre de suivi live récente (2026) — deux fenêtres différentes, pas un recalcul complet sur la même fenêtre. L'écart entre les corrections observées (quelques %) et les écarts entre modèles (souvent >100%) est cependant assez large pour que cette approximation ne remette pas en cause la conclusion. Un rerun complet sur la fenêtre live confirmerait le résultat mais n'est pas jugé nécessaire au vu de cette marge.

6 Détail — couverture à 50% et 95%, par actif et par loi

Repris à la demande initiale : couverture empirique mesurée aux niveaux 50% (centre, cible 0,50) et 95% (queues, cible 0,95), pour chaque modèle, chaque actif, et chaque loi testée (fenêtre d'évaluation du protocole §4, cf. document principal). Chaque cellule lit « 50 / 95 » (couverture mesurée en %, cible 50,0 / 95,0).

SPY

Modèle	Normal	Student-t	GED	CQR
ARIMA-GARCH	62.0 / 93.8	62.0 / 93.8	62.8 / 93.8	63.7 / 95.6
SARIMA	53.1 / 90.3	47.8 / 91.2	49.6 / 92.9	46.9 / 87.6
Naïve	57.5 / 90.3	46.0 / 90.3	48.7 / 92.9	46.9 / 88.5
Prophet	39.8 / 85.0	39.8 / 85.0	39.8 / 82.3	46.0 / 95.6
LSTM	34.5 / 82.3	31.0 / 82.3	31.0 / 82.3	32.7 / 86.7

BTC-USD

Modèle	Normal	Student-t	GED	CQR
ARIMA-GARCH	62.2 / 95.7	54.3 / 95.7	56.1 / 96.3	53.7 / 96.3
SARIMA	43.9 / 83.5	40.9 / 84.2	37.8 / 84.2	46.3 / 95.7
Naïve	43.9 / 82.9	39.0 / 82.9	36.6 / 83.5	50.0 / 95.1
Prophet	27.4 / 66.5	27.4 / 66.5	28.7 / 66.5	32.3 / 72.6
LSTM	32.3 / 72.0	29.9 / 74.4	28.7 / 75.0	45.1 / 89.6

ETH-USD

Modèle	Normal	Student-t	GED	CQR
ARIMA-GARCH	62.8 / 93.3	44.5 / 92.1	45.1 / 96.3	48.8 / 93.9
SARIMA	54.3 / 90.2	45.7 / 90.2	44.5 / 91.5	48.8 / 95.7
Naïve	56.7 / 90.8	45.7 / 90.8	43.9 / 91.5	49.4 / 95.7
Prophet	21.3 / 61.6	21.3 / 61.6	23.2 / 57.3	25.0 / 64.6
LSTM	47.0 / 85.4	35.4 / 85.4	34.8 / 87.8	43.9 / 97.0

ZN=F

Modèle	Normal	Student-t	GED	CQR
ARIMA-GARCH	51.3 / 93.8	47.8 / 93.8	47.8 / 93.8	52.2 / 98.2
SARIMA	65.5 / 98.2	59.3 / 98.2	61.1 / 98.2	60.2 / 98.2
Naïve	68.1 / 98.2	60.2 / 98.2	63.7 / 98.2	63.7 / 98.2
Prophet	10.6 / 63.7	10.6 / 63.7	10.6 / 63.7	11.5 / 76.1
LSTM	54.0 / 96.5	50.4 / 96.5	54.9 / 96.5	55.8 / 98.2

TLT

Modèle	Normal	Student-t	GED	CQR
ARIMA-GARCH	53.1 / 95.6	53.1 / 95.6	55.8 / 95.6	55.8 / 96.5
SARIMA	70.8 / 99.1	52.2 / 98.2	63.7 / 99.1	58.4 / 96.5
Naive	77.9 / 99.1	52.2 / 98.2	59.3 / 100.0	55.8 / 96.5
Prophet	22.1 / 75.2	21.2 / 75.2	24.8 / 69.0	41.6 / 79.7
LSTM	56.6 / 98.2	35.4 / 97.3	38.0 / 100.0	38.0 / 95.6

ARIMA-GARCH — rappel du refit natif GARCH (non retenu, cf. §5.1 du document principal) : couverture 50/95 sous *native_ged* et *native_skewt*.

Actif	<i>native_ged</i> (50/95)	<i>native_skewt</i> (50/95)
SPY	58.4 / 92.9	59.3 / 91.2
BTC-USD	53.7 / 97.0	52.4 / 95.7
ETH-USD	51.8 / 95.1	52.4 / 94.5
ZN=F	46.0 / 93.8	46.9 / 93.8
TLT	52.2 / 94.7	52.2 / 94.7

Lecture

Prophet est hors calibration à 50% quelle que soit la loi, sur tous les actifs (10,6% à 41,6% observé contre 50% visé — GED et Student-t ne bougent presque rien : 39,8→39,8 sur SPY, 10,6→10,6 sur ZN=F). C'est la preuve directe, actif par actif, que son défaut est un σ trop petit, pas une mauvaise forme de queue — aucune loi ne peut compenser une largeur d'intervalle fondamentalement insuffisante.

Le swap manuel dégrade nettement LSTM sur les actifs volatils : cov 50% chute de 46,9% (normal) à 34,8–35,4% (Student-t/GED) sur ETH-USD, et de 56,6% à 35,4–38,1% sur TLT — cohérent avec le diagnostic « σ figé, jamais recalculé » du document principal.

La sur-couverture au centre est la plus marquée sur les actifs calmes : Naive atteint 77,9% de couverture à 50% sous loi normale sur TLT (cible 50%), et SARIMA 70,8% — le pire écart mesuré ici, bien au-delà des 56–66% observés sur les actifs plus volatils. GED et Student-t corrigent une bonne partie de cet excès (Naive TLT : 77,9→59,3 sous GED, →52,2 sous Student-t) sans jamais tout à fait atteindre la cible.

CQR pousse presque systématiquement la couverture à 95% au niveau ou au-dessus de la cible (95,6 à 98,2% selon l'actif pour ARIMA-GARCH, jusqu'à 96,9% pour LSTM sur ETH-USD) — cohérent avec le constat du document principal : jamais catastrophique, mais systématiquement un peu large aux extrêmes.

Le refit natif GARCH ne bat pas le swap manuel sur la couverture non plus : les deux colonnes ci-dessus sont proches, parfois légèrement en-dessous des variantes manuelles (*native_ged*/*native_skewt*) — un argument de plus, en complément du coût 800× supérieur déjà documenté, pour ne pas l'adopter.