

RÉSUMÉ — NsDiff : valeur économique, re-cadrage 200 tirages, cadrage monthly

2026-08-07. Synthèse du chantier répondant au brief « NsDiff : valeur économique, re-cadrage 200 tirages, cadrage monthly ». Ce document est une **vue** de NOTE_nsdiff_backtest_eco_et_recadrage.md, qui reste la source de vérité et contient le détail complet, les protocoles et les limites.

1. Le résultat, en une phrase

La configuration qu'on déploierait n'est plus battue par ARIMA-GARCH — et elle ne le bat pas non plus, ni en calibration, ni en argent, ni sur les scénarios de trajectoires. Le programme se termine sur une parité, pas sur une victoire.

Chantier	Question	Réponse
A1 re-cadrage	la piste OOS est-elle encore comparable ?	non — 1 seul modèle sur 7 était concerné (NsDiff) ; base repointée sur 200 tirages
A2 config production	la config qu'on déploierait bat-elle GARCH ?	elle fait jeu égal : 0 défaite sur 12 tests poolés, contre 6 sur 12 pour une graine unique
A3-ii cadence de refit	l'asymétrie de protocole expliquait-elle l'écart ?	non — $\times 24,6$ en coût de calcul ne déplace aucun verdict
B valeur économique	NsDiff apporte-t-il de l'argent au-delà de GARCH ?	non — 0 résultat survit à Holm dans les 9 familles de décision
B3 scénarios	la diffusion se différencie-t-elle par la trajectoire ?	non — et sur le pricing d'option, GARCH gagne 7 cellules sur 10
C monthly	le régime mensuel est-il faisable ?	NO-GO pour les 3 voies — mais à une observation près (§4)

Ce qui a changé en base : 2 700 lignes NsDiff repointées de 50 à 200 tirages (couverture 0,909 $\rightarrow$ 0,9315), sauvegarde horodatée prise avant écriture. TSDiff retiré du benchmark. **453 tests passent** (365 avant le chantier, +88 neufs).

2. Zoom n° 1 — les deux cas qui « ne survivent pas à Holm »

2.1 Pourquoi une correction, et laquelle

Le chantier B teste beaucoup : 3 stratégies $\times$ 3 horizons $\times$ 2 régimes $\times$ 3 niveaux de coût, et pour chacun plusieurs bras. À un seuil de 5 % sans correction, on attend **un faux positif toutes les 20 cases** — c'est-à-dire, sur une famille de 6 tests, une chance sur quatre d'en voir au moins un « significatif » alors que rien n'est vrai.

La correction retenue est **Holm-Bonferroni**, déclarée avant les runs. Elle fonctionne en **descente** : on trie les p-values croissantes, on compare la plus petite au seuil le plus strict α/m , la deuxième à $\alpha/(m-1)$, etc., et **on s'arrête au premier échec** — tout ce qui suit tombe avec lui, même si sa propre p-value passerait son propre seuil.

Famille déclarée : les 6 tests poolés globaux (3 horizons $\times$ 2 régimes) d'un même match et d'une même métrique. Seuil le plus strict : $0,05 / 6 = \mathbf{0,00833}$.

Deux familles du chantier B ont produit des résultats bruts significatifs. Ni l'une ni l'autre ne survit — et les deux échouent **dès le premier rang**.

2.2 Cas n° 1 — le bootstrap apparié sur var_limit

Stratégie de limite de risque, bras « graine tirée au hasard » contre GARCH. Deux cellules sur six ressortent significatives en brut.

Rang	Cellule	p brute	Seuil de son rang	Verdict brut	p ajustée	Verdict Holm
1	weekly W+3	0,0354	0,00833	NsDiff meilleur	0,2124	indistinguishable

Rang	Cellule	p brute	Seuil de son rang	Verdict brut	p ajustée	Verdict Holm
2	weekly W+2	0,0482	0,01000	NsDiff meilleur	0,2410	indistinguable
3	weekly W+1	0,0844	0,01250	indistinguable	0,3376	indistinguable
4	daily W+1	0,2834	0,01667	indistinguable	0,8502	indistinguable
5	daily W+2	1,0000	0,02500	indistinguable	1,0000	indistinguable
6	daily W+3	1,0000	0,05000	indistinguable	1,0000	indistinguable

Lecture : la plus petite p-value de la famille vaut 0,0354, contre un seuil de 0,00833 — un facteur **4,2** au-dessus. La procédure s'arrête au rang 1 et rien ne passe. La plus petite p ajustée de la famille est **0,21**.

Et l'ordre de grandeur confirme : sur les deux cellules significatives, l'écart moyen de PnL vaut **+3,3 et +4,9 points de base par origine** en faveur de NsDiff (+2,4 sur la troisième cellule weekly, non significative). Au niveau de coût central, un aller-retour coûte 10 bps sur SPY et **60 bps sur la crypto**. L'avantage détecté, à supposer qu'il soit réel, est un **ordre de grandeur sous les frais**.

2.3 Cas n° 2 — le test SPA de Hansen sur var_limit

Le SPA (`mcs.spa_test`, déjà dans le repo) est **unilatéral** et recentré : il est plus puissant qu'un bootstrap bilatéral pour détecter un petit avantage systématique. Il trouve, lui, **trois** cellules — toutes en weekly.

Rang	Cellule	p SPA brute	Seuil de son rang	p ajustée	Gain moyen par origine
1	weekly W+1	0,0332	0,00833	0,1992	+2,2 bps
2	weekly W+2	0,0406	0,01000	0,2030	+3,2 bps
3	weekly W+3	0,0482	0,01250	0,2030	+4,3 bps
4	daily W+2	0,3678	0,01667	1,0000	+0,9 bps
5	daily W+3	0,3962	0,02500	1,0000	+0,7 bps
6	daily W+1	1,0000	0,05000	1,0000	-1,3 bps

Même mécanique : plus petite p = 0,0332 contre un seuil de 0,00833, arrêt au rang 1, **0 survivant sur 6**.

Le SPA a été soumis à Holm comme le reste, et c'est un choix. L'en exempter au motif qu'il est « le test le plus adapté » reviendrait à se réserver le test le plus favorable après avoir vu les résultats — exactement ce que la correction existe pour empêcher.

2.4 Ce que « ne survit pas à Holm » veut dire, et ne veut pas dire

- **Ce que ça veut dire** : le motif observé est compatible avec le hasard, une fois pris en compte le nombre de tests effectués. Il ne fonde pas une décision.
- **Ce que ça ne veut PAS dire** : que l'effet est nul. À `effective_n` = 30, la puissance est faible ; un vrai avantage de 3 bps par origine serait indétectable ici quoi qu'il arrive.
- **Ce qui tranche vraiment, dans ce cas précis** : la **taille de l'effet**, pas la p-value. 2 à 5 bps par origine face à 10–60 bps de frais aller-retour : le signal, réel ou non, n'est pas exploitable.

Bilan des 9 familles de décision du chantier B : 5 rejets bruts au total, **0 survivant**.

3. Zoom n° 2 — « ne bat pas acheter-et-garder » : ce que ça signifie exactement

3.1 Ce qui a été testé

24 tests appariés (2 stratégies actives × 3 horizons × 2 régimes × 2 modèles), bootstrap par blocs sur les différences de PnL par origine. **Aucun ne rejette l'égalité** : p de **0,25 à 1,00**. « Ne bat pas » signifie donc littéralement « *aucun test ne permet de conclure à une différence de PnL* » — et non « *fait moins bien* ». La nuance est importante, parce que le

tableau descriptif raconte autre chose.

3.2 Le tableau descriptif — et il n'est pas défavorable

Niveau de coût central, bras NsDiff-ensemble contre acheter-et-garder :

Cellule	Stratégie	PnL stratégie	PnL B&H	Sharpe stratégie	Sharpe B&H	Drawdown strat.	Drawdown B&H
weekly W+1	var_limit	−0,047	−0,230	−0,40	−0,49	−0,103	−0,503
daily W+1	var_limit	−0,067	−0,230	−0,48	−0,49	−0,133	−0,503
weekly W+2	var_limit	+0,012	−0,073	+0,06	−0,07	−0,127	−0,796
daily W+2	var_limit	−0,002	−0,073	−0,01	−0,07	−0,142	−0,796
weekly W+3	var_limit	+0,056	+0,105	+0,23	+0,07	−0,147	−1,067
daily W+3	var_limit	+0,032	+0,105	+0,11	+0,07	−0,175	−1,067

Sur le papier, var_limit a un **meilleur Sharpe que B&H dans les 6 cellules** et un **drawdown 3,8 à 7,3 fois plus faible**. Pourquoi n'est-ce pas présenté comme une victoire ?

3.3 Les trois raisons de ne pas surinterpréter ce tableau

(a) **La réduction de drawdown est en grande partie mécanique.** var_limit dimensionne sa position pour que la VaR à 2,5 % vaille 3 % du capital : elle n'est donc **pas pleinement investie**. Exposition moyenne |w| :

Cellule	var_limit	inverse_width	acheter-et-garder
W+1	0,60 – 0,66	0,84 – 0,87	1,00
W+2	0,49 – 0,55	0,85 – 0,88	1,00
W+3	0,44 – 0,49	0,85 – 0,88	1,00

Et le détail par actif est encore plus net (var_limit, weekly W+1) : sur la crypto, l'exposition tombe à **0,16 sur ETH** et **0,23 sur BTC**, contre 0,81 sur SPY et 1,00 sur ZN=F. Or c'est précisément la crypto qui a chuté sur la période (B&H : −0,46 sur BTC, −0,55 sur ETH). **Être trois quarts hors du marché sur l'actif qui s'effondre réduit mécaniquement la perte et le drawdown** — ce n'est pas la preuve d'un signal, c'est la conséquence arithmétique d'une exposition plus faible.

(b) **Le Sharpe, lui, est sans échelle — mais il n'est pas la quantité testée.** Le Sharpe corrige de l'exposition, et il reste favorable à var_limit. C'est le point le plus solide en faveur de la stratégie. Mais le test porte sur les **différences de PnL par origine**, et à effective_n = 30, il n'a pas la puissance de certifier un écart de Sharpe de cet ordre. Affirmer « var_limit bat B&H » sur la base d'un Sharpe descriptif non testé serait exactement le genre de raccourci que le reste du programme s'interdit.

(c) **inverse_width ne bénéficie d'aucune de ces excuses — et détruit de la valeur.** Elle est investie à ~85 %, donc comparable à B&H, et malgré cela : **11 séries de PnL négatives sur 12, 8 pires que B&H sur 12**, un taux de gain de 42–47 % (soit sous le pile ou face), et un Sharpe négatif dans 6 cellules sur 6. Le proxy de confiance « 1/largeur du PI » n'est informatif **ni pour NsDiff ni pour GARCH**. C'est le résultat le plus net du chantier B, et il est négatif pour les deux modèles.

3.4 La formulation juste

*Sur la période et le panier testés, aucune des stratégies dérivées des intervalles ne dégage un PnL statistiquement distinguable de celui d'acheter et garder. var_limit présente un profil risque/rendement descriptivement meilleur, largement attribuable à une exposition moyenne de 44–66 % ; inverse_width détruit de la valeur à exposition comparable. **Aucun des deux modèles ne se distingue de l'autre sur aucune de ces stratégies.***

3.5 Le cas à part : la famille 3 ne prend jamais position

La troisième famille du brief — « prendre position seulement si le PI exclut le rendement nul » — donne un résultat en apparence dégénéré et en réalité très informatif : sur **2 700 origines**, pour **les deux modèles**, aux trois horizons, **zéro position ouverte**. Un intervalle à 95 % contient *toujours* le prix courant à ces horizons.

La question du brief — « des intervalles honnêtes filtrent-ils mieux les faux signaux ? » — reçoit donc une réponse nette : **à 95 %, aucun des deux modèles n'émet jamais de signal**. Rejouer à un niveau plus étroit exigerait de choisir un seuil après avoir vu ce résultat ; non fait, délibérément.

4. Zoom n° 3 — le NO-GO monthly, critère par critère

4.1 Les deux critères, déclarés avant tout résultat

1. **Couverture** : la couverture observée à 95 % doit tomber dans **[0,90 ; 0,98]** — à **chacun** des trois horizons, pas en moyenne ; 2. **Winkler** : le score composite ne doit pas être **significativement pire** que celui de la baseline garch_monthly (bootstrap par blocs, 5 %).

Une voie qui échoue à l'un des deux est NO-GO. Les deux critères ont été fixés dans le module avant le premier fit.

4.2 Le problème de fond : le nombre de fenêtres, pas d'observations

Actif	Quotidiennes	Hebdo	Mensuelles	Fenêtres d'entraînement (seq_len = 30)
SPY	2 905	604	139	70 (×8,0 de moins qu'en hebdo)
BTC-USD	4 222	604	139	70 (×8,0)
ZN=F	2 905	604	139	70 (×8,0)
ETH-USD	3 179	455	105	36 (×11,4)
TLT	2 121	441	102	33 (×12,0)

À seq_len = 30, le lookback consomme 30 des ~100 rendements disponibles. Sur ETH et TLT, un modèle d'incertitude voit littéralement **une trentaine d'exemples**. Le budget d'entraînement devient le levier dominant — et le sweep le confirme brutalement : à 40 époques, la voie native produit une bande de **81 % du prix** et couvre 100 % ; à 160 époques, **32 %** et 94 %. Sous-entraîné, le modèle ne sait rien faire d'autre qu'élargir.

Note de protocole : un premier passage sur (20, 40, 80) époques a placé l'optimum **au bord** de la grille. Une grille dont l'argmin est sur sa borne est une troncature, pas une sélection : elle a été élargie **une fois** à (20, 40, 80, 160, 320), sur la **validation**, avant tout regard sur le test.

4.3 Le verdict, voie par voie

Voie	Config retenue	Cov95	Largeur (% prix)	Winkler	RMSE	CRPS	Verdict
garch_monthly (baseline)	refit / origine	0,944	22,00	152,7	31,17	—	—
monthly_native	seq_len 12, 160 ép.	0,926	22,67	154,5	31,34	17,73	NO-GO
weekly_propagated	seq_len 30, 160 ép.	0,898	21,79	170,9	31,42	18,83	NO-GO
synthetic_augmented	seq_len 30, 40 ép.	0,852	20,57	214,0	34,48	19,27	NO-GO

Détail horizon par horizon (✓ = critère tenu, ✗ = échoué) :

Voie	M+1	M+2	M+3
monthly_native	cov 0,917 ✓ — Winkler ✓	cov 0,889 ✗ — Winkler ✓	cov 0,972 ✓ — Winkler ✓

Voie	M+1	M+2	M+3
weekly_propagated	cov 0,861 ✗ — Winkler ✓	cov 0,861 ✗ — Winkler ✓	cov 0,972 ✓ — Winkler ✓
synthetic_augmented	cov 0,861 ✗ — Winkler ✓	cov 0,861 ✗ — Winkler ✗ (p = 0,0074)	cov 0,833 ✗ — Winkler ✗ (p = 0,0006)

4.4 Les trois NO-GO ne se valent pas du tout

monthly_native **échoue d'une seule observation**. Sa seule case hors bande est M+2 à 0,889 contre une borne à 0,90. Sur 36 origines, cela fait **32 succès au lieu de 33** : une observation. Sur tous les autres axes, la voie native fait jeu égal avec GARCH-monthly — Winkler 154,5 contre 152,7, RMSE 31,34 contre 31,17, et **jamais significativement pire à aucun horizon** (p = 0,899 / 0,412 / 1,000).

Le critère a été fixé a priori et il est appliqué tel quel — mais présenter ce NO-GO comme un rejet net serait malhonnête. **L'énoncé exact est** : à effective_n = 12, le pilote ne permet pas de conclure au go, et il n'en est pas loin.

weekly_propagated **échoue vraiment**. Propager le nuage hebdomadaire jusqu'à la cible mensuelle sous-couvre franchement à M+1 et M+2 (0,861 des deux côtés) et paie **12 % de Winkler de plus** que la voie native. Le modèle hebdomadaire est entraîné à un horizon de 3 semaines et se retrouve étiré à 13 pas : il ne transporte pas correctement l'incertitude sur cette distance. Cette voie est **dominée par la voie native sur les quatre métriques** — à abandonner.

synthetic_augmented **est la seule à dégrader activement**. Elle est significativement **pire** que GARCH-monthly à M+2 et M+3, sous-couvre partout (0,833 – 0,861) et a le plus mauvais RMSE du lot. L'explication est structurelle, et elle était déclarée dans le module **avant** le run : une série KernelSynth est tirée d'un processus gaussien à covariance fixe. Elle apporte de la **diversité de formes** — tendances, cycles, ruptures de corrélation — mais elle est **homoscédastique par construction** : ni queues lourdes, ni clustering de volatilité, ni asymétrie. Entraîner un modèle d'incertitude sur 5 fenêtres synthétiques homoscédastiques pour 1 fenêtre réelle **lui apprend à ne pas voir la volatilité changer**.

La condition posée par le brief (« si (i) sous-entraîne ») était bien remplie ; **le remède proposé ne marche pas** — et il échoue pour une raison qu'on peut nommer, pas par accident.

4.5 Conséquence et suite

Le brief déclarait un critère d'arrêt : « si B conclut "aucune valeur économique ajoutée, aucune différenciation scénarios", le chantier C perd sa justification ». **B conclut exactement cela**. Le chantier C a néanmoins été mené jusqu'à son verdict — il tournait en parallèle, et une étude de faisabilité arrêtée avant sa conclusion ne vaut rien. Les deux convergent : **le mensuel sort du périmètre NsDiff**.

Si on y revenait un jour, par rendement attendu décroissant :

- refaire le pilote sur les **5 actifs** — le NO-GO tient à une observation sur un seul actif, cinq pilotes donneraient une base de décision réelle ;
- élargir encore la grille d'époques vers le haut : la courbe de CRPS n'a été explorée qu'une fois au-delà de 80 ;
- abandonner weekly_propagated (dominée) et remplacer KernelSynth par un générateur à **volatilité stochastique**, seule façon de corriger le défaut identifié en §4.4.

5. Ce qu'il faut retenir

1. **Le re-cadrage était nécessaire mais petit** : un modèle sur sept, pas sept. Le chiffrer avant de l'exécuter a évité un chantier inutile. 2. **L'ensemble multi-graines est la seule amélioration gratuite du programme** : il fait passer NsDiff de 6 défaites sur 12 à 0 sur 12 contre GARCH, sans un seul fit supplémentaire. 3. **Les explications alternatives ont été éliminées une à une** : ni la fraîcheur du fit (A3-ii, ×24,6 en coût pour rien), ni la structure jointe des trajectoires (B3) n'expliquent l'absence d'avantage. 4. **La valeur économique différentielle n'existe pas à ce jour** — et le peu qui ressort en brut est un ordre de grandeur sous les frais de transaction. 5. **Le mensuel est hors périmètre**, mais la voie native mérite d'être rejugée sur cinq actifs avant d'être classée définitivement.

Source de vérité : NOTE_nsdiff_backtest_eco_et_recadrage.md. Artefacts JSON reproductibles dans experiments/. Tout chiffre de ce résumé a été revérifié contre les JSON produits par les runs.