

Calibration des intervalles de confiance : gaussienne vs alternatives

Synthèse de session — d'où vient le problème, ce qui a été testé, ce qui reste ouvert

DeepEdgeBenchmark
30 juillet 2026

1 Management summary

- Les intervalles de confiance de 4 des 5 modèles classiques reposent sur une hypothèse gaussienne. La calibration mesurée montre un défaut systématique : intervalle trop large au centre (50%), trop étroit aux extrêmes (95%) — la signature des *queues épaisses* des rendements financiers.
- Trois pistes de correction ont été testées en comparaison (rien n'est en production) : changer la famille de loi (Student-t/GED/skew-t), recalibrer après coup par *conformal prediction* (CQR), ou apprendre la forme via un réseau à mélange de gaussiennes (MDN, LSTM seul).
- **Le changement de loi corrige le défaut de calibration à moindre coût pour 3 modèles sur 5** (SARIMA, Naive, ARIMA-GARCH : -69 à -79% d'erreur de calibration, pour un surcoût de calcul négligeable). Il ne corrige rien pour Prophet (le problème est ailleurs) et dégrade LSTM.
- **Ce résultat ne contredit pas le classement global des modèles**, qui reste dominé par la qualité du pari directionnel plutôt que par la forme de la distribution — un point clé détaillé en §5, qui répond à l'apparent paradoxe « la gaussienne semble globalement meilleure ».
- Aucune décision de mise en production n'a encore été prise : c'est un travail de comparaison, pas un déploiement (cf. §6).

2 Point de départ : les modèles et la problématique

Le benchmark compare 6 modèles de prévision de prix (ARIMA-GARCH, SARIMA, Prophet, LSTM, Naive, TSDiff) sur 5 actifs (SPY, BTC-USD, ETH-USD, ZN=F, TLT). Chaque modèle doit produire, en plus d'une prédiction ponctuelle, un intervalle de confiance (50/80/95%) censé refléter honnêtement son incertitude.

Cinq des six modèles construisent cet intervalle en supposant, implicitement ou explicitement, une **forme gaussienne** : trois s'appuient sur une véritable librairie statistique dont l'ajustement suppose un bruit gaussien (ARIMA-GARCH via *arch*, SARIMA via *statsmodels*, Prophet via son modèle bayésien interne) ; deux (LSTM, Naive) appliquent une formule manuelle « prédiction $\pm 1,96 \times$ écart-type » sans aucune librairie. Seul TSDiff échappe entièrement à cette hypothèse : il tire un nuage de trajectoires simulées, sans forme présupposée.

La question de départ : la calibration mesurée sur le benchmark (couverture réelle des intervalles à 50/80/95% face aux cibles) a révélé un motif systématique sur les quatre modèles gaussiens à σ analytique : l'intervalle couvre **plus** que promis au centre (50% visé, 0,57 à 0,66 observé — trop prudent) et **moins** que promis aux extrêmes (95% visé, 0,93 à 0,94 observé — trop confiant). C'est exactement la signature empirique des queues épaisses (excès de kurtosis) des rendements

financiers : les mouvements extrêmes du marché sont plus fréquents que ce qu'une gaussienne budgète. D'où la question posée : une loi à queues plus épaisses corrigerait-elle ce défaut, et à quel coût ?

3 Les options envisagées

Trois pistes ont été identifiées, classées par effort d'implémentation croissant :

Option	Principe	Effort
1 — Loi paramétrique alternative	Remplacer la forme gaussienne par une autre famille toujours supposée a priori, mais avec un paramètre de forme en plus : Student-t (queues plus épaisses), GED (aplatissement indépendant des queues), skew-t (+ asymétrie).	Quasi gratuit pour ARIMA-GARCH (paramètre natif de la librairie arch) ; swap manuel pour les autres.
2 — Conformal prediction (CQR)	Ne suppose aucune forme : recalibre après coup l'intervalle de n'importe quel modèle existant sur un jeu de calibration séparé, pour garantir empiriquement la couverture visée.	Modéré — une couche additionnelle par-dessus les modèles existants, sans les retoucher.
3 — Mixture density network (MDN)	Sortie = plusieurs composantes gaussiennes pondérées, apprises des données plutôt que choisies a priori — forme flexible, potentiellement asymétrique ou bimodale.	Plus coûteux — nouvelle tête de sortie et nouvelle fonction de perte (LSTM uniquement).

Recommandation initiale (avant test) : tester l'option 1 en premier vu son coût quasi nul, garder la CQR comme filet de sécurité si l'option 1 ne suffit pas, et ne considérer le MDN qu'en dernier recours vu son coût plus élevé.

4 Les tests faits

Étape 1 — validation rapide de l'option 1 sur un seul modèle. Avant d'investir dans une comparaison complète, l'option 1 a d'abord été testée seule sur ARIMA-GARCH (2 actifs, BTC-USD et SPY) : c'est le changement le moins cher à essayer (un seul paramètre de la librairie déjà utilisée), donc le candidat naturel pour vérifier rapidement si l'hypothèse « la forme de la queue est le problème » tient la route avant d'étendre l'effort.

Étape 2 — extension à tous les modèles et à toutes les options. Le résultat positif de l'étape 1 a justifié d'étendre la comparaison aux 5 modèles classiques, et d'ajouter les options 2 (CQR, choisie comme filet de sécurité indépendant de la forme) et 3 (MDN, réservée à LSTM car c'est le seul modèle dont le défaut de calibration a une cause structurelle — un σ figé, jamais recalculé — qu'une forme apprise pourrait en théorie corriger).

Protocole retenu : chaque modèle est réévalué via son propre backtest walk-forward existant, non modifié. La fenêtre de test est séparée chronologiquement en une fenêtre de calibration (40%, sert à ajuster les lois alternatives et les scores de conformité, jamais notée) et une fenêtre d'évaluation (60%, seule fenêtre servant au calcul des indicateurs). L'indicateur principal de comparaison est l'**erreur de calibration** : la moyenne des écarts absolus entre couverture mesurée et couverture cible sur les trois niveaux (50/80/95%), moyennée sur les 5 actifs — 0 = parfaitement calibré. Le surcoût

de calcul de chaque option est aussi mesuré, rapporté au coût du backtest de base du modèle.

Ce qui n'a pas été fait : aucune option testée n'a été branchée dans le code de production des modèles (à l'exception d'ARIMA-GARCH, qui avait déjà reçu le paramètre de loi lors d'une étape antérieure) — c'est un travail de comparaison, pas un déploiement.

5 Résultats

5.1 Calibration des intervalles : verdict par modèle

Modèle	Erreur avant	Meilleure option	Erreur après	Δ	Verdict
SARIMA	4,56	CQR / GED	1,08	−76%	Vaut le coût — quasi gratuit
Naive	5,32	GED	1,10	−79%	Vaut le coût — quasi gratuit
ARIMA-GARCH	4,32	Student-t (manuel)	1,32	−69%	Égale le refit natif, 800× moins cher
Prophet	28,08	Aucune ne suffit	20,59	−27%	Problème de σ , pas de loi
LSTM	6,77	Aucune à adopter	6,89	+2%	Le swap manuel dégrade

Erreur de calibration en points de pourcentage (0 = parfait), moyennée sur 5 actifs. Le gain est net et quasi gratuit partout où le problème diagnostiqué était bien la *forme* de la queue (SARIMA, Naive, ARIMA-GARCH). Il ne l'est pas quand le problème est ailleurs : Prophet sous-couvre massivement à tous les niveaux (σ structurellement trop petit — changer la forme de la queue autour d'un σ déjà trop petit ne le rend pas plus grand) ; LSTM a un σ unique figé sur les résidus d'entraînement, jamais recalculé dans le temps — lui changer la forme de queue peut activement *dégrader* la calibration (6,77 → 11,25 sous Student-t seul). La CQR est l'option la plus universellement sûre (jamais catastrophique) mais pas toujours la plus précise face à un bon fit paramétrique, et systématiquement un peu plus large à 95%. Le MDN n'est pas rentable en l'état (erreur moyenne 9,23 contre 6,77 pour le LSTM de production, +23% de temps d'entraînement, instabilité forte d'un entraînement à l'autre).

5.2 Le classement global des modèles (CRPS) ne bouge pas — et ce n'est pas contradictoire

En parallèle, une comparaison indépendante a confronté le CRPS gaussien (forme fermée) au CRPS empirique (nuage de scénarios) sur les 6 modèles. Le classement global est resté stable :

Modèle	Rang moyen (CRPS gaussien)	Rang moyen (CRPS empirique)
ARIMA-GARCH	2,2	1,2
SARIMA	2,4	1,8
Naive	1,8	3,2
TSDiff	3,6	3,8
LSTM	5,0	5,0
Prophet	6,0	6,0

Naive, ARIMA-GARCH et SARIMA dominent dans les deux cas ; TSDiff (le seul modèle véritablement non gaussien) reste au milieu du tableau ; Prophet et LSTM ferment la marche, quelle que soit la mesure.

Pourquoi la gaussienne « gagne » globalement alors qu'on vient de montrer qu'elle est mal calibrée ? Les deux analyses ne répondent pas à la même question. Le classement CRPS ci-dessus compare les modèles *tels quels*, sans jamais leur substituer une loi à queues épaisses — il ne teste donc pas « gaussien contre Student-t », il teste « quel modèle prédit le mieux, dans son ensemble, avec sa distribution d'origine ». Or à l'horizon $D+1$, le rendement attendu d'un actif financier est très proche de zéro (marché quasi-efficient) — la mesure directe le confirme : Naive, ARIMA-GARCH et SARIMA parient un mouvement quasi nul (0,02 à 0,16%) quand le vrai mouvement moyen est de 0,2 à 2,5% selon l'actif, et ce pari prudent est déjà proche de l'optimal pour le CRPS. TSDiff, seul modèle à parier un vrai mouvement (3 à 15× plus gros), n'a qu'un taux de bonne direction de 49 à 55% — à peine mieux que pile ou face — ce qui le pénalise sur le CRPS sans que cela ait le moindre rapport avec la forme de sa distribution. **Le classement CRPS est dominé par la qualité du pari directionnel, pas par la forme de la queue** — c'est un axe indépendant de la calibration testée en §5.1. Un modèle peut donc très bien gagner au classement global tout en ayant un intervalle mal calibré (c'est exactement le cas d'ARIMA-GARCH, SARIMA et Naive), et corriger sa calibration (§5.1) ne change rien à sa qualité de point prédit — ce n'est pas la même chose que le modèle « serait meilleur » sous une loi gaussienne : la gaussienne n'a simplement jamais été mise en concurrence directe avec une alternative dans ce classement précis.

6 Points ouverts

- **Aucune des trois options n'a été mise en production.** Une décision reste à prendre : adopter GED/skew-t par défaut pour SARIMA, Naive et ARIMA-GARCH (gain net, coût négligeable), et sous quelle forme (swap manuel post-hoc, comme déjà validé, ou refit natif — jugé non rentable pour ARIMA-GARCH, 800× plus cher pour un gain non mesurable).
- **Le classement CRPS global n'a jamais été recalculé avec la meilleure option de calibration de chaque modèle.** On sait que la calibration s'améliore nettement (§5.1) et que le classement global ne bouge pas quand on compare les modèles à distribution inchangée (§5.2) — mais personne n'a encore vérifié si réévaluer ARIMA-GARCH/SARIMA/Naive sous leur meilleure loi, puis refaire le classement CRPS complet face à TSDiff et aux autres, change quoi que ce soit à l'ordre final. C'est la vérification manquante pour clore complètement le sujet.
- **Le vrai problème de Prophet (σ trop petit) reste non résolu.** Aucune des trois options testées ne s'y attaque directement — un diagnostic de la source du sous-dimensionnement de σ dans Prophet reste à faire avant d'envisager une correction.
- **LSTM n'a pas de solution retenue.** Le swap manuel dégrade, le MDN prototype n'est pas rentable en l'état (instabilité d'entraînement). Une piste non testée : recalculer σ dynamiquement pendant la boucle de validation au lieu de le figer une seule fois sur les résidus d'entraînement — pourrait suffire sans changer la forme de la loi.
- **Le taux de bonne direction de TSDiff (49–55%) n'a pas été testé statistiquement** (pas de test formel contre 50%, type intervalle de confiance de Wilson) — nécessaire avant de conclure définitivement à une absence d'edge directionnel.
- **Écart non réconcilié sur la couverture à 95% de TSDiff :** quasi totale (99–100%) sur la fenêtre resserrée utilisée pour la comparaison CRPS gaussien/empirique, contre sous-couverture (~81%) dans l'analyse poolée plus large. Les deux mesures ne portent pas sur les mêmes fenêtres ni les mêmes regroupements de régimes — à creuser plutôt qu'à trancher.