

Prédire le prix à quelques semaines

Évaluation probabiliste — CRPS & calibration — DeepEdgeBenchmark, 21 juillet 2026
Chaque prévision jugée sur toute sa distribution (500 scénarios), pas seulement sa moyenne.

L'essentiel

- **On ne juge plus au RMSE** (qui ne regarde qu'un chiffre, la moyenne — injuste pour un modèle de diffusion) mais sur le **CRPS** (note de toute la distribution) et la **calibration à 3 niveaux** (50 / 80 / 95 %).
- **Jugé sur sa distribution, TSDiff n'est plus le cancre** : CRPS $\sim 2,34$, dans le peloton des classiques ($\sim 2,0$), loin devant Prophet (9,06). Invisible au RMSE.
- **Aucun modèle n'est bon partout — la vraie découverte.** TSDiff est le SEUL juste au cœur de la distribution (50 %), mais ses queues sont trop fines (sous-couvre à 95 %). ARIMA-GARCH est l'inverse : solide aux extrêmes, trop large au centre.
- **Entraîner en hebdo n'apporte aucun avantage** (au mieux à égalité avec le quotidien).

Ce qu'on a testé, et les 3 mots à connaître

On évalue des **prédictions** (pas des « test cases » : rien à voir avec les tests du code). Chaque modèle prédit le prix à ~30 dates passées, et on compare au réel. 6 modèles × 5 actifs × plusieurs horizons ; pour chaque prévision, **500 scénarios** gardés.

Mot	En clair
CRPS	Note globale d'une prévision : précision et honnêteté de l'incertitude en un chiffre. Plus bas = mieux. (Remplace le RMSE, adapté aux distributions.)
Couverture	Le contrôle des promesses : quand le modèle dit « prix dans cette fourchette, sûr à 95 % », le vrai prix y tombe-t-il vraiment 95 % du temps ? En dessous = fourchette trop étroite (trop sûr de lui) ; au-dessus = trop large (trop prudent).
Centre / queues	La fourchette à 50 % décrit le comportement normal du prix (le « centre »). La fourchette à 95 % doit englober les événements extrêmes rares (les « queues » : krach, flambée).

Résultat 1 — Qualité globale de la prévision (CRPS)

Le CRPS met tous les modèles sur la même échelle (un point = une distribution dégénérée). **Vert** = compétitif, **rouge** = en retrait.

Modèle	CRPS (normalisé)	Verdict
ARIMA-GARCH	~2,0	peloton de tête
SARIMA	~2,1	peloton de tête
Prophet	9,06	très en retrait
LSTM	n.d.	valeur exacte non lue
Naïve	~2,0	peloton de tête
TSDiff	2,34	compétitif — rejoint le peloton

Lecture : au RMSE, TSDiff paraissait mauvais. Jugé sur toute sa distribution, il **rejoint le peloton** — la bonne métrique change le verdict. Prophet décroche nettement.

La valeur exacte de LSTM et le détail des 240 cellules étaient dans un fichier verrouillé au moment de la rédaction — à compléter.

Résultat 2 — Fiabilité des fourchettes, à 3 niveaux (la vraie découverte)

Couverture **observée** (cible entre parenthèses). **Vert** = bien calibré, **rouge** = significativement mal calibré (après correction).

Modèle	50 % — centre (0,50)	80 % (0,80)	95 % — queues (0,95)
ARIMA-GARCH	0.57	0.83	0.93
SARIMA	0.61	0.85	0.94
Prophet	0.42	0.63	0.80
LSTM	0.66	0.86	0.94
Naive	0.61	0.85	0.94
TSDiff	0.53	0.76	0.88

Concrètement, sur 100 prévisions de TSDiff :

- **Fourchette à 50 %** : il promet le vrai prix dedans 50 fois -> il y est **53 fois**. Parfait. Il vise juste le comportement normal du prix — le seul des 6 à y arriver.
- **Fourchette à 95 %** : il promet 95 fois -> il n'y est que **88 fois**. 12 fois, le prix a bougé **plus fort qu'il ne le jugeait possible** : ses queues sont trop fines, il sous-estime les extrêmes.
- **ARIMA-GARCH, c'est l'inverse** : bon aux extrêmes (0,93), mais trop large au centre (0,57). **Prophet** est mauvais aux 3 niveaux.

Pourquoi ça compte : pour **gérer le risque** (grosses pertes rares), ce sont les queues qui comptent -> ARIMA-GARCH est plus sûr, TSDiff risqué. Pour le **prix probable au quotidien** (le centre) -> TSDiff est le meilleur. Aucun modèle n'est bon aux 3 niveaux : invisible au RMSE.

Résultat 3 — Viser 1 semaine : quotidien (D+7) ou hebdo (W+1) ?

Comparé sur le CRPS (peu de dates -> prudence).

Modèle	Verdict (CRPS)
ARIMA-GARCH	Aucune différence
SARIMA	Aucune différence
Prophet	Quotidien (D+7) meilleur
LSTM	Quotidien (D+7) meilleur
Naïve	Aucune différence
TSDiff	Données insuffisantes

Aucun modèle ne favorise l'hebdo ; là où c'est significatif (Prophet, LSTM), c'est le quotidien qui gagne.

Résultat 4 — Fréquence d'entraînement (jour vs semaine)

Non tranchable ici : les prévisions hebdo-natives sont quasi absentes des échantillons (trou de couverture en base, pas un manque de dates). Le verdict de l'analyse précédente (au RMSE) reste : **pas de différence — entraîner en hebdo n'apporte rien**.

Carte d'identité de chaque modèle

Modèle	CRPS	Centre (50 %)	Queues (95 %)	En bref
ARIMA-GARCH	Peloton	juste	fiable	Le plus fiable en général.
SARIMA	Peloton	juste	fin	Correct, calage 95 % un peu faible.
Prophet	En retrait	mal calibré	mal calibré	Mauvais partout.
LSTM	n.d.	trop large	fiable	Correct, solide aux extrêmes.
Naive	Peloton	juste	fiable	Simple mais solide.
TSDiff	Compétitif	juste	fin	Champion du centre, queues trop fines.

Limites

- Échantillons paramétriques pour 5 modèles sur 6 (seul TSDiff a un nuage natif) ; TSDiff ré-entraîné faute de checkpoint (fidèle, pas bit-identique).
- Régime hebdo-natif quasi vide -> question fréquence non tranchable sur le CRPS ; horizon plafonné à 15 -> W+3 crypto exclu.
- Classement des modèles entre eux hors périmètre (asymétrie de protocole non corrigée par les tests).

En résumé : en passant au CRPS + calibration multi-niveaux, TSDiff passe de « pire modèle » à **compétitif, et meilleur au cœur de sa distribution** — mais ses queues restent trop fines. La leçon : la métrique décide du verdict ; un modèle probabiliste se juge sur toute sa distribution.