

Taux d'utilisation — Test cases TC1.1–TC1.5 (D+1)

DeepEdgeBenchmark — validation business

Etat au 17 juillet 2026 — BTC-USD, pipeline daily

1 Tableau récapitulatif

Tous modèles confondus	Taux d'utilisation
Vraies + fausses prédictions	80,6 %
Vraies prédictions (live)	70,4 %
Fausse prédictions (backtest OOS)	81,6 %

	ARIMA	SARIMA	Prophet	LSTM	TSDiff
Vrai	58,8 %	82,4 %	64,7 %	82,4 %	61,5 %
Faux	96,3 %	97,5 %	63,0 %	62,2 %	89,0 %
Vrai + Faux	92,7 %	96,1 %	63,1 %	64,1 %	87,0 %

Table 1: Taux d'utilisation par modèle (source : *tracking.db*, dashboard DeepEdgeBenchmark).

2 Comment fonctionne ce taux

Chaque ligne (un jour D , un modèle) est évaluée par cinq règles mutuellement quasi exclusives : TC1.1 Bull-Calm (hausse prédite, position longue modérée), TC1.2 Bull-Stress (hausse quasi certaine même au pire cas du PI), TC1.3 Bear-Calm (baisse prédite, position courte modérée), TC1.4 Bear-Stress (baisse quasi certaine même au meilleur cas du PI), TC1.5 Sideways (journée plate prédite, test de justesse pur, sans position). Une ligne est déclarée **utilisable** si au moins un test case s'y est déclenché *et* que son **counter** de résolution est positif (+1 ou +2) ; un jour sans déclenchement, ou dont le signal résolu est négatif ($-1/-2$), compte comme non utilisable. Le **taux d'utilisation** rapporte ce compte au nombre total de lignes de la sélection.

La distinction *vraie / fausse prédiction* ne dépend pas de la colonne technique **source** (**live/oos**) mais uniquement de la date : est « vraie » toute prédiction dont $D \geq 06/07/2026$ (08/07/2026 pour TSDiff, entré plus tard dans la grille), qu'elle ait techniquement tourné en **live** ce jour-là ou qu'elle ait été reconstruite en **oos** lors d'un backfill. Tout ce qui précède est une « fausse » prédiction : une reconstruction de backtest sur la période de validation. Ce tableau est restreint à BTC-USD et à l'horizon D+1 (seul horizon couvert par ces règles).

3 Pourquoi les « vraies » prédictions ne sont pas fiables

Trois problèmes cumulatifs, vérifiés directement dans `tracking.db` :

- **Échantillon réel bien plus petit qu'il n'y paraît.** Le n affiché (17 lignes par modèle, 13 pour TSDiff) compte deux fois la plupart des journées : une fois via la prédiction `live` du jour, une fois via la reconstruction `oos` du backtest journalier qui recouvre aussi les jours récents. En pratique, il n'y a que **9 à 10 jours de marché distincts** derrière ces 17 lignes, pas 17 essais indépendants.
- **Trous de collecte, différents par modèle.** La table `sim_trades` (source `live`) n'est pas peuplée pour les mêmes jours selon le modèle. Exemple concret : ARIMA-GARCH n'a de signal enregistré en `live` que sur 2 des 9 jours réels (14 et 15/07) — les 7 jours précédents n'ont *aucune* ligne en base pour ce modèle, alors que la règle métier aurait déclenché un signal (majoritairement gagnant) si elle avait tourné. SARIMA, lui, est peuplé sur 6 des 9 jours. Un jour sans ligne compte automatiquement comme « non utilisable », ce qui pénalise mécaniquement le modèle le moins bien couvert — indépendamment de la qualité de ses prédictions.
- **Une seule fenêtre de marché.** Ces 9–10 jours couvrent une unique période (mi-juillet 2026), pas une diversité de régimes (haussier/baissier/calme/ stress). À $n \approx 10$, l'intervalle de confiance à 95 % sur un taux avoisinant 30–80 % dépasse ± 30 points : impossible de distinguer un vrai écart d'un coup de chance.

4 Conclusions par modèle

Prophet. Le taux OOS de Prophet (63,0 %) reflète encore un bug connu et documenté (`BRIEF_correction_prophet`). `run_prophet` faisait un seul *fit* puis prédisait toute la fenêtre de test en un batch (au lieu d'un walk-forward 1-pas comme les autres modèles), créant une dérive de tendance (+11,8 % sur BTC, +21,8 % sur ETH au moment de l'audit). Le correctif a été codé et mergé le 15/07 à 16h39, mais les données OOS déjà en base ne sont pas régénérées automatiquement : le biais moyen mesuré aujourd'hui sur BTC-USD OOS reste de +10,4 %, quasi identique à l'avant-correctif, et le dernier run Prophet utilisé date de 15h55 le 15/07 — 44 minutes *avant* le merge du fix. Le score de Prophet ne doit donc pas être comparé tel quel aux autres tant que son backtest n'a pas été régénéré avec le code corrigé.

ARIMA vs SARIMA (58,8 % vs 82,4 % en vrai). L'écart tient surtout au trou de collecte décrit ci-dessus (2 jours `live` peuplés sur 9 pour ARIMA contre 6 pour SARIMA), pas à une différence de qualité entre deux modèles pourtant proches. Un effet secondaire plus mineur : la bande d'incertitude de SARIMA est en moyenne ~ 15 –20 % plus large relativement (10,4 % du prix contre 9,0 % pour ARIMA-GARCH en OOS) — les seuils de tolérance des test cases étant des fractions de cette largeur, une bande plus large rend mécaniquement la validation plus facile.

TSDiff (89,0 % en faux, le plus bas des modèles entraînés). Ceci est mesuré sur 164 jours OOS, donc un signal réel, pas du bruit d'échantillon. TSDiff prédit un mouvement moyen de +0,57 % par rapport au dernier prix connu, contre +0,11 à +0,16 % pour ARIMA/SARIMA (quasi-persistance pure, corrélation 0,9999 avec le prix de la veille). Le test « Sideways » (quasi-immobile) — qui gagne souvent car le mouvement réel moyen de BTC (1,83 %/jour) tient fréquemment dans la tolérance généreuse dérivée d'une bande de ~ 10 % — se déclenche donc moins pour TSDiff, qui prend plus souvent un vrai pari directionnel. Or un pari directionnel sur un actif proche d'une marche

aléatoire ne gagne qu’une fois sur deux environ (44–51 % mesuré sur les déclenchements bull/bear-calm, tous modèles confondus). Ce n’est pas que TSDiff est un moins bon modèle probabiliste — sa couverture d’IC à 95 % (91,1 %) reste proche du nominal, à peine sous celle d’ARIMA (92,9 %) — c’est que ce KPI récompense structurellement les prévisions les plus proches d’une persistance pure, un artefact déjà documenté dans le repo (`honest_eval/README.md` : *"all models were effectively predicting yesterday's price $\pm \varepsilon$ "*).

5 Le taux global « tous modèles confondus » (>80 %) est-il exploitable ?

Non, pas directement, et l’arithmétique le montre : sur les 5 modèles du tableau, le volume *faux* (814 lignes OOS) pèse **91 %** de l’échantillon combiné contre seulement 81 lignes *vraies* (9 %). Le chiffre affiché de 80,6 % n’est donc presque rien d’autre que le chiffre du backtest (81,6 %) recopié : l’apport du vrai suivi live (70,4 %, pourtant nettement différent) ne fait bouger l’agrégat que d’un point. Le voir dépasser 80 % ne valide donc pas une performance live : cela valide surtout que le backtest génère beaucoup de journées « quasi-immobiles » gagnantes — exactement l’artefact de persistance décrit plus haut.

Pour qu’une agrégation soit réellement parlante, il faudrait : (1) ne calculer le taux que sur des lignes *live* (jamais mélanger avec l’OOS, qui écrase le signal par le volume) ; (2) accumuler plusieurs dizaines de jours de suivi live couvrant des régimes différents (haussier/baissier/calme/stress), pas une seule quinzaine de juillet ; (3) combler d’abord les trous de collecte par modèle (cf. §3) pour comparer les modèles sur un nombre de jours réellement équivalent ; et (4) croiser ce KPI binaire avec des métriques non dégénérées face à la persistance (RMSE, CRPS, Theil’s U de `honest_eval`), pour ne pas confondre « modèle qui ne bouge jamais » et « modèle qui prédit bien ».

6 Détail jour par jour — ARIMA-GARCH (capture d’écran du dashboard)

La table ci-dessous reconstitue le contenu de la capture d’écran fournie (détail jour par jour ARIMA-GARCH, filtre « vraies prédictions » + « seulement les jours avec signal »)¹.

¹L’image elle-même n’a pas pu être intégrée en tant que fichier dans ce document (capture collée dans la conversation, non enregistrée sur disque) — son contenu est reproduit fidèlement en tableau ci-dessous. Dis-moi si tu veux que je l’intègre telle quelle : il suffit de déposer le fichier image dans le dossier partagé.

Date (D)	Source	Réf. P(D)	Prévision	Réel	Test case(s)	Counter
2026-07-15	live	64 871,99	65 036,30	62 891,95	TC1.1, TC1.5	-1, +2
2026-07-14	live	64 956,11	64 966,52	64 241,96	TC1.1, TC1.5	-1, +2
2026-07-13	oos	62 239,12	62 393,79	64 956,11	TC1.1, TC1.5	+2, -1
2026-07-12	oos	63 758,22	63 825,36	62 239,12	TC1.1, TC1.5	-1, +1
2026-07-11	oos	63 802,03	63 902,60	63 758,22	TC1.1, TC1.5	-1, +2
2026-07-10	oos	64 127,14	64 173,94	63 802,03	TC1.1, TC1.5	-1, +2
2026-07-09	oos	63 193,15	63 202,29	64 127,14	TC1.1, TC1.5	+1, +2
2026-07-08	oos	62 257,57	62 370,31	63 193,15	TC1.1, TC1.5	+1, +2
2026-07-07	oos	63 297,39	63 413,60	62 257,57	TC1.1, TC1.5	-1, +2
2026-07-06	oos	63 995,02	64 052,18	63 297,39	TC1.1, TC1.5	-1, +2

Table 2: Seules les lignes avec au moins un signal sont affichées (10 sur 17 — les 7 lignes restantes, sans signal ou non peuplées côté live, cf. §3, ne sont pas montrées par le filtre du dashboard).

Indicateur (ARIMA-GARCH, vrai)	Valeur
Utilisation brute	10
Performance simulation (Σ counter)	+13
Taux d'utilisation	58,8 %
n (lignes)	17
Verdict (seuil ≥ 80 %)	Non validé