

Synthèse KPI probabilistes

DeepEdgeBenchmark — 240 combinaisons réévaluées sur CRPS/calibration

Exécuté le 21 juillet 2026

1 Pourquoi cette synthèse

La synthèse précédente classait les modèles au **RMSE**, qui ne juge que la prévision *centrale*. C’est inadapté à un modèle **probabiliste/de diffusion** comme TSDiff, qui produit une distribution entière de scénarios : le RMSE ignore la forme de la distribution, les queues et l’incertitude. Cette synthèse réévalue les **240 combinaisons** (6 modèles $\times$ 5 actifs $\times$ 8 cellules de régime) sur des KPI adaptés : **CRPS empirique**, **couverture multi-niveaux** (50/80/95 %), **finesse**, **score de Winkler** et, en secondaire, **MASE**.

2 Méthode

Échantillons (N=500, sans ré-entraînement pour 5 modèles sur 6). La base ne stockait que point + intervalle à 95 %. Pour ARIMA-GARCH, SARIMA, Prophet, Naive et LSTM, chaque intervalle est construit par le modèle lui-même comme $\hat{y} \pm z\sigma$ (log-normal en espace rendement pour ARIMA-GARCH, gaussien en espace prix pour les 4 autres — vérifié directement dans `models/*.py`). σ est donc retrouvable algébriquement depuis (`y_pred`, `y_lower`, `y_upper`) déjà en base, et N=500 échantillons sont tirés de cette même loi paramétrique — zéro ré-entraînement, zéro nouveau calcul lourd.

TSDiff : rééchantillonnage natif, avec un vrai calcul. TSDiff n’a **aucun checkpoint persisté** dans ce dépôt (`model_artifacts/pipeline.py` ne sérialise jamais d’artefact TSDiff — vérifié directement, pas supposé). Chaque valeur actuellement en base a été produite par un unique passage train-once-forward dont le nuage d’échantillons a été jeté immédiatement (réduit à moyenne + quantiles 2,5/97,5). Obtenir de vrais échantillons exige donc de rejouer ce même protocole (même fenêtre de données, `seed=42`, même nombre d’épochs déjà sélectionné par `epoch_sweep.py` par actif) en conservant les 500 tirages au lieu de les jeter — pas une nouvelle méthodologie, juste la capture de ce que le pipeline calcule déjà en interne à chaque origine.

Trois cellules de régime, un seul entraînement chacune.

- **Régime A** (D+1/D+7, natif quotidien) : fenêtre glissante de 700 jours (échelle vérifiée sur les runs de production), `epochs=40` (défaut `tsdiff_model.py`).
- **Régime B** (W+1/W+2/W+3, entraîné quotidien – «TSDiff-D») : `horizon=15` pas quotidiens, `epochs` par actif issus de `epoch_sweep_results*.json`.
- **Régime C** (W+1/W+2/W+3, natif hebdomadaire – «TSDiff-W») : `horizon=3` pas hebdomadaires, `epochs` par actif issus de `weekly_multiasset_results.json`.

Garde-fous respectés. N=500 identique pour les 6 modèles ; même estimateur de CRPS empirique partout (Gneiting & Raftery 2007, éq. 20) ; PIT sur la distribution complète ; aucun rééchantillonnage conditionné sur des données postérieures à l’origine ; puissance effective (bootstrap par blocs) toujours affichée.

3 Résultats poolés par modèle (tous horizons, 5 actifs)

CRPS normalisé par l’échelle MASE de l’actif (même convention que l’analyse poolée existante) — comparable entre BTC-USD et ZN=F malgré l’écart d’échelle des prix.

Modèle	n	CRPS (norm.)	Cov 50 %	Cov 80 %	Cov 95 %
SARIMA	1520	2,03	0,609	0,855	0,936
ARIMA-GARCH	1520	2,03	0,567	0,828	0,933
Naive	1520	2,14	0,614	0,853	0,940
TSDiff	1395	2,34	0,525	0,760	0,878
LSTM	1549	3,39	0,660	0,864	0,941
Prophet	1520	9,06	0,416	0,630	0,801

Table 1: Cible de couverture : 0,50 / 0,80 / 0,95. CRPS : plus bas = meilleur.

SARIMA et ARIMA-GARCH restent en tête sur le CRPS poolé, suivis de près par Naive et **TSDiff, qui n’est plus dernier ou hors-jeu comme au RMSE seul** — son CRPS est du même ordre de grandeur que les modèles statistiques classiques. Prophet reste très en retrait, cohérent avec son décrochage déjà connu au RMSE. LSTM se distingue : sa couverture est la plus proche de la cible à tous les niveaux, mais son CRPS reste médiocre — intervalles bien positionnés mais trop larges (manque de finesse).

4 Ce que le RMSE cachait : TSDiff par horizon

Horizon	CRPS (norm.)	Cov 95 %	Commentaire
D+1	1,16	0,999	Meilleure couverture de tous les modèles à cet horizon
D+7	3,86	0,953	Encore bien calibré
W+1	2,55	0,580	Sous-couverture sévère
W+2	3,96	0,587	Sous-couverture sévère
W+3	3,45	0,674	Sous-couverture sévère

Table 2: TSDiff seul, par horizon (poolé sur les actifs disponibles).

C’est le résultat central de cette réévaluation : à D+1, TSDiff est **le mieux calibré des 6 modèles** — un signal totalement invisible au RMSE, qui ne regarde que le point central. Mais la calibration se dégrade fortement dès que l’horizon s’allonge au-delà de D+7 (régime B, «TSDiff-D») : la couverture à 95 % tombe à 0,58–0,67, confirmant ce qui était déjà noté ailleurs dans ce dépôt comme «structurellement sous-calibré» pour TSDiff-D.

5 Tests statistiques poolés

Même protocole que l’analyse poolée existante (DM-HAC + bootstrap par blocs, clusters bonds=ZN=F+TLT et crypto=BTC-USD+ETH-USD, correction de Holm sur les 6 modèles), joué sur le CRPS empirique et la calibration multi-niveaux au lieu du RMSE.

5.1 Calibration (écart à la cible, après correction de Holm)

Modèle	Écart @50 %	Écart @80 %	Écart @95 %
ARIMA-GARCH	+0,059*	+0,026	−0,016
SARIMA	+0,082*	+0,032	−0,027*
Prophet	−0,109*	−0,196*	−0,166*
Naive	+0,088*	+0,034	−0,022
LSTM	+0,124*	+0,040	−0,025
TSDiff	+0,013	−0,048	−0,077*

Table 3: Signe positif = sur-couverture (intervalles trop larges), négatif = sous-couverture. * = significatif après correction de Holm (IC à 95 % excluant 0). Puissance effective (bootstrap par blocs) : $n_{\text{eff}} \approx 270\text{--}305$ par cellule (sur $\sim 900\text{--}1500$ lignes brutes).

TSDiff est le seul modèle bien calibré à 50 % (écart non-significatif, +0,013) mais se dégrade significativement aux niveaux plus élevés — cohérent avec le tableau précédent (bonne calibration à D+1/D+7, mauvaise sur les horizons hebdomadaires qui dominent le pool). Prophet est significativement mal calibré à tous les niveaux, et dans le sens de la sous-couverture partout (intervalles trop étroits malgré un CRPS déjà mauvais). ARIMA-GARCH, Naive et LSTM sur-couvrent significativement à 50 % (intervalles un peu trop larges à ce niveau) mais sont statistiquement bien calibrés à 95 %.

5.2 D+7 vs W+1 (aligné vendredi)

Modèle	n (n_{eff})	Écart CRPS	Verdict
ARIMA-GARCH	35 (11)	−0,29	pas de différence exploitable
SARIMA	35 (11)	−0,30	pas de différence exploitable
Naive	35 (11)	−0,28	pas de différence exploitable
Prophet	35 (11)	−8,90*	D+7 significativement meilleur
LSTM	40 (13)	−3,19*	D+7 significativement meilleur
TSDiff	—	—	données insuffisantes

Table 4: Écart = $\text{CRPS}(D+7) - \text{CRPS}(W+1)$. Puissance très limitée ($n_{\text{eff}} \approx 11\text{--}13$) — à lire avec prudence.

5.3 Fréquence B vs C (entraîné quotidien vs natif hebdomadaire)

Données insuffisantes pour les 6 modèles. Le régime C (natif hebdomadaire) est quasi-vide dans la matrice actuelle : pour TSDiff, 89–90 des ~ 90 lignes possibles par actif sont marquées

daily_duplicate=1 (vérifié directement en base) — un trou de couverture préexistant, pas un artefact de cette réévaluation. Aucun verdict n'est tiré faute de puissance.

6 Limites

- **5 modèles sur 6 : échantillons paramétriques, pas le nuage d'origine.** Le nuage brut n'a jamais existé pour ARIMA-GARCH, SARIMA, Prophet, Naive, LSTM — seule sa loi implicite (gaussienne/ log-normale) est reconstruite depuis le PI stocké.
- **TSDiff : ré-entraînement fidèle, pas bit-identique.** Même protocole, même seed, mais un nouveau calcul — les points centraux corréleront à $\sim 0,97$ avec les valeurs stockées en base sans être identiques.
- **TSDiff-D, W+3, actifs crypto : plafond structurel.** Le modèle régime B est entraîné avec horizon=15 pas (calibré pour des marchés à 5 jours/semaine) ; BTC-USD/ETH-USD (7 jours/semaine) ont besoin de 21 pas pour W+3 — au-delà de la capacité native du modèle. 30 lignes (W+3 régime B, crypto) sont donc absentes de cette matrice, un plafond hérité du protocole d'origine, pas corrigé ici (corriger exigerait un nouvel entraînement avec un horizon plus grand, hors périmètre : ce brief ne ré-entraîne pas au-delà de ce qui était déjà nécessaire).
- **Classement inter-modèle toujours hors périmètre.** L'asymétrie de protocole (TSDiff entraîné une fois par cellule vs les 5 autres rééchantillonnés depuis une PI stockée sans réentraînement) n'est corrigée par aucun test statistique — un écart de CRPS entre TSDiff et les autres ne doit pas être lu comme un verdict de supériorité/infériorité de modèle.

7 Conclusion

Jugé sur ce qu'il fait vraiment (une distribution, pas un point), TSDiff n'est plus le modèle hors-jeu que suggérait le RMSE seul : son CRPS poolé est comparable à ARIMA-GARCH/SARIMA/Naive, et sa calibration à D+1 est la meilleure des 6 modèles. La contrepartie, elle aussi invisible au RMSE : une sous-calibration significative et robuste (testée, pas supposée) sur les horizons hebdomadaires, cohérente avec le diagnostic «TSDiff-D structurellement sous-calibré» déjà posé ailleurs dans ce dépôt. Prophet reste le point faible confirmé, cette fois sur CRPS *et* calibration, pas seulement sur l'erreur ponctuelle.