

Validation business des modèles

DeepEdgeBenchmark

Run du 7 juillet 2026

1 Objectif

Cette validation évalue si les prédictions produites par les 5 modèles du benchmark sont *exploitables* avant même de connaître le vrai futur. Elle est distincte du benchmark statistique existant (*benchmarks/*), qui mesure la précision une fois l'horizon atteint. Ici, chaque prédiction reçoit deux verdicts calculables immédiatement :

- **Intégrité** : la prédiction est-elle structurellement saine (valeurs finies, bornes d'intervalle cohérentes, dates cohérentes, régime valide) ? Un échec signale un bug de pipeline, pas un mauvais modèle.
- **Plausibilité** : le mouvement prédit reste-t-il dans un ordre de grandeur raisonnable pour cet actif et cet horizon ? Un échec signale une prédiction délirante mais techniquement valide.

2 Périmètre

- **Actifs (5)** : BTC-USD, ETH-USD, SPY, ZN=F, TLT.
- **Horizons (2)** : D+1 (1 jour de trading), D+7 ($\approx$ 5 jours de trading).
- **Modèles (5)** : ARIMA-GARCH, SARIMA, Prophet, LSTM, Naive.
- **Total** : $5 \times 2 \times 5 = 50$ test cases, cutoff au 2026-07-06.

Seuils de plausibilité par classe d'actif (mouvement journalier normal, étendu en racine de l'horizon) : crypto 15 %, indice 5 %, obligataire 3 %.

3 Résultats globaux

Aucun échec technique sur ce run (0 exception, 0 valeur manquante). 100 % des prédictions sont structurellement saines. Les 5 échecs de plausibilité (10 %) sont analysés ci-dessous : ce ne sont pas des faux positifs, ce sont exactement le type de signal que cette couche est censée remonter.

Modèle	Test cases	Intégrité OK	Plausibilité OK
ARIMA-GARCH	10	10/10	10/10
SARIMA	10	10/10	10/10
Prophet	10	10/10	6/10
LSTM	10	10/10	10/10
Naive	10	10/10	9/10
Total	50	50/50	45/50

Table 1: Verdicts par modèle, tous actifs et horizons confondus.

Actif	Horizon	Dernier cours	Prédiction	Mouvement	Largeur IC
BTC-USD	D+1	63 995	84 419	+31,9 %	58,0 %
BTC-USD	D+7	63 995	85 933	+34,3 %	58,0 %
ETH-USD	D+1	1 798	2 375	+32,1 %	99,2 %
ETH-USD	D+7	1 798	2 469	+37,3 %	97,3 %

Table 2: Prédictions Prophet jugées implausibles (seuil crypto : 15 % à D+1, ≈ 34 % à D+7).

4 Constat principal : Prophet sur BTC-USD et ETH-USD

Sur les 3 autres actifs (SPY, ZN=F, TLT), Prophet reste sobre (+1 à +3 %) : le problème est spécifique aux actifs crypto, pas au modèle en général.

Cause probable : l’adaptateur Prophet fitte le modèle sur le prix brut (pas le log-prix, pas les rendements), avec une tendance linéaire par morceaux à points de rupture automatiques. Sur BTC/ETH, dont le prix a varié sur plusieurs ordres de grandeur depuis 2018, une tendance récente marquée s’extrapole de manière très agressive sur quelques jours – contrairement à ARIMA/SARIMA (qui travaillent sur les rendements) ou LSTM. C’est un point faible connu de Prophet sur les séries à forte croissance non stationnaire.

5 Constat secondaire : Naive sur TLT

Naive tire un mouvement aléatoire uniforme ± 5 % quel que soit l’actif. Sur TLT (obligataire, seuil 3 %/jour), un tirage dépassant 3 % en valeur absolue survient environ 40 % du temps – c’est arrivé une fois sur les 10 test cases Naive de ce run (TLT, D+1). La bande fixe de Naive n’est pas calibrée par classe d’actif ; à garder en tête si Naive doit servir de référence sur des actifs à faible volatilité.

6 Architecture livrée

- `validation/tracking_db.py – save_prediction(record, db_path)`, persistance idempotente (clé `tc_id + model + cutoff_date`), `ValueError` si champ manquant.
- `validation/verdict_rules.py – check_integrity()` et `check_plausibility()`, seuils par classe d’actif.
- `validation/generate_test_cases.py` – orchestration : téléchargement, calibration régime, appel des 5 modèles, calcul des verdicts, sauvegarde.

Hors scope (géré séparément) : `evaluate_pending()` (remplissage de `actual` une fois le futur connu – 2026-07-07 pour D+1, 2026-07-13 pour D+7) et `report()` (taux agrégés par modèle/actif/horizon/régime).

NB : si la cohérence du champ régime importe pour l'agrégation par `report()`, repartir d'une base `tracking.db` vide et relancer un run complet.