

Dashboard externe — DeepEdgeBenchmark

Rédigé le 10 août 2026. Établi par lecture directe du code de génération (`model_artifacts/generate_dashboard.py`), du workflow de déploiement, des artefacts `Run/**` et de la base `validation/tracking.db` — aucun chiffre supposé. Intègre le branchement du mensuel et le stamp de fraîcheur livrés le 10 août 2026.

En une phrase. Le dashboard externe est régénéré et déployé automatiquement (GitHub Pages) à partir de deux sources : les artefacts `Run/**` (entraînements quotidiens) pour le **daily**, et la base `tracking.db` pour le **weekly** et — désormais — le **monthly**. Les trois fréquences sont donc affichées ; l'historique des données diffère nettement de l'une à l'autre, c'est l'objet de cette note.

1. Ce qu'est le dashboard externe

- **Déploiement** : page GitHub Pages (<https://darkshey.github.io/DeepEdgeBenchmark/>), **régénérée par la CI** (`.github/workflows/deploy-pages.yml`) à chaque push touchant `Run/**`, `validation/tracking.db` ou `generate_dashboard.py`. Le HTML n'est plus committé (externalisation, étape 1) ; les séries lourdes sont découpées par date en `data/<run_date>.json` et chargées à la demande (lazy-load, étape 2).
- **Onglets par actif** : KPIs (date de run / horizon / modèles sélectionnables, tuiles par modèle, breakdown modèle × horizon avec largeur de PI 95 %) ; Graphique (prix réel + prédictions, bande IC95, séparation train/validation) ; Comparaison (tous actifs). En bas : tableau jour-par-jour des test cases TC1.1-TC1.5 (`sim_trades`), restreint à D+1.
- **Sources distinctes selon la fréquence** : `Run/**` pour le daily, `tracking.db` pour le weekly et le monthly. Deux natures d'historique différentes (voir §2 à §4).

2. Historique des données — DAILY affiché — cœur du dashboard

2.1 Source

Les artefacts `Run/<date>-<modèle>-<actif>-<horizon>/` produits par `pipeline.py` : `metrics.json`, `metadata.json`, `predictions.parquet`, `prices.parquet`. Un dossier = un entraînement quotidien pour un couple (modèle, actif), lu aux deux horizons **D+1** et **D+7**.

2.2 Fenêtre d'historique & réentraînement

- **Fréquence d'entraînement** : **1 jour** (`frequency: "1d"`).
- **Fenêtre glissante d'environ 3 ans**, recalée à chaque run : `window_start` $\approx$ date de run - 3 ans. Ex. run 2026-08-04 → fenêtre **2023-08-04 → 2026-08-02** ; run 2026-07-07 → **2023-07-07 → 2026-07-06**. Même fenêtre pour tous les actifs (crypto comprise).
- **Réentraîné à chaque date de run** ($\neq$ train-once), seed 42, avec découpe train/validation : `train_end` $\approx$ 2026-02-18 → la validation est la queue récente. Points de validation : **n_val = 113** à D+1, ~ 10 à D+7 (cibles D+7 espacées d'une semaine dans la même fenêtre).

2.3 Couverture

Dimension	Contenu
Dates de run	2026-07-07 → 2026-08-04 — 27 dates ($\approx$ quotidien, jours ouvrés)
Modèles (7)	ARIMA-GARCH, SARIMA, Prophet, LSTM, Naive, TSDiff, NsDiff
Actifs (5)	BTC-USD, ETH-USD, SPY, TLT, ZN=F

Horizons	D+1 et D+7
KPIs affichés	RMSE, MAE, MAPE, précision directionnelle, Cov95, largeur de PI, CRPS, test de Diebold-Mariano, MASE, Theil U...
Signaux de trading	TC1.1-TC1.5 résolus à D+1 , sur 5 modèles (ARIMA-GARCH, SARIMA, Prophet, LSTM, TSDiff — jamais Naive)

En clair : le daily, c'est ~1 mois d'entraînements quotidiens, chacun sur ~3 ans de prix glissants réappris chaque jour, évalués à 1 et 7 jours.

3. Historique des données — WEEKLY affiché — TSDiff & NsDiff seulement

3.1 Source

La base `validation/tracking.db` (pas `Run/`), filtrée `frequence='weekly' AND horizon_type='weekly' AND source IN ('oos','live')` — **régime C** (modèle hebdomadaire natif), horizons W+1/2/3.

3.2 Fenêtre & contenu

- **Backtest OOS : 2024-10-18 → 2026-07-03, 90 origines par actif** (95 dates distinctes toutes classes confondues), 5 actifs, mécanisme *train-once-forward*.
- **Quelques lignes « live » récentes** : NsDiff (2026-07-31 → 08-02), TSDiff (2026-07-21).
- **Restriction d'affichage** : les 7 modèles ont des lignes weekly en base, mais le dashboard n'expose que **TSDiff et NsDiff** (`WEEKLY_KPI_MODELS`). Cov95 exacte (depuis les bornes) ; CRPS / couvertures 50-80 % en **approximation gaussienne** (nuage réel non persisté).

Cadrage imposé par le code : le weekly est présenté comme un gain de **calibration** (fiabilité de l'intervalle), **jamais de précision**.

4. Historique des données — MONTHLY affiché — branché le 2026-08-10

Nouveau. Le mensuel n'est plus un emplacement réservé : il est désormais collecté et affiché (`collect_monthly_kpis`, calqué à l'identique sur le weekly). Le bouton « Monthly » s'active dès qu'une donnée existe pour l'actif.

4.1 Source

La base `validation/tracking.db`, filtrée `frequence='monthly' AND horizon_type='monthly'` — **régime C** (mensuel natif), horizons M+1/M+2/M+3. Le régime B (daily poussé à la fin de mois) existe en base mais reste hors affichage, comme le weekly n'affiche que le régime C.

4.2 Fenêtre & contenu

- **Backtest OOS : 2023-01-31 → 2026-04-30, 40 origines par actif et par modèle**, 5 actifs.
- **Modèles affichés : TSDiff et NsDiff** uniquement (`MONTHLY_KPI_MODELS` — ce sont les seuls présents en mensuel). Cov95 exacte ; CRPS / cov50-80 en approximation gaussienne, comme le weekly. Badge de robustesse inter-graines réutilisé quand l'artefact multiseed mensuel existe (`{nsdiff,tsdiff}_monthly_multiseed.json`).
- **Pas de règles de trading mensuelles** : le mensuel est une surface **KPI**, pas un pipeline de signaux (cohérent avec `sim_trades` qui n'a de règles qu'à D+1).

Faible puissance — déclarée à l'affichage. ~130-140 clôtures mensuelles depuis 2015, cibles M+1/2/3 recouvrantes → **effective_n ≈ 10**. La plupart des cellules ressortent « indistinguishable » :

effet **attendu** d'un faible échantillon, **jamais** une équivalence démontrée. Une note de bas de section le rappelle explicitement.

5. Fraîcheur vis-à-vis de la base (stamp de provenance)

Un bandeau dédié (`collect_data_freshness`, lecture seule) affiche désormais, **par piste**, la dernière origine, le nombre d'origines et le run le plus récent — pour lire d'un coup d'œil jusqu'où va la donnée. État sur le dépôt courant :

Piste	Dernière origine	Run le plus récent
Weekly (régime C)	2026-08-02	weekly-nsdiff-2026-08-02
Monthly (régime C)	2026-04-30	20260805-tsdiff-monthly-oos

Détail technique utile : le tri « run le plus récent » se fait sur `cutoff_date` (toujours une vraie date), et non sur `run_id` — car les `run_id` ne sont pas tous préfixés `YYYYMMDD` (ex. `weekly-nsdiff-2026-08-02` vs `20260805-...`), ce qui aurait pu faire passer un run de juillet pour le plus récent.

6. Tableau récapitulatif

Fréquence	Affiché ?	Source	Modèles	Historique / fenêtre	Réentraînement
Daily D+1, D+7	Oui (cœur)	Run/**	7	Fenêtre glissante ~3 ans ; runs 2026-07-07 → 2026-08-04 (27 dates)	À chaque date de run
Weekly W+1/2/3, régime C	Oui — TSDiff & NsDiff	tracking.db	2 affichés / 7 en base	OOS 2024-10-18 → 2026-07-03 (90 origines) + live fin juil. 2026	Train-once- forward
Monthly M+1/2/3, régime C	Oui — TSDiff & NsDiff (nouveau)	tracking.db	2	OOS 2023-01-31 → 2026-04-30 (40 origines/ actif)	Train-once- forward

7. Provenance & points de vigilance

- **Fraîcheur (dépôt local)** : les artefacts `Run/` vont jusqu'au **2026-08-04** ; les stamps base donnent weekly au 2026-08-02 et monthly au 2026-04-30. La bascule ensemble du 08-08 n'est pas encore présente sur ce dépôt — le stamp la fera apparaître dès que la base à jour sera en place.
- **Trois historiques non superposables** : le daily est un *rolling* ~3 ans réappris chaque jour ; le weekly et le monthly sont des backtests figés (90 et 40 origines). Ne pas les présenter sur la même échelle.
- **Approximation CRPS (weekly & monthly)** : gaussienne, car le nuage de tirages des modèles de diffusion n'est pas conservé ; seule la Cov95 est exacte.
- **Périmètre du changement** : un seul fichier modifié (`generate_dashboard.py` + ses tests), 10 tests ajoutés, 238/238 verts, aucune dépendance lourde importée (vérifié) ; `tracking.db` intacte.