


De la donnée brute au dashboard — DeepEdgeBenchmark

Rédigé le 10 août 2026. Chaque affirmation est adossée au code (`experiments/epoch_sweep.py`, `oos_nsdiff_daily_weekly.py`, `oos_nsdiff_monthly.py`, `model_artifacts/`) et à la base `validation/tracking.db`. Objectif : ne laisser aucune étape implicite.

Comment lire. Une même donnée de prix sert les trois fréquences. Ce qui change d'une fréquence à l'autre, c'est (1) la **découpe** train/validation/test, (2) le **régime** d'entraînement, et (3) la **surface** qui l'affiche. Les sections 3, 4 et 6 sont le cœur ; le reste cadre.

1. Le chemin de la donnée (vue d'ensemble)



2. La donnée brute — une source unique

- **Source** : historique de prix yfinance à partir de 2015-01-01. En cas de dérive (yfinance retraite rétroactivement certains dividendes — cas TLT), repli sur un **snapshot gelé** `DONNEE~1.XLS`, vérifié concordant à $\sim 4 \cdot 10^{-6}$. À chaque origine réutilisée, le `last_close` téléchargé est comparé au `last_close` stocké **avant** tout entraînement (échec rapide si écart).
- **Resampling** : la même série est déclinée en **daily**, **weekly** (vendredi) et **monthly** (dernier jour de bourse du mois). 5 actifs : BTC-USD, ETH-USD (crypto), SPY (actions), TLT, ZN=F (obligations/taux).

En clair : un seul jeu de prix, découpé en trois cadences. Rien n'est inventé par fréquence — seule la granularité change.

3. La découpe train / validation / test — sans aucune fuite

Pour chaque fréquence, la série est coupée en **trois blocs disjoints et chronologiques** (`three_way_split`) :

Bloc	Ce que c'est	À quoi il sert — et à quoi il ne sert JAMAIS
TRAIN (≤ T0)	Tout l'historique jusqu'à T0	Entraîner le modèle. C'est la seule donnée que le modèle « voit ».

VALIDATION (n_val origines)	Le bloc juste après T0	Uniquement choisir le budget d'époques (argmin CRPS). Ne sert pas à mesurer la performance finale.
TEST / OOS (n_test origines)	Le bloc encore après, jusqu'à la fin (moins une marge de 3)	Produire les prévisions évaluées (les verdicts). N'est touché par aucun réglage.

Le point anti-ambiguïté. Le test est **strictement postérieur** à la validation, qui est strictement postérieure au train. Aucune donnée de test ne participe au moindre choix (budget d'époques, seuils, sélection). La marge de 3 points garantit que les cibles $W+1/2/3$ (ou $M+1/2/3$) de la dernière origine existent vraiment. « *Un modèle sur-appris paraîtrait parfait sur le train — la mesure n'y aurait aucune valeur.* »

4. Les trois régimes — même cible, chemins différents

Régime	Définition	Où on l'utilise
A	Modèle daily projeté à D+7 calendaires (7 jours fixes)	Ancienne approche ; abandonnée pour la comparaison rigoureuse (biais de définition d'horizon en crypto).
B	Modèle entraîné en daily , puis lu à la distance réelle en jours de bourse jusqu'à la cible-vendredi (ou fin de mois)	« daily poussé » — le côté daily des comparaisons daily-vs-weekly / daily-vs-monthly.
C	Modèle entraîné nativement à la fréquence cible (série resamplée en hebdo / mensuel), horizon = 3 pas	Le côté « natif » ; c'est ce qu'affichent les dashboards weekly et monthly.

*En clair : B et C visent **exactement la même chose** (le prix à 1 semaine, ou à 1 mois), par deux chemins. On compare donc bien deux façons de prévoir la même cible — pas « 1 jour contre 1 semaine ».*

5. Ce que contient la base `tracking.db` — par source

Source	Lignes	Contenu	Fenêtre	Ce que ça alimente
oos	27 524	Backtest figé (<i>train-once-forward</i>), 7 modèles ; daily D1/D7, weekly & monthly (régimes B et C)	2023-01-31 → 2026-07-20	Dashboards (daily, weekly, monthly), mini-dashboard D7/W1, verdicts
live	1 510	Prévisions réelles « en avant » : daily (7 modèles) + weekly (NsDiff, TSDiff)	2026-07-06 → 2026-08-02	Suivi de production, lignes récentes des dashboards
backtest_rolling_nsdiff	1 080	Backtest à refit périodique (≠ train-once), NsDiff hebdo, isolé	2024-10-18 → 2026-07-03	Backtest économique (PnL/Sharpe vs GARCH) — pas le dashboard

Pourquoi trois sources. `oos` = « comment le modèle se serait comporté sur le passé » (mesure figée) ; `live` = « ce qu'il prédit vraiment maintenant » ; `backtest_rolling` = une étude séparée, avec réentraînement périodique, réservée à la valeur économique — cloisonnée pour ne pas contaminer les mesures OOS.

6. Détail par fréquence — donnée → traitement → sortie

6.1 Daily cœur du dashboard

- **Donnée** : série daily, **fenêtre glissante ~3 ans** recalée à chaque date de run (ex. run 2026-08-04 → 2023-08-04 → 2026-08-02).
- **Traitement** : pipeline `Run/` — **réentraînement à chaque jour de run** ($\neq$ train-once), seed 42, découpe train/validation (`train_end` $\approx$ 2026-02-18, `n_val` = 113 à D+1). Horizons D+1 et D+7.
- **Sortie** : artefacts `Run/<date>-<modèle>-<actif>-<horizon>/` (metrics, predictions, prices) — 27 dates (2026-07-07 → 2026-08-04), 7 modèles $\times$ 5 actifs ; miroir en base (`oos` D1/D7 dont les `run_id` sont les dossiers Run, + `live` daily).
- **Ce que ça produit** : KPIs daily (RMSE, MAE, Cov95, CRPS, Diebold-Mariano...) + signaux de trading TC1.1-1.5 résolus à **D+1** (5 modèles, jamais Naive).

6.2 Weekly régime C affiché : TSDiff & NsDiff

- **Donnée** : série weekly resamplée depuis 2015.
- **Traitement** : *train-once-forward* (entraîné une fois avant la 1^{re} origine, jamais réentraîné dans la boucle), seed 42, `seq_len` 30, budget d'époques 40 **choisi sur la validation**. Origines de test **reprises verbatim** des 5 baselines (aucun recalcul de découpe) → régimes B et C strictement appariés à cible identique. Marge `WEEK_MARGIN` = 3.
- **Sortie** : `tracking.db` — 90 origines/actif OOS (2024-10-18 → 2026-07-03) + quelques lignes `live` (fin juillet 2026). 7 modèles en base, **2 affichés** (TSDiff, NsDiff).
- **Ce que ça produit** : dashboard weekly (Cov95 exacte, CRPS gaussien approché) ; comparaison daily-vs-weekly (mini-dashboard D7/W1) ; duel TSDiff vs NsDiff. Présenté comme gain de **calibration**, jamais de précision.

6.3 Monthly nouvellement affiché

- **Donnée** : série monthly (dernier jour de bourse du mois) ; ~130-140 clôtures depuis 2015.
- **Traitement** : *train-once-forward*, `seq_len` **18** (~1,5 an, choix déclaré vs 30 en daily), budget 40, `k_denoise` 20. Découpe **auto-générée** (`three_way_split_monthly`, marge `MONTH_MARGIN` = 3) car aucune baseline mensuelle n'existait à réutiliser : `n_val` = 6, `n_test` = 40. Ex. SPY : train jusqu'à 2022-06-30, validation 2022-07 → 2022-12, test 40 origines.
- **Sortie** : `tracking.db` — 40 origines/actif (2023-01-31 → 2026-04-30), régimes B et C, **NsDiff & TSDiff** seulement.
- **Ce que ça produit** : dashboard monthly (branché le 10 août 2026, régime C affiché).

Réserve de puissance (mensuel). Cibles M+1/2/3 recouvrantes + peu de mois → **effective_n $\approx$ 10** (contre $\approx$ 30 en weekly). Les verdicts « indistinguishable » sont l'effet **attendu** du faible échantillon, jamais une équivalence démontrée.

7. Le budget d'échantillonnage (modèles de diffusion)

Pour NsDiff / TSDiff, une prévision n'est pas un chiffre mais un **nuage de tirages** → médiane + bande à 95 %. Réglages : `seq_len` 30 (daily) / 18 (monthly), `k_denoise` 20, `epochs` 40, `n_samples` 50 par graine — en cours de bascule vers un **ensemble 5 graines (42-46) $\times$ 200 tirages = 1000** pour fiabiliser les bandes.

Ce que le budget règle, et ce qu'il ne touche jamais. Le nombre d'époques est choisi **sur la validation** (argmin CRPS) ; le nombre de tirages est fixé par convergence. **Ni l'un ni l'autre** n'est réglé sur le test, et aucun facteur correctif a posteriori n'est appliqué aux intervalles. La couverture 95 % n'est **mesurée** que sur l'OOS.

8. Ce que chaque donnée a permis de conclure

- **OOS daily & weekly** → TSDiff et NsDiff perdent sur la précision du point et le CRPS ; leur force est la **calibration**. NsDiff bat TSDiff sur la calibration (Winkler, couverture) ; côté weekly natif, la calibration l'emporte nettement sur le daily poussé. **Rien ne bat GARCH(1,1)** au test SPA.
- **OOS monthly** → faible puissance assumée : verdicts surtout « indistinguishable », à ne pas lire comme équivalence.
- **backtest_rolling (isolé)** → alimente le **backtest économique** (PnL/Sharpe/drawdown vs GARCH, frais à 0 € pour l'instant) — la calibration n'est pas la valeur économique, d'où cette étude séparée.

9. Récapitulatif — donnée → usage → livrable

Donnée	Comment utilisée	Pour produire quoi
Prix bruts (2015→, yfinance + snapshot)	Resampling daily/weekly/monthly ; vérif last_close	Les 3 séries de base
Bloc TRAIN	Entraînement du modèle	Le modèle ajusté
Bloc VALIDATION	Choix du budget d'époques (argmin CRPS) uniquement	Hyperparamètre d'entraînement
Bloc TEST / OOS	Prévision à chaque origine, jamais touché par un réglage	Les verdicts (RMSE, Cov95, Winkler, CRPS...)
Artefacts Run/** (daily)	Lus par le générateur de dashboard	KPIs daily + signaux TC (D+1)
oos weekly/monthly	Lu par les dashboards (régime C)	Surfaces weekly & monthly, comparaison D7/W1
live	Prévisions en avant enregistrées	Suivi de production
backtest_rolling_nsdiff	Backtest à refit périodique, isolé	Backtest économique vs GARCH